ĐẠI HỌC BÁCH KHOA HÀ NỘI

ĐỒ ÁN TỐT NGHIỆP

Hệ thống hỏi đáp pháp luật Việt Nam

LÊ DUY ANH
anh.ld204629@sis.hust.edu.vn

Ngành: Khoa học máy tính

Giảng viên hướng dẫn: TS. Ngô Văn Linh _____

Chữ kí GVHD

Khoa: Khoa học máy tính

Trường: Công nghệ Thông tin và Truyền thông

HÀ NỘI, 06/2024

LỜI CẢM ƠN

Trong quá trình thực hiện đồ án, em xin gửi lời cảm ơn chân thành đến thầy Ngô Văn Linh đã tận tình hướng dẫn, giúp đỡ và giải đáp thắc mắc để em có thể hoàn thành tốt đồ án tốt nghiệp này. Bên cạnh đó, em cũng xin cảm ơn tới các thầy cô trong đội ngũ giảng viên tại Đại học Bách Khoa Hà Nội đã truyền đạt những kiến thức, kinh nghiệm cho em trong suốt 4 năm học vừa qua.

Em xin biết ơn sâu sắc tới bố mẹ và anh chị em của em, nguồn động lực to lớn cho em để em không ngừng cố gắng. Em xin cảm ơn tới người thân, bạn bè đã luôn đồng hành bên em. Những tình cảm, sẻ chia , động viên của mọi người dành cho em đã giúp em vượt qua những chặng đường vô cùng khó khăn.

Em cũng muốn cảm ơn bản thân mình đã cố gắng, nỗ lực hết mình để hoàn thành đồ án tốt nghiệp này. Những trải nghiệm đó không chỉ giúp em trưởng thành, mạnh mẽ hơn mà còn dạy cho em sự kiên nhẫn, can đảm, tự tin hơn để đến với những cơ hội, những cánh cửa hy vọng mới trong cuộc sống.

LỜI CAM KẾT

Họ và tên sinh viên: Lê Duy Anh
Điện thoại liên lạc: 0971920270
Email: anh.ld204629@sis.hust.edu.vn
Lớp: KHMT05-K65
Hệ đào tạo: Kỹ sư chính quy

Tôi – *Lê Duy Anh* – cam kết Đồ án Tốt nghiệp (ĐATN) là công trình nghiên cứu của bản thân tôi dưới sự hướng dẫn của *TS.Ngô Văn Linh*. Các kết quả nêu trong ĐATN là trung thực, là thành quả của riêng tôi, không sao chép theo bất kỳ công trình nào khác. Tất cả những tham khảo trong ĐATN – bao gồm hình ảnh, bảng biểu, số liệu, và các câu từ trích dẫn – đều được ghi rõ ràng và đầy đủ nguồn gốc trong danh mục tài liệu tham khảo. Tôi xin hoàn toàn chịu trách nhiệm với dù chỉ một sao chép vi phạm quy chế của nhà trường.

Hà Nội, ngày tháng năm

Tác giả ĐATN

Họ và tên sinh viên

TÓM TẮT NỘI DUNG ĐỒ ÁN

Ngày nay, nhu cầu tìm kiếm thông tin về pháp luật của người dân ngày càng tăng cao, nên việc truy xuất thông tin chính xác, đầy đủ và nhanh chóng là rất cần thiết. Những hệ thống hỏi đáp truyền thống thường gặp những thách thức trong việc truy xuất thông tin do việc hiểu nội dung, ngữ cảnh của câu hỏi cũng như văn bản còn rất hạn chế, từ đó người dùng có thể nhận về những thông tin không chính xác gây ra mất thời gian và ảnh hưởng đến trải nghiệm người dùng. Vì vậy, việc xây dựng một hệ thống hỏi đáp về pháp luật có độ chính xác cao sẽ đem lại nhiều lợi ích.

Hướng tiếp cận của em là sử dụng kết hợp các mô hình truy xuất với nhau, các mô hình nhúng văn bản, để tận dụng được điểm mạnh của từng mô hình. Trong đó, với mô hình nhúng văn bản thì em sử dụng nhiều kiến trúc tiên tiến hiện nay như Condenser, coCondenser kết hợp với mô hình BGE-m3 Embedding đã được tiền huấn luyện cho đa ngôn ngữ trong đó có tiếng Việt.

Về giải pháp, em sử dụng mô hình bi-encoder để truy xuất ra các ứng cử viên sau đó sử dụng mô hình cross-encoder để xếp hạng lại các ứng cử viên đó và kết hợp điểm đánh giá rồi đưa ra kết quả sau cùng. Trong đó bi-encoder sẽ là sự kết hợp của hai loại mô hình, một là mô hình dựa trên PhoBERT với những tri thức mạnh mẽ về ngôn ngữ tiếng Việt và sẽ được em tiền huấn luyện, tinh chỉnh trên miền dữ liệu của bài toán hỏi đáp pháp luật, hai là BGE-m3 embedding đang là mô hình nhúng văn bản tốt nhất cho tới thời điểm em thực hiện đồ án này. Và BGE-m3 cũng là lựa chọn của em cho mô hình cross-encoder. Ngoài ra, các phương pháp tiền huấn luyện, tinh chỉnh mô hình cụ thể sẽ được em trình bày trong đồ án này.

Đóng góp chính của đồ án tốt nghiệp của em là xây dựng, cải thiện một hệ thống hỏi đáp pháp luật với khả năng truy xuất có độ chính xác cao bằng cách sử dụng các kiến trúc tiên tiến hiện nay. Kết quả đạt được sau cùng là giúp người dùng có thể tiếp cận với những văn bản pháp luật phù hợp nhất với câu hỏi, sự quan tâm, thắc mắc của người dùng.

MỤC LỤC

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI 1

1.1 Đặt vấn đề 1

1.2 Các giải pháp hiện tại và hạn chế 1

1.3 Đóng góp của đồ án 2

1.4 Bố cục đồ án 3

CHƯƠNG 2. NỀN TẢNG LÝ THUYẾT 4

2.1 Mô hình truy xuất thông tin 4

2.2 Phương pháp xếp hạng BM25 5

2.3 Phương pháp mã hóa Bi-encoder 6

2.4 Phương pháp mã hóa Cross-encoder 7

2.5 Phương pháp học tương phản Contrastive learning 9

2.6 Mô hình Condenser và biến thể coCondenser 10

2.7 Mô hình XLM-RoBERTa 13

CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT 14

3.1 Tổng quan giải pháp 14

3.1.1 Sơ đồ hoạt động 14

3.1.2 Mô hình PhoBERT-base v2 15

3.1.3 Mô hình BGE-m3 Embedding 15

3.2 Tiền xử lý dữ liệu 18

3.3 Huấn luyện Retriever 18

3.3.1 Huấn luyện mô hình BM25 19

3.3.2 Tiền huấn luyện bi-encoder 19

3.3.3 Tinh chỉnh bi-encoder 20

3.4 Huấn luyện Reranker 20

CHƯƠNG 4. ĐÁNH GIÁ THỰC NGHIỆM 22

4.1 Dữ liệu sử dụng 22

4.1.1 Tổng quan về dữ liệu 22

4.1.2 Thống kê về dữ liệu 22

4.2 Tham số đánh giá 23

4.3 Đường cơ sở 23

4.4 Thiết lập thí nghiệm 23

4.5 Kết quả thí nghiệm 24

4.5.1 Thí nghiệm tinh chỉnh mô hình BM25 24

4.5.2 Thí nghiệm so sánh các hàm mất mát 25

4.5.3 Thí nghiệm so sánh các mô hình bi-encoder 25

4.5.4 Thí nghiệm bổ sung BM25 26

4.5.5 Thí nghiệm bổ sung chunking dữ liệu 27

4.5.6 Thí nghiệm bổ sung reranker và tổng hợp các thành phần 28

4.5.7 Thí nghiệm so sánh tốc độ truy xuất của các mô hình 30

CHƯƠNG 5. KẾT LUẬN 32

5.1 Kết luận 32

5.2 Hướng phát triển trong tương lai 32

TÀI LIỆU THAM KHẢO 35

PHỤ LỤC 37

A. Kiến trúc mô hình BERT 37

A.1 Mô hình BERT 37

A.1.1 Cơ chế chú ý nội bộ 37

A.1.2 Mô hình ngôn ngữ mặt nạ (Masked Language Model - MLM) 39

A.1.3 Dự đoán câu tiếp theo (Next Sentence Prediction - NSP) 40

A.1.4 Quá trình tiền huấn luyện và tinh chỉnh mô hình BERT 41

DANH MỤC HÌNH VẼ

Hình 2.1 Kiến trúc bi-encoder 6
Hình 2.2 Kiến trúc cross-encoder 8
Hình 2.3 Kiến trúc của Condenser Nguồn: [8] 11

Hình 3.1 Sơ đồ hoạt động của mô-đun Retrieval 14
Hình 3.2 Quá trình huấn luyện nhiều giai đoạn của BGE-m3 embedding với phương pháp tự chắt lọc kiến thức. Nguồn: [12] 17
Hình 3.3 Luồng hoạt động của quá trình tiền huấn luyện, tinh chỉnh các mô hình của Retriever. 19
Hình 3.4 Luồng hoạt động của quá trình tinh chỉnh mô hình Reranker . 21

Hình 4.1 Biểu đồ phân bố theo độ dài token của các văn bản pháp luật . 22
Hình 4.2 Biểu đồ phân bố theo độ dài token của các câu truy vấn 23

Hình A.1 Scaled Dot-Product Attention. Nguồn: [13] 38
Hình A.2 Multi-Head Attention. Nguồn: [13] 39
Hình A.3 Mô hình ngôn ngữ mặt nạ 40
Hình A.4 Sơ đồ tiền huấn luyện và tinh chỉnh mô hình BERT. Nguồn: [3] 42

DANH MỤC BẢNG BIỂU

Bảng 4.1 Độ chính xác (%) của mô hình BM25 khi tinh chỉnh siêu tham số k_1 và b 24
Bảng 4.2 Độ chính xác (%) của mô hình PhoBERT-base v2 vòng 1 với các hàm loss 25
Bảng 4.3 Độ chính xác (%) của các mô hình bi-encoder chưa tinh chỉnh, tinh chỉnh vòng 1 và tinh chỉnh vòng 2 25
Bảng 4.4 Độ chính xác (%) của các mô hình BGE-m3 vòng 1 26
Bảng 4.5 Độ chính xác (%) của mô hình bi-encoder vòng 2 kết hợp với BM25 27
Bảng 4.6 Độ chính xác (%) của mô hình BGE bi-encoder vòng 2 kết hợp chunking dữ liệu và BM25 với hai thiết lập về kích thước chunk là 256 và 512. 28
Bảng 4.7 Độ chính xác (%) của mô hình baseline và các mô hình bi-encoder vòng 2 khi bổ sung thành phần reranker 29
Bảng 4.8 Tốc độ truy xuất của các mô hình (giây/1 truy vấn) 30

DANH MỤC THUẬT NGỮ VÀ TỪ VIẾT TẮT

Thuật ngữ	**Ý nghĩa**
BERT	Bidirectional Encoder Representations from Transformers
BGE	BAAI General Embedding
BM25	Best Matching 25
CLS	Classification
IR	Truy xuất thông tin (Information Retrieval)
LSTM	Long-Short Term Memory
MLM	Mô hình ngôn ngữ mặt nạ (Masked Language Model)
NLP	Xử lý ngôn ngữ tự nhiên (Natural Language Processing)
RNN	Recurrent Neural Network
RoBERTa	Robustly Optimized BERT Approach
SOTA	State Of The Art
TF-IDF	Term Frequency – Inverse Document Frequency
XLM	Cross-lingual Language Model

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

1.1 Đặt vấn đề

Trong xã hội hiện đại, sự phát triển của công nghệ số đã mở ra nhiều cơ hội mới cho việc truy cập và sử dụng thông tin pháp luật. Tuy nhiên, việc tiếp cận và hiểu rõ các quy định về pháp luật vẫn là một thách thức đối với nhiều người, đặc biệt là những người không có nền tảng chuyên môn về pháp luật. Sự phức tạp của ngôn ngữ và cấu trúc pháp lý khiến cho quá trình tìm kiếm thông tin cụ thể trở nên khó khăn và tốn kém thời gian. Việc truy xuất thông tin pháp luật không chỉ đòi hỏi kiến thức chuyên môn mà còn cần các công cụ hỗ trợ mạnh mẽ để tìm kiếm và phân tích thông tin một cách hiệu quả. Với khối lượng lớn các văn bản pháp luật được ban hành, việc tìm kiếm thông tin chính xác và phù hợp trở thành một vấn đề quan trọng. Điều này đặt ra yêu cầu cần có một hệ thống hỗ trợ người dùng trong việc truy vấn và xử lý thông tin pháp luật một cách nhanh chóng và hiệu quả.

Một hệ thống hỏi đáp pháp luật tự động có thể đáp ứng nhu cầu này bằng cách sử dụng các mô hình ngôn ngữ hiện đại để hiểu và xử lý các câu hỏi về pháp luật. Mô-đun truy xuất thông tin (Retrieval) trong hệ thống này đóng vai trò quan trọng trong việc xác định và trích xuất các văn bản pháp luật liên quan từ cơ sở dữ liệu.

Mục tiêu của nghiên cứu này là xây dựng một mô-đun truy xuất thông tin pháp luật, nhằm nâng cao hiệu suất và độ chính xác của hệ thống hỏi đáp pháp luật. Bằng cách áp dụng các kỹ thuật tiên tiến trong xử lý ngôn ngữ tự nhiên (NLP), nghiên cứu này hy vọng sẽ tạo ra một công cụ hỗ trợ đắc lực cho người dùng trong việc tìm kiếm và hiểu rõ các quy định pháp luật, từ đó góp phần nâng cao hiệu quả công việc và cuộc sống.

1.2 Các giải pháp hiện tại và hạn chế

Đã có rất nhiều các phương pháp truy xuất thông tin văn bản hiệu quả như những phương pháp dựa trên thống kê, phương pháp sử dụng các mô hình học sâu hiện đại nhưng mỗi phương pháp đều có những ưu điểm, hạn chế riêng:

Phương pháp dựa trên thống kê như TF-IDF [1], BM25 [2] ước lượng độ tương đồng giữa 2 văn bản dựa trên tần suất và sự xuất hiện các từ vựng, tuy là những mô hình đơn giản, dễ hiểu và hiệu quả nhưng còn hạn chế vì không nắm bắt được ngữ cảnh, ý nghĩa của câu mà chỉ dựa trên so khớp từ vựng.

Phương pháp sử dụng cross-encoder: Cross-encoder là mô hình mã hóa cặp, nơi cả câu truy vấn và các câu ứng cử viên được mã hóa cùng nhau qua một mạng nơ-ron duy nhất. Phương pháp này cho phép mô hình nắm bắt được ngữ cảnh và

mối quan hệ giữa các câu một cách tốt hơn so với các phương pháp thống kê truyền thống. Cross-encoder thường sử dụng các kiến trúc mô hình hiện đại như BERT [3] hay RoBERTa [4] để mã hóa và tính toán độ tương đồng giữa các câu. Một nghiên cứu nổi bật về cross-encoder là của Nogueira và Cho [5], trong đó họ sử dụng BERT để thực hiện nhiệm vụ truy xuất thông tin trên bộ dữ liệu MS MARCO [6]. Kết quả thí nghiệm cho thấy mô hình BERT cross-encoder đạt được kết quả tốt hơn so với các phương pháp truyền thống như BM25. Tuy nhiên, thời gian xử lý truy vấn của cross-encoder lại lâu hơn rất nhiều (do phải mã hóa lại toàn bộ cặp câu mỗi khi thực hiện truy vấn), làm giảm khả năng ứng dụng trong thực tế.

Phương pháp sử dụng bi-encoder: Bi-encoder là mô hình mã hóa song song, trong đó câu truy vấn và văn bản được mã hóa riêng rẽ sau đó so sánh vector mã hóa để tính toán độ tương đồng. SBERT [7] là mô hình sử dụng kiến trúc bi-encoder tạo vector biểu diễn cho mỗi câu đầu vào sau đó tính độ tương đồng cosine. Tuy nhiên theo Gao và Callan [8], cấu trúc self-attention (chú ý nội bộ) của các mô hình ngôn ngữ tiêu chuẩn chưa sẵn sàng để sử dụng cho các mã hóa dày đặc vì cần phải tổng hợp thông tin văn bản vào vector biển diễn dày đặc (dense vector). Qua đó, các tác giả đề xuất kiến trúc Condenser và coCondenser [9] để khắc phục nhược điểm trên.

Về các giải pháp truy xuất văn bản pháp luật Việt Nam, nhóm của Hà và các cộng sự [10] đã sử dụng TF-IDF, BM25 kết hợp với tinh chỉnh PhoBERT nhưng mô hình còn khá đơn giản, chưa đạt được độ hiệu quả cao. Minh và các cộng sự [11] đã sử dụng BM25+ kết hợp với huấn luyện bi-encoder nhiều vòng tuy nhiên chưa tận dụng được hết thế mạnh của các phương pháp truy xuất. Một số giải pháp được đề xuất trong cuộc thi Zalo AI Challenge 2021 cũng sử dụng các phương pháp như huấn luyện Condenser, coCondenser nhưng chưa đủ tối ưu.

Các nghiên cứu hiện tại về truy xuất văn bản pháp luật Việt Nam đã đạt được một số thành tựu nhất định, tuy nhiên vẫn còn nhiều hạn chế cần khắc phục. Việc kết hợp các phương pháp truy xuất truyền thống với các mô hình học sâu tiên tiến, cải thiện chất lượng dữ liệu huấn luyện sẽ là hướng đi cần thiết để nâng cao hiệu quả của các hệ thống truy xuất thông tin pháp luật.

1.3 Đóng góp của đồ án

Trong đồ án này em đã tiến hành nghiên cứu, thử nghiệm với nhiều phương pháp, mô hình và thu được các đóng góp chính như sau:

1. Sử dụng mô hình xếp hạng BM25, kiến trúc bi-encoder kết hợp với cross-encoder để tận dụng được khả năng so khớp về từ vựng của BM25, tốc độ truy xuất nhanh của bi-encoder và khả năng chính xác cao của cross-encoder.

2. Sử dụng kiến trúc Condenser, coCondenser kết hợp với BGE-m3 [12] cho mô-đun retriever và mô hình BGE-m3 cho mô-đun reranker và đạt được hiệu năng cao.
3. Sử dụng phương pháp chunking dữ liệu để giúp hệ thống có thể xử lý tốt với cả những văn bản pháp luật dài.
4. Thử nghiệm nhiều kiến trúc để so sánh độ hiệu quả cũng như tốc độ xử lý của hệ thống để tìm ra phương pháp tốt nhất có thể.

1.4 Bố cục đồ án

Các chương còn lại của báo cáo đồ án tốt nghiệp này sẽ có những nội dung chính như sau:

Chương 2 trình bày về các cơ sở lý thuyết chính cho đồ án. Tại đây, em sẽ trình bày sơ qua về mô hình truy xuất thông tin (Information Retrieval – IR), mô hình xếp hạng BM25, mô hình bi-encoder, cross-encoder, học biểu diễn tương phản, kiến trúc Condenser, coCondenser, mô hình XLM-RoBERTa.

Chương 3 trình bày về giải pháp đề xuất, em sẽ trình bày về kiến trúc em lựa chọn thực hiện trong đồ án này, mô hình PhoBERT, mô hình BGE-m3 và cách em tiền xử lý dữ liệu, tiền huấn luyện và tinh chỉnh các mô hình nhiều vòng, phương pháp khai thác các mẫu âm khó.

Chương 4 trình bày về kết quả đánh giá thực nghiệm, em sẽ giới thiệu về các cài đặt, các tham số lựa chọn, em sẽ trình bày về các kịch bản thử nghiệm và phân tích kết quả để so sánh, đánh giá để thấy rõ hơn hiệu quả của mô hình.

Trong chương 5 cũng là chương cuối cùng của đồ án, em sẽ đưa ra những kết luận về những điều đã làm được, những hạn chế của đồ án và các định hướng phát triển trong tương lai.

CHƯƠNG 2. NỀN TẢNG LÝ THUYẾT

Trong phần này, em sẽ trình bày sơ qua về kiến trúc phổ biến của mô hình truy xuất thông tin (Information Retrieval - IR) cũng như lý thuyết cơ bản về các kiến trúc, mô hình được sử dụng trong từng khối chức năng.

2.1 Mô hình truy xuất thông tin

Truy xuất thông tin (Information Retrieval – IR) là quá trình tìm kiếm và truy xuất các thông tin có liên quan từ một kho dữ liệu lớn bao gồm các văn bản, hình ảnh, âm thanh (trong bài toán hỏi đáp về pháp luật thì dữ liệu là văn bản) để đáp ứng nhu cầu tìm kiếm thông tin cụ thể của người dùng. Mục tiêu của hệ thống IR là tìm và cung cấp những thông tin, tài liệu phù hợp nhất dựa trên truy vấn của người dùng.

Có nhiều mô hình khác nhau được sử dụng trong bài toán về truy xuất thông tin, mỗi mô hình lại có một cách tiếp cận riêng và những thuật toán riêng để tính toán, đánh giá nhằm xếp hạng tài liệu.

Mô hình Boolean là một trong những mô hình IR đơn giản và cơ bản nhất. Trong mô hình này, truy vấn của người dùng sẽ được biểu diễn dưới dạng các biểu thức sử dụng toán tử AND, OR, NOT. Một tài liệu được coi là phù hợp với truy vấn nếu nó thỏa mãn biểu thức Boolean của truy vấn đó. Ngoài ưu điểm là đơn giản, dễ hiểu thì nhược điểm của phương pháp này là không đánh giá được mức độ liên quan của tài liệu (score), do đó khiến kết quả truy vấn có thể quá nhiều hoặc quá ít tùy thuộc vào cách diễn đạt truy vấn.

Mô hình xác suất (Probabilistic) là mô hình dựa trên lý thuyết xác suất để ước tính khả năng một tài liệu có liên quan đến một truy vấn cụ thể không. Một trong những mô hình xác suất phổ biến là mô hình BM25. Ưu điểm của các mô hình xác suất là cung cấp được mức độ liên quan, thường có hiệu suất tốt hơn so với mô hình Boolean, tuy nhiên cần phải hiệu chỉnh các tham số sao cho phù hợp với tập dữ liệu cụ thể.

Mô hình nhúng câu (Sentence Embedding Models) là các mô hình học sâu hiện đại, sử dụng kiến trúc Transformer [13] để tạo ra các biểu diễn ngữ nghĩa của câu hoặc đoạn văn. Các mô hình này có khả năng hiểu ngữ cảnh phức tạp và cung cấp biểu diễn vector cho các đoạn văn bản. Các mô hình này cải thiện độ chính xác và hiệu quả của hệ thống truy xuất thông tin nhờ khả năng xử lý ngôn ngữ tự nhiên tốt giúp hiểu ngữ nghĩa phức tạp của văn bản. Tuy nhiên các mô hình này lại yêu cầu nhiều tài nguyên tính toán và dữ liệu huấn luyện, dẫn tới sự phức tạp trong việc

triển khai cũng như tối ưu hóa so với các mô hình truyền thống.

Các mô hình truy xuất thông tin rất đa dạng và phong phú, từ các mô hình cơ bản như Boolean và xác suất đến các mô hình hiện đại như mô hình nhúng sử dụng học sâu (BERT, RoBERTa, XLM-RoBERTa [14], ...). Mỗi mô hình có những ưu nhược điểm riêng, và việc lựa chọn mô hình phù hợp phụ thuộc vào yêu cầu cụ thể của ứng dụng. Với bài toán truy xuất về pháp luật thì chắc chắn sẽ ưu tiên các mô hình nhúng hiện đại với khả năng hiểu và xử lý ngôn ngữ tự nhiên, từ đó năng cao hiệu suất của hệ thống.

2.2 Phương pháp xếp hạng BM25

BM25 viết tắt của Best Matching 25 là một phương pháp xếp hạng được sử dụng rộng rãi nhất trong truy xuất thông tin. BM25 dựa trên lý thuyết xác suất và được thiết kế để ước lượng mức độ liên quan của tài liệu đối với một truy vấn cụ thể. Nó sử dụng thông tin về tần suất xuất hiện của các từ khóa trong tài liệu và truy vấn, cũng như độ dài của tài liệu, để tính toán điểm số cho tài liệu đó. Điểm số này sẽ phản ánh mức độ phù hợp của tài liệu với truy vấn đó.

Công thức tính độ tương đồng của một tài liệu P đối với một truy vấn Q:

$$\text{similar}(P, Q) = \sum_{i=1}^{n} \text{IDF}(q_i) \cdot \frac{f(q_i, P) \cdot (k_1 + 1)}{f(q_i, P) + k_1 \cdot (1 - b + b \cdot \frac{|P|}{\text{avg(p)}})} \tag{2.1}$$

Trong đó, q_i là từ khóa thứ i trong truy vấn Q, $f(q_i, P)$ là tần suất xuất hiện của từ khóa q_i trong tài liệu P, $|P|$ là độ dài của tài liệu P, và avg(p) là độ dài trung bình của các tài liệu trong tập dữ liệu. Tham số k_1 điều chỉnh độ nhạy của mô hình với tần suất từ khóa, trong khi b điều chỉnh ảnh hưởng của độ dài tài liệu.

Trọng số IDF có công thức như sau:

$$\text{IDF}(q_i) = \log\left(\frac{N - n_{q_i} + 0.5}{n_{q_i} + 0.5} + 1\right) \tag{2.2}$$

Trong đó, N là tổng số tài liệu và n_{q_i} là số lượng tài liệu chứa từ khóa q_i.

Về ưu điểm, BM25 có khả năng xếp hạng tài liệu một cách hiệu quả dựa trên độ liên quan giữa tài liệu và truy vấn, nhờ vào cách tính toán xác suất dựa trên tần suất từ xuất hiện trong tài liệu. BM25 có thể linh hoạt điều chỉnh các siêu tham số để cải thiện hiệu quả. Với tính toán đơn giản và nhanh chóng thì BM25 có thể dễ dàng tích hợp vào các hệ thống tìm kiếm.

Về nhược điểm, BM25 chỉ dựa trên tần suất từ và không xem xét ngữ cảnh của

từ trong tài liệu, do đó có thể bỏ qua các mối quan hệ ngữ nghĩa quan trọng. BM25 không hoạt động tốt với các truy vấn rất ngắn, không có khả năng xử lý các từ đồng nghĩa.

Tóm lại, BM25 là một mô hình xếp hạng rất hiệu quả, mang lại hiệu suất tìm kiếm tốt trong nhiều trường hợp, tuy nhiên còn nhiều hạn chế đặc biệt là trong lĩnh vực xử lý ngôn ngữ tự nhiên.

2.3 Phương pháp mã hóa Bi-encoder

Bi-encoder là một kiến trúc mạng neural được sử dụng phổ biến trong các truy xuất thông tin, ghép cặp văn bản. Ý tưởng của bi-encoder là mã hóa hai đoạn văn bản thành hai vector nhúng trong cùng không gian vector, để sau đó có thể so sánh bằng cách sử dụng các độ đo tương đồng như cosine similarity.

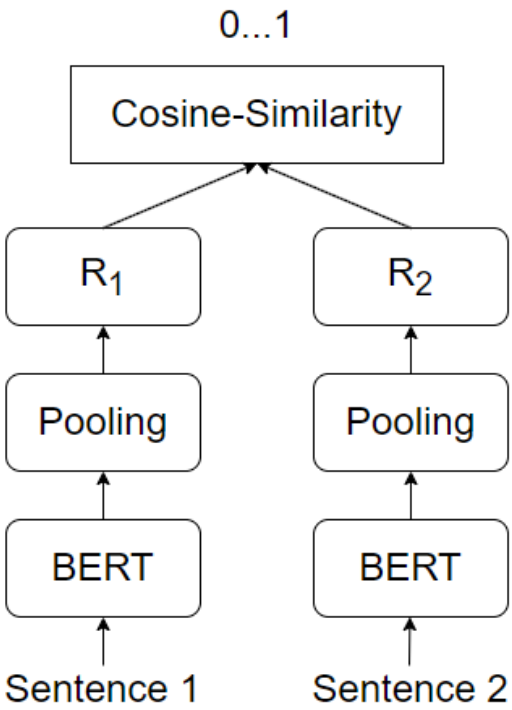

Hình 2.1: Kiến trúc bi-encoder

Ban đầu hai đoạn văn bản được chuyển thành danh sách các token để đưa qua mô hình mã hóa để thu được danh sách các vector nhúng, các mô hình dùng để mã hóa thường dựa trên kiến trúc Encoder của Transformers, ví dụ như BERT, RoBERTa, XLM-RoBERTa,. . . .

$$V_1 = \text{Encoder}(Sentence_1), \quad V_2 = \text{Encoder}(Sentence_2) \tag{2.3}$$

Sau đó các vector nhúng được đưa qua lớp pooling (thường là mean pooling,

max pooling hoặc là CLS pooling) để tạo ra các vector nhúng. Trong đó mean pooling là lấy giá trị trung bình của các vector nhúng, max pooling là lấy giá trị lớn nhất từ mỗi chiều của các vector nhúng, còn CLS pooling là lấy vector nhúng của token đặc biệt [CLS] để đại diện cho toàn văn bản.

$$R_1 = \text{Pooling}(V_1), \quad R_2 = \text{Pooling}(V_2) \tag{2.4}$$

Cuối cùng là tính độ tương đồng của hai vector nhúng bằng độ đo consine similarity, giá trị này xác định mức độ liên quan của hai văn bản ban đầu. Ngoài cosine similarity thì còn những cách tính độ tương đồng khác như Euclidean distance, Manhattan distance, tuy nhiên thông dụng nhất vẫn là cosine similarity.

$$\text{score} = \text{similarity}(R_1, R_2) = \frac{R_1 \cdot R_2}{\|R_1\|\|R_2\|} \tag{2.5}$$

Về ưu điểm, bi-encoder cho phép tính toán các vector nhúng độc lập, giúp ta tiết kiệm thời gian và tài nguyên tính toán khi xử lý nhiều cặp văn bản. Ngoài ra ta có thể tiết kiệm thời gian bằng cách lưu trữ trước các vector nhúng và chỉ tính toán độ tương đồng khi cần thiết.

Về nhược điểm, vì bi-encoder mã hóa hai đoạn văn bản một cách độc lập nên có thể mô hình không nắm bắt được đầy đủ ngữ cảnh liên quan giữa hai đoạn văn bản. Với những văn bản rất ngắn thì bi-encoder có thể hoạt động không hiệu quả.

Nhìn chung, bi-encoder là một phương pháp mạnh mẽ và hiệu quả trong mã hóa và so khớp văn bản, tuy nhiên để đạt được hiệu suất tối ưu, cần phải tinh chỉnh mô hình sao cho phù hợp.

2.4 Phương pháp mã hóa Cross-encoder

Cross-encoder là một kiến trúc mạng neural hiện đại được sử dụng rộng rãi trong các nhiệm vụ như truy vấn thông tin và ghép cặp văn bản. Mục tiêu chính của cross-encoder là mã hóa và so sánh hai đoạn văn bản cùng một lúc, cho phép mô hình hiểu rõ hơn về mối quan hệ ngữ nghĩa giữa chúng.

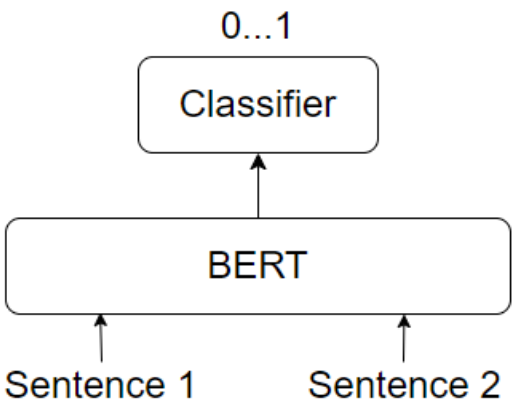

Hình 2.2: Kiến trúc cross-encoder

Trong cross-encoder, thay vì mã hóa từng đoạn văn bản riêng lẻ, hai đoạn văn bản được kết hợp lại thành một chuỗi duy nhất trước khi đưa vào mô hình. Các mô hình mã hóa thông dụng như BERT, RoBERTa, hoặc XLM-RoBERTa thường được sử dụng trong kiến trúc này. Hai đoạn văn bản được nối lại, sau đó chuyển đổi thành danh sách các token và được đưa vào mô hình để xử lý.

$$\text{Input} = [\text{CLS}], \text{Sentence}_1, [\text{SEP}], \text{Sentence}_2, [\text{SEP}] \tag{2.6}$$

Mô hình mã hóa toàn bộ chuỗi kết hợp này, và vector nhúng tương ứng với token [CLS] thường được sử dụng để biểu diễn toàn bộ cặp văn bản.

$$R = \text{Encoder}(\text{Input})_{[\text{CLS}]} \tag{2.7}$$

Vector nhúng [CLS] sau đó được đưa vào một lớp phân loại để xác định mức độ liên quan giữa hai đoạn văn bản. Kết quả có thể là một giá trị xác suất hoặc một nhãn phân loại, tùy thuộc vào ứng dụng cụ thể, trong bài toán này sẽ là một số thực thuộc đoạn [0,1].

$$\text{score} = \text{Classifier}(R) \tag{2.8}$$

Ưu điểm lớn nhất của cross-encoder là khả năng nắm bắt chi tiết ngữ nghĩa giữa hai đoạn văn bản, dẫn đến hiệu suất cao hơn trong các tác vụ như truy xuất thông tin. Điều này đặc biệt hữu ích khi yêu cầu độ chính xác cao.

Tuy nhiên, cross-encoder đòi hỏi tài nguyên tính toán đáng kể hơn so với bi-

encoder, vì mỗi cặp văn bản đều phải được xử lý đồng thời. Điều này làm cho cross-encoder trở nên kém hiệu quả hơn trong các ứng dụng yêu cầu xử lý nhanh hoặc quy mô lớn, nơi chi phí tính toán là một yếu tố quan trọng. Giả sử trong một hệ thống tìm kiếm lớn có 1 triệu văn bản trong cơ sở dữ liệu và mỗi truy vấn cần so sánh với tất cả văn bản này. Với bi-encoder, các văn bản có thể được mã hóa trước thành các vector nhúng và được lưu trữ, khi có truy vấn với thì chỉ cần mã hóa truy vấn này thành một vector nhúng và so sánh với các vector nhúng đã lưu trữ. Điều này giúp tiết kiệm tài nguyên tính toán vì mỗi truy vấn chỉ cần tính toán độ tương đồng với các vector nhúng đã được mã hóa sẵn với tốc độ rất nhanh. Còn với cross-encoder, với mỗi truy vấn mới sẽ có 1 triệu cặp (truy vấn, văn bản) cần được mã hóa, chi phí tính toán là rất lớn và không thực tế.

Tóm lại, cross-encoder là một phương pháp mạnh mẽ và chính xác trong việc so khớp văn bản, nhưng cần phải đánh đổi với tài nguyên tính toán. Để tận dụng được ưu điểm của cross-encoder thì có thể kết hợp sử dụng bi-encoder để có thể truy xuất thông tin nhanh và chính xác.

2.5 Phương pháp học tương phản Contrastive learning

Contrastive learning là một phương pháp học máy quan trọng, chủ yếu được sử dụng để học các biểu diễn hiệu quả từ dữ liệu. Contrastive learning tập trung vào việc học các biểu diễn sao cho các điểm dữ liệu tương tự (mẫu dương) gần nhau trong không gian nhúng và các điểm dữ liệu không tương tự (mẫu âm) xa nhau. Điều này được thực hiện thông qua tối ưu hóa một hàm mất mát tương phản (contrastive loss function).

Có nhiều công thức hàm mất mát trong học biểu diễn tương phản, tuy nhiên Contrastive Loss là hàm cơ bản và thông dụng nhất, có công thức như sau:

$$\mathcal{L} = \frac{1}{2N} \sum_{i=1}^{N} \left(y_i \cdot d_i^2 + (1 - y_i) \cdot \max(0, \text{margin} - d_i)^2 \right) \tag{2.9}$$

Trong đó, N là số lượng cặp dữ liệu, y_i là nhãn của cặp dữ liệu thứ i và y_i=1 nếu đây là cặp dương và y_i=0 nếu là cặp âm. d_i là khoảng cách giữa 2 mẫu dữ liệu trong cặp thứ i, margin là siêu tham số thể hiện khoảng cách tối thiểu mà ta muốn giữa các cặp âm.

Một trong những kỹ thuật quan trọng trong quá trình huấn luyện bằng học biểu diễn tương phản là khai thác các mẫu âm khó, là các điểm dữ liệu khác nhãn với điểm dữ liệu A nhưng lại có độ tương đồng cao với điểm dữ liệu A. Việc ta huấn luyện mô hình với các cặp dữ liệu này sẽ giúp mô hình cải thiện hơn trong việc

phân biệt các trường hợp khó này, dẫn tới độ chính xác cũng tăng.

Contrastive Learning là một phương pháp học máy mạnh mẽ và linh hoạt, giúp cải thiện hiệu suất của các mô hình thông qua việc kéo các mẫu dữ liệu tương tự lại gần nhau và đẩy các mẫu dữ liệu không tương tự ra xa, contrastive learning tối ưu hóa không gian biểu diễn để phản ánh mối quan hệ ngữ nghĩa giữa các mẫu.

2.6 Mô hình Condenser và biến thể coCondenser

Condenser [8] là một mô hình được xây dựng dựa trên BERT với mục đích khắc phục nhược điểm của BERT. Các nghiên cứu trước đây đã có thể tinh chỉnh BERT để mã hóa văn bản một cách hiệu quả cho việc truy xuất văn bản, tuy nhiên điều đó yêu cầu rất nhiều dữ liệu huấn luyện và các kỹ thuật phức tạp để huấn luyện. Một nghiên cứu về BERT của Clark và các cộng sự [15] đã chỉ ra rằng trong các lớp giữa của mô hình BERT thì token [CLS] không được các token khác chú ý (attention) đến nhiều, điều này có nghĩa là trong các lớp này [CLS] hoạt động như các token khác mà không có vai trò đặc biệt gì, không thu thập thông tin ngữ cảnh câu văn. Phải đến tận lớp cuối cùng thì token [CLS] mới có được sự chú ý của toàn bộ câu văn để tổng hợp thông tin ngữ cảnh từ các token khác giúp thực hiện tác vụ như phân loại văn bản, dự đoán câu tiếp. Các tác giả lập luận rằng một mô hình bi-encoder hiệu quả cần phải tích cực tổng hợp thông tin từ toàn bộ chuỗi văn bản qua các lớp của mô hình, có nghĩa là token [CLS] nên đóng vai trò quan trọng hơn, phải tham gia tổng hợp thông tin ở mọi lớp chứ không chỉ lớp cuối cùng. Do đó ta cần điều chỉnh cách token [CLS] tổng hợp thông tin từ đầu đến cuối của mô hình thay vì chỉ lớp cuối cùng để giúp mô hình toàn diện và hiệu quả hơn.

Sau đây là hình minh họa kiến trúc của Condenser, được trích dẫn từ [8]

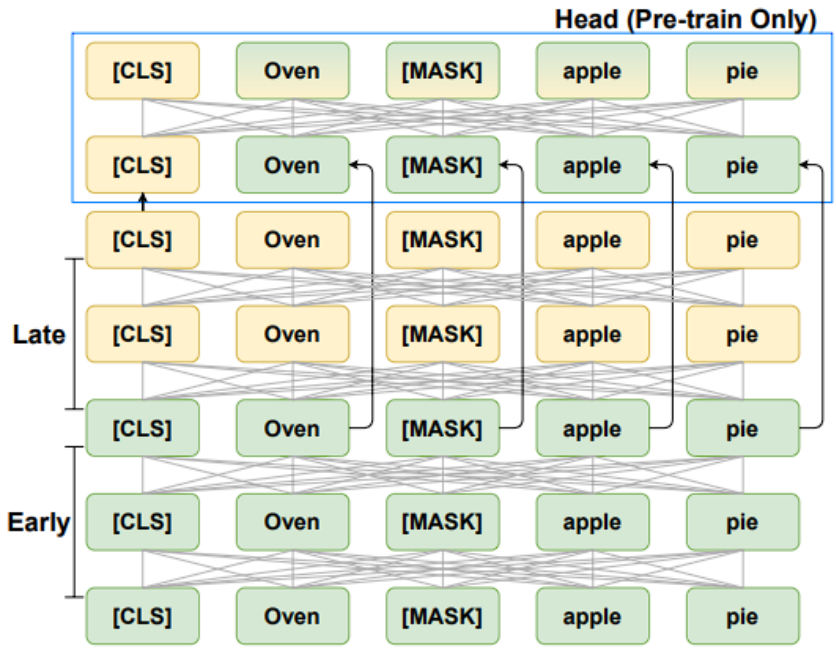

Hình 2.3: Kiến trúc của Condenser Nguồn: [8]

Các lớp của mô hình Condenser được chia thành 3 loại là *early*, *late* và *head* ký hiệu là L^e, L^l và L^h . Trong đó L^e và L^l là các lớp của mô hình backbone BERT và L^h là các lớp *head* của mô hình Condenser.

$$[h_{cls}^{early}, h^{early}] = \text{Encoder}_{early}\left([h_{cls}^{0}; h^{0}]\right) \tag{2.10}$$

$$[h_{cls}^{late}, h^{late}] = \text{Encoder}_{late}\left([h_{cls}^{early}; h^{early}]\right) \tag{2.11}$$

Tác giả thêm một nối tắt từ lớp *early* tới *head* như sau:

$$[h_{cls}^{cd}, h^{cd}] = \text{Encoder}_{head}\left([h_{cls}^{late}, h^{early}]\right) \tag{2.12}$$

Mô hình sẽ được huấn luyện bằng hàm mất mát MLM với đầu ra của lớp *head* như sau (h^{cd} là đầu ra của lớp *head*):

$$\mathcal{L}_{\text{mlm}} = \sum_{i \in \text{masked}} \text{CrossEntropy}(W h_i^{cd}, x_i) \tag{2.13}$$

Token [CLS] *late* buộc phải tổng hợp tất cả các thông tin mới được sinh ra trong lớp *late* để lớp *head* sử dụng cho việc phán đoán tác vụ MLM, vì các thông tin mới chỉ có thể truyền qua h_{cls}^{late} (token [CLS] của lớp *late* cuối cùng)

Trong quá trình tinh chỉnh mô hình, lớp *head* sẽ được lược bỏ (lớp *head* chỉ được dùng trong quá trình tiền huấn luyện) như vậy thì Condenser lúc này trở về

kiến trúc nguyên bản là BERT. Do lớp *head* được khởi tạo ngẫu nhiên và để tránh làm hỏng trọng số của mô hình backbone trong quá trình tinh chỉnh thì Condenser bổ sung thêm một ràng buộc bằng cách thực hiện MLM với cả đầu ra lớp *late*, ma trận chiếu đầu ra W được chia sẻ giữa 2 hàm loss:

$$\mathcal{L}^c_{\text{mlm}} = \sum_{i \in \text{masked}} \text{CrossEntropy}(W h_i^{\text{late}}, x_i) \tag{2.14}$$

Hàm mất mát đẩy đủ sẽ là tổng của 2 hàm mất mát trên:

$$\mathcal{L} = \mathcal{L}_{\text{mlm}} + \mathcal{L}^c_{\text{mlm}} \tag{2.15}$$

Tác giả của Condenser sau đó đã giới thiệu mô hình coCondenser, về kiến trúc thì giống như Condenser nhưng họ bổ sung thêm một mục tiêu học tương phản đơn giản ở mức độ tập văn bản mà không sử dụng câu truy vấn. Cụ thể hơn, tác giả tiền huấn luyện mô hình này bằng cách như sau: Đầu tiên, từ một danh sách ngẫu nhiên các văn bản $[d_1, d_2, ..., d_n]$, ta lấy ngẫu nhiên từ mỗi tài liệu d_i một cặp đoạn văn (s_{i1}, s_{i2}) thu được tập hợp các đoạn văn $[s_{11}, s_{12}, ..., s_{n1}, s_{n2}]$. Tập hợp này sẽ tạo thành một batch huấn luyện cho coCondenser. Ta gọi biểu diễn của token [CLS] của đoạn văn s_{ij} là h_{ij} thì hàm mất mát ở mức độ văn bản sẽ được định nghĩa như sau:

$$\mathcal{L}^{co}_{ij} = -\log \frac{\exp(\langle h_{i1}, h_{i2} \rangle)}{\sum_{k=1}^{n} \sum_{l=1}^{2} \mathbb{I}_{ij \neq kl} \exp(\langle h_{ij}, h_{kl} \rangle)} \tag{2.16}$$

Mục tiêu của hàm mất mát tương phản này là huấn luyện mô hình sao cho các vector nhúng [CLS] của hai đoạn văn từ cùng một văn bản tài liệu thì gần nhau còn các vector nhúng [CLS] của hai đoạn văn từ các tài liệu khác nhau thì xa nhau hơn trong không gian nhúng. Việc tiền huấn luyện này sẽ khiến mô hình học biểu diễn tốt hơn trên toàn bộ tập dữ liệu này. Gọi hàm mất mát MLM của đoạn s_{ij} là $\mathcal{L}^{mlm}_{ij}$ thì hàm mất mát của cả batch sẽ là trung bình của $\mathcal{L}^{mlm}_{ij}$ và $\mathcal{L}^{co}_{ij}$:

$$\mathcal{L} = \frac{1}{2n} \sum_{i=1}^{n} \sum_{j=1}^{2} \left[\mathcal{L}^{mlm}_{ij} + \mathcal{L}^{co}_{ij} \right] \tag{2.17}$$

Và tương tự như Condenser, sau khi kết thúc tiền huấn luyện thì lớp head sẽ được loại bỏ và trở lại thành một mô hình BERT.

Hai mô hình Condenser và coCondenser với những điểm mạnh nêu trên sẽ giúp

tăng cường hiệu quả truy xuất thông tin.

2.7 Mô hình XLM-RoBERTa

XLM-RoBERTa là mô hình đa ngôn ngữ dựa trên BERT, trong đó RoBERTa là một phiên bản cải tiến của mô hình BERT. RoBERTa được thiết kế để cải thiện hiệu suất bằng cách tối ưu một số khía cạnh trong quy trình đào tạo, bao gồm:

Đào tạo lâu hơn, dữ liệu lớn hơn: RoBERTa được đào tạo với khối lượng dữ liệu lớn hơn và trong thời gian dài hơn so với BERT, giúp mô hình học được nhiều hơn từ dữ liệu.

Sử dụng mặt nạ động: Trong quá trình huấn luyện, RoBERTa sử dụng mặt nạ động thay vì mặt nạ tĩnh như BERT, điều này có nghĩa là các vị trí bị che đi (masked) sẽ thay đổi mỗi khi mẫu dữ liệu được đưa qua mô hình, giúp mô hình học tốt hơn.

Loại bỏ mục tiêu dự đoán câu kế tiếp: BERT sử dụng mục tiêu dự đoán câu kế tiếp (Next Sentence Prediction - NSP) như một phần của quá trình huấn luyện, nhưng nghiên cứu đã chỉ ra mục tiêu này không cần thiết để đạt hiệu suất cao nên RoBERTa đã loại bỏ nó.

XLM-RoBERTa thừa hưởng những cải tiến trên từ RoBERTa, ngoài ra được bổ sung khả năng hỗ trợ đa ngôn ngữ, nó được huấn luyện trên bộ dữ liệu 2.5TB bao gồm 100 ngôn ngữ khác nhau, sử dụng các chiến lược như: Sử dụng một từ điển chung cho tất cả các ngôn ngữ, giúp mô hình học được các chia sẻ thông tin giữa các ngôn ngữ, sử dụng mục tiêu huấn luyện mô hình mặt nạ đa ngôn ngữ (Multilingual MLM), ... Nhờ vậy, XLM-RoBERTa đã đạt được hiệu suất cao trên nhiều tác vụ đa ngôn ngữ và được sử dụng làm kiến trúc xương sống cho nhiều các mô hình tiên tiến sau này.

CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT

3.1 Tổng quan giải pháp

Trong phần này em sẽ trình bày về tổng quan giải pháp mà em sẽ sử dụng trong đồ án này.

3.1.1 Sơ đồ hoạt động

Sơ đồ hoạt động của mô-đun truy xuất (Retrieval) mà em sẽ sử dụng trong đồ án này, bao gồm hai thành phần chính đó là bộ truy xuất (Retriever) với tác dụng truy xuất ra các candidates và bộ xếp hạng lại (Reranker) có tác dụng xếp hạng lại các candidates và đưa ra kết quả sau cùng.

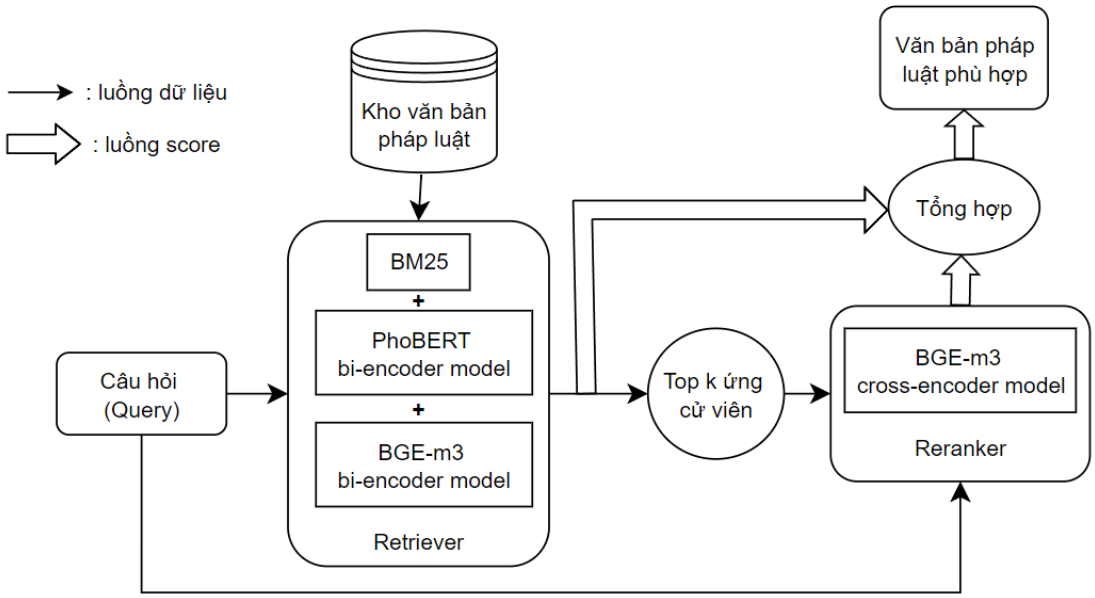

Hình 3.1: Sơ đồ hoạt động của mô-đun Retrieval

Về các mô hình tiền huấn luyện mà em sử dụng, gồm PhoBERT-base v2 [16] và BGE-m3.

Cụ thể hơn, Retriever sẽ là ensemble của 3 mô hình BM25, PhoBERT bi-encoder và BGE-m3 với ý nghĩa như sau, BM25 có lợi thế về so khớp từ vựng giúp tăng hiệu quả xếp hạng, PhoBERT bi-encoder với khả năng hiểu ngôn ngữ tiếng Việt, BGE-m3 với khả năng nhúng văn bản đa ngôn ngữ mạnh mẽ.

Ban đầu, sau khi người dùng đưa ra câu hỏi thì câu hỏi sẽ được tiền xử lý, chia thành các token sau đó được đưa vào Retriever để tính toán độ tương đồng với các văn bản trong kho dữ liệu văn bản pháp luật, từ đó lấy ra được k văn bản phù hợp nhất (top k candidates). Top k candidates sẽ được đưa vào Reranker cùng với câu

hỏi ban đầu của người dùng để tính toán lại độ tương đồng với độ chính xác cao hơn. Hai quá trình này kết hợp với nhau để bù trừ các ưu nhược điểm của nhau, retriever thì dựa trên bi-encoder nên có thể tính toán các vector mã hóa của các văn bản pháp luật từ trước để lưu vào cơ sở dữ liệu, khi đó ta chỉ cần tính toán vector mã hóa của câu truy vấn rồi tính toán độ tương đồng với tốc độ rất nhanh. Reranker do phải tính toán từng cặp câu truy vấn và văn bản nên ta sẽ chỉ lấy top k văn bản để tiết kiệm chi phí thời gian nhưng vẫn đạt được độ chính xác cao.

Điểm số về độ tương đồng sau cùng của cặp câu truy vấn và văn bản pháp luật sẽ được tính như sau:

$$\text{score}_{retriever} = (\text{score}_{PhoBERT} + \text{score}_{BGE-m3}) \times \text{score}_{BM25}$$

$$\text{score}_{reranker} = \text{score}_{BGE-reranker}$$

$$\text{score}_{final} = \text{score}_{retriever} + \text{score}_{reranker}$$

3.1.2 Mô hình PhoBERT-base v2

PhoBERT là một mô hình ngôn ngữ được tiền huấn luyện dành riêng cho tiếng Việt, phát triển dựa trên BERT và RoBERTa (một biến thể của mô hình BERT) được phát triển bởi VinAI Research . Đây là một trong những nỗ lực đầu tiên nhằm xây dựng một mô hình ngôn ngữ mạnh mẽ cho tiếng Việt, cung cấp các biểu diễn ngữ nghĩa chất lượng cao cho các tác vụ xử lý ngôn ngữ tự nhiên (NLP) như phân loại văn bản, nhận diện thực thể (NER), và phân tích cảm xúc.

Về dữ liệu sử dụng cho quá trình tiền huấn luyện, tác giả sử dụng 20GB dữ liệu văn bản tiếng Việt, sử dụng từ điển gồm 64000 từ cho quá trình tách từ (tokenize). Có hai phiên bản chính của PhoBERT là PhoBERT-base và PhoBERT-large với số tham số lần lượt là 135 triệu và 370 triệu tham số. Cho đến bây giờ thì PhoBERT vẫn là một trong những mô hình NLP tốt nhất cho ngôn ngữ tiếng Việt.

PhoBERT-base v2 là một mô hình cải tiến của PhoBERT-base khi được bổ sung 120GB dữ liệu văn bản cho việc huấn luyện. Mô hình PhoBERT-base v2 với 135 triệu tham số có khả năng xử lý đầu vào tối đa là 256 tokens. Trong đồ án này em sẽ sử dụng PhoBERT-base v2 như mô hình xương sống cho các mô hình khác.

3.1.3 Mô hình BGE-m3 Embedding

Mô hình BGE-m3 Embedding là một mô hình nhúng mới được giới thiệu vào đầu năm 2024 bởi Chen, Xiao và các cộng sự [12], đây là một mô hình nhúng văn bản đang được coi là SOTA (State Of The Art) trong lĩnh vực nhúng văn bản khi đạt được kết quả vô cùng ấn tượng trên nhiều tập dữ liệu. BGE-m3 là một mô hình đa dụng với các khả năng về đa ngôn ngữ (Multi-Linguality), đa chức năng (Multi-Functionality) và đa dạng mức độ chi tiết (Multi-Granularity). BGE-m3 được tiền

huấn luyện trên bộ dữ liệu đa ngôn ngữ khổng lồ trong đó có tiếng Việt, được phát triển bởi BAAI. Mô hình BGE-m3 gồm khoảng 568 triệu tham số có khả năng xử lý đầu vào tối đa lên tới 8192 tokens. Cho đến nay, BGE-m3 là một trong những mô hình mạnh mẽ nhất trong tác vụ nhúng văn bản.

Về khả năng đa ngôn ngữ, BGE-m3 hỗ trợ hơn 100 ngôn ngữ khác nhau và đạt được hiệu suất hàng đầu trong các nhiệm vụ truy xuất đa ngôn ngữ và liên ngôn ngữ. Đây là một bước tiến lớn trong việc xây dựng các hệ thống truy xuất thông tin có khả năng hoạt động trong môi trường đa dạng ngôn ngữ.

Về khả năng đa chức năng, BGE-m3 có thể thực hiện đồng thời ba chức năng truy xuất phổ biến: truy xuất dày đặc (dense retrieval), truy xuất đa vector (multi-vector retrieval) và truy xuất thưa (sparse retrieval), cho phép nó xử lý nhiều loại tác vụ khác nhau chỉ với một mô hình duy nhất.

Đa dạng về mức độ chi tiết tức là BGE-m3 có khả năng xử lý các đầu vào từ những câu ngắn tới những tài liệu dài lên tới 8192 tokens. Khả năng này cho phép mô hình linh hoạt ứng dụng cho nhiều bối cảnh khác nhau.

Sau đây em sẽ trích dẫn khái niệm của các hàm truy xuất từ bài báo của BGE-m3 [12]

Các hàm truy xuất

Truy xuất dày đặc: Truy vấn q được nhúng qua bộ mã hóa trở thành trạng thái ẩn $\mathbf{H}_q$. Sau đó ta chuẩn hóa vector nhúng của token [CLS]: $e_q = \text{norm}(\mathbf{H}_q[0])$ để làm biểu diễn cho câu truy vấn. Tương tự biểu diễn của đoạn văn p sẽ là $e_p = \text{norm}(\mathbf{H}_p[0])$ và điểm số thể hiện độ tương đồng giữa truy vấn và đoạn văn sẽ là tích vô hướng của e_p và e_q: $s_{\text{dense}} \leftarrow \langle e_p, e_q \rangle$.

Truy xuất thưa: Các vector nhúng đầu ra cũng được sử dụng để ước lượng độ quan trọng của từng từ vựng tạo điều kiện cho việc truy xuất thưa. Với mỗi token t trong câu truy vấn, trọng số của nó được tính bằng: $w_{q_t} \leftarrow \text{ReLU}(\mathbf{W}_{\text{lex}}^T \mathbf{H}_q[i])$, trong đó $\mathbf{W}_{\text{lex}} \in \mathbb{R}^{d \times 1}$ là ma trận chiếu giúp ánh xạ trạng thái ẩn sang dạng số thực. Nếu token t xuất hiện nhiều lần trong câu truy vấn thì ta chỉ lấy trọng số lớn nhất. Sử dụng cách tương tự ta cũng tính được trọng số của mỗi token trong đoạn văn và từ đó ta tính được điểm số thể hiện độ tương đồng giữa câu truy vấn và đoạn văn: $s_{\text{lex}} \leftarrow \sum_{t \in q \cap p} (w_{q_t} \cdot w_{p_t})$, trong đó $q \cap p$ là tập các token có trong cả câu truy vấn và đoạn văn.

Truy xuất đa vector: Là mở rộng của truy xuất dày đặc, phương pháp này sử dụng toàn bộ các nhúng đầu ra để biểu diễn cho câu truy vấn và đoạn văn (thay vì chỉ dùng nhúng đầu ra của [CLS]): $E_q = \text{norm}(\mathbf{W}_{\text{mul}}^T \mathbf{H}_q)$, $E_p = \text{norm}(\mathbf{W}_{\text{mul}}^T \mathbf{H}_p)$,

trong đó $\mathbf{W}_{\text{mul}} \in \mathbb{R}^{d \times d}$ là ma trận chiếu. Theo như ColBert [17], ta sẽ tính toán độ tương đồng như sau: $s_{\text{mul}} \leftarrow \frac{1}{N} \sum_{i=1}^{N} \max_{j=1}^{M} E_q[i] \cdot E_p^T[j]$, N và M là độ dài của truy vấn và đoạn văn.

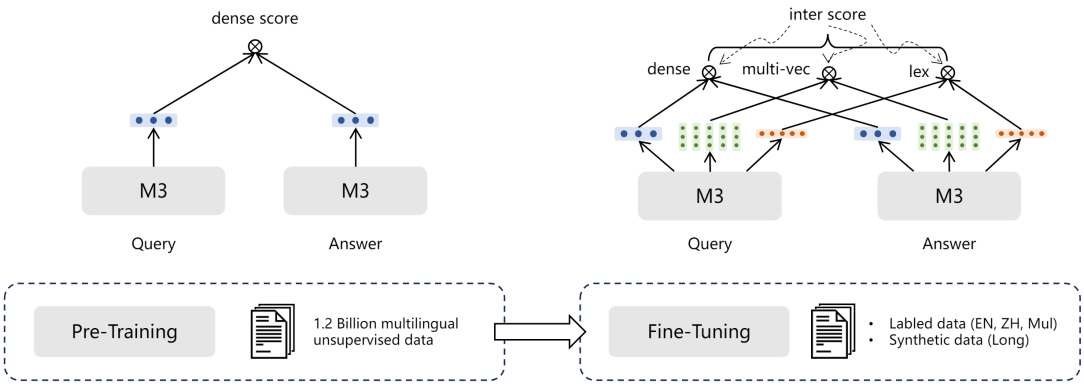

Hình 3.2: Quá trình huấn luyện nhiều giai đoạn của BGE-m3 embedding với phương pháp tự chắt lọc kiến thức. Nguồn: [12]

Hình 3.2 được trích dẫn từ [12] mô tả quá trình huấn luyện nhiều giai đoạn của mô hình BGE-m3, tác giả dùng mô hình XLM-RoBERTa đã được tiền huấn luyện để làm bộ mã hóa văn bản cơ bản. Đầu tiên, bộ mã hóa văn bản này được tiền huấn luyện trên một lượng rất lớn dữ liệu không giám sát - 1.2 tỷ cặp câu từ 194 ngôn ngữ và 2655 cặp liên ngôn ngữ, quá trình này chỉ sử dụng truy xuất dày đặc (dense retrieval) và được huấn luyện bằng dạng cơ bản của học biểu diễn tương phản. Phương pháp tự chắt lọc kiến thức được sử dụng ở giai đoạn 2 nhằm tinh chỉnh mô hình nhúng để thiết lập 3 chức năng truy xuất. Dữ liệu huấn luyện ở giai đoạn 2 bao gồm cả dữ liệu có nhãn và dữ liệu tổng hợp (synthetic data).

Cũng như các mô hình nhúng khác, BGE-m3 được huấn luyện với mục đích học được một không gian nhúng mà trong đó các cặp mẫu dương gần nhau (độ tương đồng, score cao) hơn so với các cặp mẫu âm. Giả sử với truy vấn q có mẫu dương là p^* và các mẫu âm P', $s(\cdot)$ là một hàm bất kỳ trong số 3 hàm truy xuất đã được đề cập $\{s_{\text{dense}}(\cdot), s_{\text{lex}}(\cdot), s_{\text{mul}}(\cdot)\}$, thì quá trình huấn luyện sẽ được thực hiện để tối ưu hóa hàm mất mát như sau:

$$\mathcal{L} = -\log \frac{\exp(s(q, p^*)/\tau)}{\sum_{p \in \{p^*, P'\}} \exp(s(q, p)/\tau)} \tag{3.1}$$

Các tác giả cho rằng mục tiêu huấn luyện của các hàm truy xuất khác nhau có thể bị xung đột với nhau gây ảnh hưởng đến hiệu quả của toàn mô hình nhúng. Để khắc phục điều này thì họ đã đề xuất phương pháp tự chắt lọc kiến thức, dựa trên nguyên lý là nếu kết hợp dự đoán từ các hàm truy xuất khác nhau thì sẽ được một

kết quả chính xác hơn, và sử dụng kết quả kết hợp đó để hướng dẫn cho việc huấn luyện mô hình (teacher). Ở đây s_{inter} đóng vai trò như một chuẩn mực để mô hình cố gắng học theo, còn hàm loss $\mathcal{L}_*$' sẽ đo lường mức độ mà các xác suất dự đoán của mô hình (dựa trên s_*) khớp với xác suất mong muốn (dựa trên s_{inter}):

$$s_{\text{inter}} \leftarrow s_{\text{dense}} + s_{\text{lex}} + s_{\text{mul}}. \tag{3.2}$$

$$\mathcal{L}'_* \leftarrow -p(s_{\text{inter}}) * \log p(s_*). \tag{3.3}$$

$$\mathcal{L}' \leftarrow \frac{\mathcal{L}'_{\text{dense}} + \mathcal{L}'_{\text{lex}} + \mathcal{L}'_{\text{mul}}}{3}. \tag{3.4}$$

Trong đó $p(.)$ là hàm softmax, s_* là một trong s_{dense}, s_{mul}, s_{lex}.

Và hàm mất mát cuối cùng cho quá trình tự chắt lọc kiến thức là tổng của hai hàm:

$$\mathcal{L}_{\text{final}} \leftarrow \mathcal{L} + \mathcal{L}'. \tag{3.5}$$

Trong phạm vi đồ án này, do giới hạn về phần cứng huấn luyện em chỉ sử dụng mô hình BGE-m3 với hàm truy xuất dày đặc chứ chưa tận dụng được kết hợp 3 hàm truy xuất cũng như sử dụng phương pháp tự chắt lọc kiến thức. Nhưng khả năng của các phương pháp này sẽ mở ra những thành tựu mới trong truy xuất thông tin về pháp luật Việt Nam.

3.2 Tiền xử lý dữ liệu

Để tạo ra bộ dữ liệu tiền huấn luyện cho mô hình coCondenser, em sử dụng phương pháp tương tự trong paper của tác giả là mỗi văn bản pháp luật sẽ lấy 2 đoạn văn không trùng nhau với tổng độ dài không quá 128 tokens, những đoạn văn cùng 1 văn bản pháp luật sẽ là mẫu dương còn khác văn bản thì sẽ là mẫu âm. Điều này sẽ giúp cho mô hình coCondenser có thêm tri thức về miền dữ liệu văn bản pháp luật tiếng Việt, giúp tăng độ chính xác trong việc mã hóa văn bản.

Ngoài ra, em bổ sung thêm phương pháp chunking bằng cách chia các văn bản pháp luật thành các chunks có cùng độ dài để có thể xét đầy đủ, không bỏ sót thông tin quan trọng trong các văn bản trong quá trình truy xuất thông tin. Giả sử văn bản có độ dài hơn 1000 tokens nhưng phần liên quan nhất đến câu truy vấn lại nằm ở đoạn sau và bị mô hình cắt bỏ đi, như thế thì hệ thống sẽ bỏ lỡ và đưa ra những văn bản trả lời không chính xác.

3.3 Huấn luyện Retriever

Retriever được xây dựng từ các mô hình BM25, PhoBERT bi-encoder model, BGE-m3 bi-encoder model. Luồng huấn luyện được thể hiện qua sơ đồ 3.3.

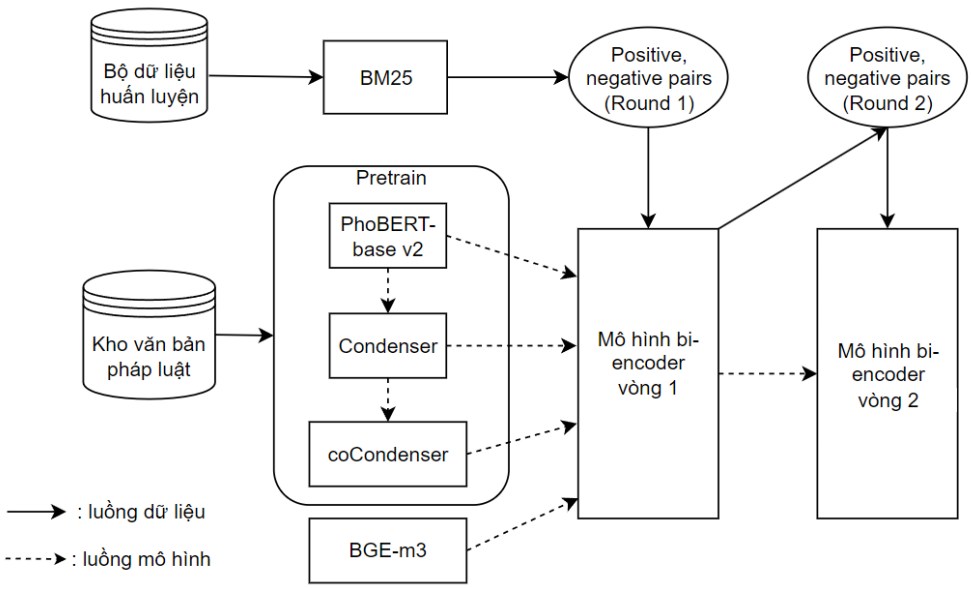

Hình 3.3: Luồng hoạt động của quá trình tiền huấn luyện, tinh chỉnh các mô hình của Retriever.

3.3.1 Huấn luyện mô hình BM25

Mô hình BM25 là mô hình xác suất chỉ dựa trên thống kê các từ vựng nên không cần sử dụng bộ dữ liệu câu hỏi, điều khoản trả lời mà chỉ cần huấn luyện trên bộ dữ liệu văn bản pháp luật. Dữ liệu text sẽ được tiền xử lý bằng cách loại bỏ dấu câu, đưa về chữ in thường, loại bỏ stopword (bao gồm chữ số, một số chữ cái, từ đơn) sau đó được chuyển về dạng token và được huấn luyện. Em đã thử nghiệm thay đổi các siêu tham số k_1, b để có được kết quả tốt nhất.

3.3.2 Tiền huấn luyện bi-encoder

Mặc dù mô hình PhoBERT-base v2 đã là một mô hình ngôn ngữ mạnh mẽ với sự "am hiểu" về ngôn ngữ tiếng Việt nhưng có rất nhiều lĩnh vực ngôn ngữ như trong y tế, giáo dục, khoa học,... Mỗi lĩnh vực lại có những thuật ngữ, cách dùng từ riêng nên rất khó để một mô hình có thể xử lý tốt tất cả, đặc biệt là trong miền dữ liệu về pháp luật, nơi mà từng từ ngữ sẽ ảnh hưởng rất lớn đến ý nghĩa cũng như ngữ cảnh của văn bản. Do đó em sẽ tiền huấn luyện PhoBERT-base v2 trên tập dữ liệu văn bản pháp luật bằng cách sử dụng mô hình ngôn ngữ mặt nạ Masked Language Model - MLM. Sau đó em sử dụng mô hình vừa được huấn luyện để làm mô hình xương sống cho mô hình Condenser. Em tiếp tục huấn luyện mô hình Condenser bằng MLM như trên để mô hình học được cách biểu diễn token [CLS] tốt hơn, giúp vector biểu diễn của token [CLS] mang đầy đủ ngữ nghĩa của toàn bộ câu. Mô hình coCondenser là mô hình Condenser sau khi được huấn luyện và sẽ được huấn luyện tiếp bằng phương pháp học biểu diễn tương phản với bộ dữ liệu

được lựa chọn như 3.2.

Với mô hình BGE-m3, do giới hạn phần cứng huấn luyện nên em không thực hiện tiền huấn luyện trên tập dữ liệu văn bản pháp luật nhưng với mô hình rất mạnh như BGE-m3 thì kết quả sẽ không bị giảm sút quá nhiều.

Qua đó, em thu được các mô hình với khả năng mã hóa tốt hơn cho ngôn ngữ tiếng Việt đặc biệt là trong lĩnh vực pháp luật và sẽ là tiền đề để em tinh chỉnh cho tác vụ truy xuất thông tin phía sau đây.

3.3.3 Tinh chỉnh bi-encoder

Em lựa chọn phương pháp học biểu diễn tương phản để tinh chỉnh các mô hình bi-encoder và sẽ cần các cặp mẫu dương, mẫu âm để huấn luyện. Do đó, em sử dụng mô hình xếp hạng BM25 đã được huấn luyện để thu được các mẫu dương, mẫu âm khó (Mẫu âm khó là các văn bản tuy không phải câu trả lời cho câu truy vấn nhưng lại có điểm số tương đồng cao với câu truy vấn, mẫu dương là văn bản thuộc phần câu trả lời của câu truy vấn). Trong đồ án này, em lựa chọn lấy 50 văn bản có độ tương đồng cao nhất với câu truy vấn để thu được các mẫu dương, mẫu âm khó. Và trong toàn bộ đồ án, khi khai thác mẫu âm khó của mô hình thì em luôn sử dụng con số 50 này để có được sự đồng nhất.

Sau khi sử dụng BM25, em thu được hơn 120000 cặp gồm câu truy vấn, văn bản pháp luật và nhãn, trong đó nhãn nhận giá trị 1 nếu là mẫu dương và nhận giá trị 0 trong trường hợp ngược lại. Em chia tập huấn luyện và kiểm thử theo tỉ lệ 80-20 và thực hiện các mô hình đã tiền huấn luyện ở phần trước và thu được các mô hình vòng 1. Sở dĩ gọi là vòng 1 là vì em nhận thấy có thể tiếp tục tinh chỉnh các mô hình này bằng cách khai thác các mẫu âm khó của từng mô hình và dùng dữ liệu vừa thu được để huấn luyện cho chính mô hình đó. Do dữ liệu để tinh chỉnh là các mẫu âm khó của mô hình BM25 nên hoàn toàn có thể sử dụng phương pháp tương tự với các mô hình vòng 1 để thu được các mô hình vòng 2 với độ chính xác cao hơn.

Em đã thử làm tương tự để đào tạo các mô hình vòng 3 nhưng kết quả cải thiện không đáng kể nên quyết định dừng lại ở vòng 2.

3.4 Huấn luyện Reranker

Mô hình em sử dụng trong reranker là BGE-reranker-v2-m3, đây là mô hình cross-encoder BGE-m3 nhưng đã được tiền huấn luyện cho đa ngôn ngữ có cả tiếng Việt nên em sẽ tinh chỉnh từ bộ tham số của mô hình này, em thực hiện khai thác các mẫu âm khó của mô hình BGE-m3 bi-encoder vòng 2 để làm dữ liệu huấn luyện cho cross-encoder. Đầu vào của mô hình BGE-m3 cross-encoder là câu truy

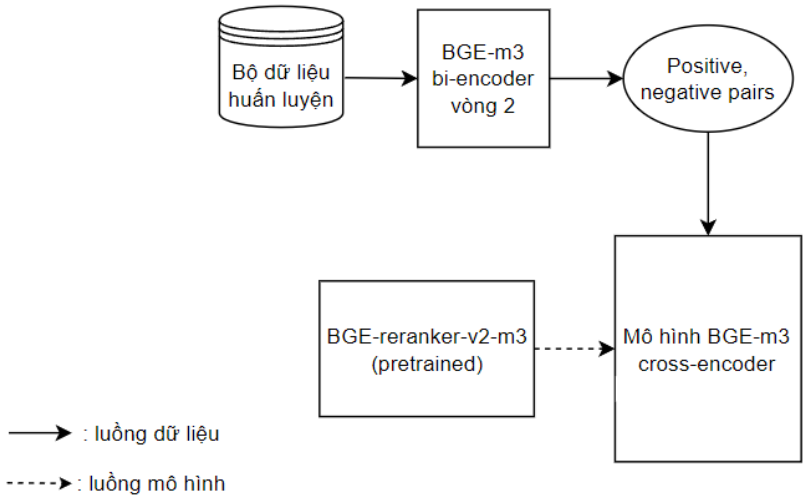

Hình 3.4: Luồng hoạt động của quá trình tinh chỉnh mô hình Reranker

vấn và văn bản pháp luật được phân cách nhau bởi token [SEP] và đầu ra của mô hình là 1 số thực thuộc đoạn [0,1] thể hiện mức độ liên quan của câu truy vấn và văn bản pháp luật. Em cũng thử huấn luyện vòng 2 cho BGE-m3 cross-encoder nhưng kết quả cũng không cải thiện quá nhiều nên sẽ sử dụng mô hình vòng 1 để kết hợp vào mô-đun retrieval sau cùng.

CHƯƠNG 4. ĐÁNH GIÁ THỰC NGHIỆM

Trong chương này, em sẽ trình bày về dữ liệu sử dụng, các thiết lập thí nghiệm, các kết quả thực nghiệm để chứng minh tính hiệu quả của các mô hình đề xuất.

4.1 Dữ liệu sử dụng

4.1.1 Tổng quan về dữ liệu

Em sử dụng dữ liệu công khai từ cuộc thi Legal Text Retrieval (Truy xuất văn bản pháp luật) của Zalo AI Challenge 2021, gồm 2 phần chính đó là:

(i) Kho dữ liệu văn bản pháp luật gồm các điều luật trong hệ thống pháp luật Việt Nam.

(ii) Các bộ câu hỏi về pháp luật kèm theo điều luật, điều khoản để trả lời cho câu hỏi đó.

Cụ thể hơn, kho dữ liệu văn bản pháp luật gồm có 61425 điều luật, được sử dụng để trả lời cho câu hỏi về pháp luật. Bộ câu hỏi, đáp án thì gồm có 3196 cặp câu hỏi và đáp án, trong đó em sử dụng 80% cho việc huấn luyện mô hình và 20% còn lại cho việc kiểm thử, đánh giá mô hình tức là 2556 cặp cho việc huấn luyện và 640 cặp cho việc kiểm thử. Ngoài ra còn có 511 câu hỏi chưa có câu trả lời của ban tổ chức.

4.1.2 Thống kê về dữ liệu

Sau khi thực hiện tách từ (tokenize) các điều luật trong kho văn bản pháp luật cũng như các câu truy vấn, em thực hiện thống kê độ dài của chúng để xem xét cách xử lý dữ liệu cũng như chọn mô hình phù hợp.

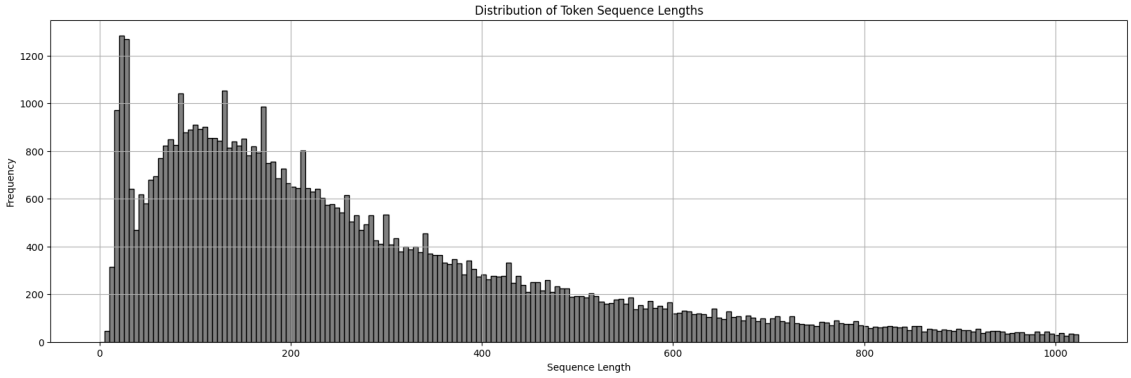

Hình 4.1: Biểu đồ phân bố theo độ dài token của các văn bản pháp luật

Ở đây em chỉ hiển thị phần có độ dài nhỏ hơn 1024 tokens vì phần còn lại chiếm số lượng khá nhỏ so với toàn bộ. Qua thống kê ta có thể thấy độ dài trung bình của các văn bản pháp luật là khoảng 335 tokens, tức là lớn hơn khá nhiều so với độ dài

tối đa của đầu vào mô hình PhoBERT, do đó em bổ sung cách tiếp cận phân đoạn dữ liệu (chunking) để so sánh và tìm ra cách xử lý tốt nhất cho bài toán.

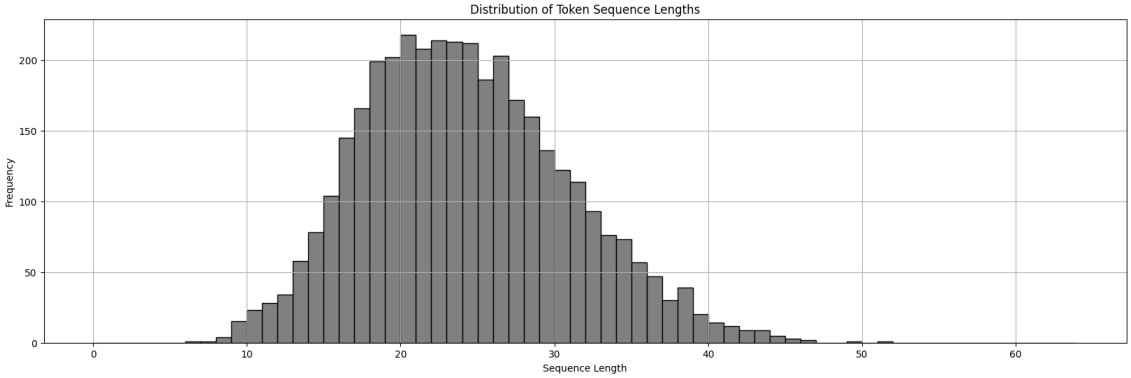

Hình 4.2: Biểu đồ phân bố theo độ dài token của các câu truy vấn

Tương tự, biểu đồ này thể hiện độ dài của các câu truy vấn thường không dài quá 50 tokens, trung bình khoảng 24 tokens. Vì vậy không ảnh hưởng tới việc lựa chọn mô hình cũng như cách tiền xử lý dữ liệu.

4.2 Tham số đánh giá

Trong đồ án lần này, em ưu tiên cải thiện độ chính xác của hệ thống truy xuất thông tin về pháp luật nên sẽ sử dụng thang đo độ chính xác là Acc@1, Acc@10, Acc@100, tức là nếu văn bản có score cao nhất là đáp án đúng của truy vấn thì Acc@1 sẽ tính là đúng, còn với Acc@10 thì chỉ cần ít nhất 1 trong 10 văn bản có score cao nhất thì sẽ tính là đúng, Acc@100 tương tự như vậy. Cách tính sẽ là số truy vấn trả lời đúng chia cho tổng số truy vấn (ở đây tập kiểm thử của em có tổng cộng 640 truy vấn).

4.3 Đường cơ sở

Đường cơ sở (baseline) mà em chọn cho bài toán hỏi đáp về pháp luật là mô hình bkai-foundation-models/vietnamese-bi-encoder trên cộng đồng mã nguồn mở Hugging Face. Đây là mô hình truy xuất ngôn ngữ tiếng Việt dựa trên kiến trúc bi-encoder sử dụng PhoBERT-base v2 và được huấn luyện sử dụng một số bộ dữ liệu được dịch sang tiếng Việt và 80% tập dữ liệu huấn luyện từ cuộc thi Legal Text Retrieval của Zalo AI Challenge 2021 (cũng chính là bộ dữ liệu em sử dụng trong đồ án này). Em chọn mô hình này trở thành đường cơ sở vì đây là mô hình được huấn luyện trên tập dữ liệu mà em sử dụng, và là một trong những mô hình được sử dụng phổ biến trong tác vụ truy xuất thông tin tiếng Việt.

4.4 Thiết lập thí nghiệm

Ban đầu, em thực hiện huấn luyện mô hình BM25 trên toàn bộ tập dữ liệu văn bản pháp luật và thay đổi siêu tham số k_1 và b để chọn ra mô hình tốt nhất.

Trong các mô hình học sâu, em sử dụng độ chính xác tính toán là float16 để giúp tăng tốc độ tính toán cũng như giảm bộ nhớ. Tiền huấn luyện với MLM được thiết lập với tỉ lệ che (masked) là 15%.

Mô hình PhoBERT-base v2 được tiền huấn luyện bằng MLM trong 20 epochs, kích thước batch là 64. Mô hình Condenser và coCondenser được tiền huấn luyện trong 5 epoch với kích thước batch là 32. Mô hình BGE-m3 không áp dụng tiền huấn luyện.

Em tinh chỉnh các mô hình bi-encoder vòng 1 trong 10 epochs và vòng 2 trong 5 epoch, kích thước batch là 64 cho các mô hình PhoBERT và kích thước batch là 2 cho mô hình BGE-m3. Mô hình BGE-m3 cross-encoder được tinh chỉnh trong 20 epoch với kích thước batch là 2.

Với các mô hình bi-encoder, em sẽ lưu lại dữ liệu về vector mã hóa của tập văn bản pháp luật để có thể tái sử dụng trong việc thử nghiệm nhiều lần.

4.5 Kết quả thí nghiệm

4.5.1 Thí nghiệm tinh chỉnh mô hình BM25

Đầu tiên, em sẽ thực hiện thử nghiệm thay đổi siêu tham số k_1 và b của mô hình BM25 để tìm ra bộ siêu tham số phù hợp. Các siêu tham số này đóng vai trò quan trọng trong việc điều chỉnh trọng số của các từ trong tài liệu, từ đó ảnh hưởng trực tiếp đến hiệu quả của mô hình truy vấn.

k_1	b	Acc@1	Acc@10	Acc@100
1.5	0.7	46.25	82.66	95.31
2.5	0.7	44.06	79.53	95.16
0.3	0.7	**50.16**	82.5	**95.63**
0.3	1.5	44.06	79.66	95.47
0.4	0.6	49.22	82.81	95.47
0.5	0.5	47.97	**82.88**	95.31

Bảng 4.1: Độ chính xác (%) của mô hình BM25 khi tinh chỉnh siêu tham số k_1 và b

Dựa trên bảng 4.1, ta có thể thấy rằng việc thay đổi các giá trị của các siêu tham số k_1 và b ảnh hưởng đáng kể đến độ chính xác của mô hình. Sau khi thử nghiệm thì em quyết định chọn k_1=0.3, b=0.7 cho tất cả các thí nghiệm sau vì đã đạt được độ chính xác ổn đối với một mô hình chỉ đơn thuần dựa trên thống kê như BM25. Việc lựa chọn các siêu tham số này không chỉ giúp cải thiện độ chính xác mà còn cho phép mô hình hoạt động hiệu quả hơn trong việc tìm kiếm và xếp hạng các tài liệu liên quan, ngoài ra còn cung cấp một nền tảng vững chắc cho các bước tiếp như tạo dữ liệu huấn luyện cho các mô hình bi-encoder vòng 1, đóng góp một phần

quan trọng vào toàn bộ mô-đun retrieval.

4.5.2 Thí nghiệm so sánh các hàm mất mát

Để huấn luyện cho các mô hình bi-encoder, em sử dụng các hàm mất mát Contrastive Loss (CL) và Online Contrastive Loss (OCL).

Mô hình	Acc@1	Acc@10	Acc@100
PhoBERT-base v2 ContrastiveLoss	58.29	83.56	94.53
PhoBERT-base v2 OnlineContrastiveLoss	**58.75**	**84.84**	**94.84**

Bảng 4.2: Độ chính xác (%) của mô hình PhoBERT-base v2 vòng 1 với các hàm loss

Qua bảng so sánh 4.2 có thể thấy OCL có kết quả nhỉnh hơn CL điều đó là do Contrastive Loss tập trung vào việc học khoảng cách giữa các cặp dữ liệu, đảm bảo rằng các điểm dữ liệu tương tự được ánh xạ gần nhau, trong khi các điểm khác nhau được ánh xạ xa nhau và hàm mất mát này được tính toán trên toàn bộ cặp dữ liệu trong một batch. Ngược lại, Online Contrastive Loss là một biến thể được thiết kế để tăng hiệu quả tính toán bằng cách chỉ xem xét một số cặp dữ liệu được chọn lọc thông minh, thay vì tất cả các cặp có thể có, điều này giúp giảm số lượng cặp cần xử lý, tiết kiệm tài nguyên tính toán và tăng tốc độ huấn luyện. Do đó em đã chọn OCL để huấn luyện các mô hình về sau.

4.5.3 Thí nghiệm so sánh các mô hình bi-encoder

Trong thí nghiệm này, em thực hiện so sánh 4 mô hình PhoBERT-base v2, Condenser, coCondenser, BGE-m3 dense retrieval qua các vòng: chưa tinh chỉnh, tinh chỉnh vòng 1, tinh chỉnh vòng 2 để thấy được độ chính xác của các mô hình so với nhau cũng như từng mô hình so với chính nó ở các vòng trước.

Mô hình	Round	Acc@1	Acc@10	Acc@100
PhoBERT-base v2	0	21.4	50.16	74.38
Condenser		27.5	60.94	81.41
coCondenser		38.75	70.94	90.94
BGE-m3 dense retrieval		57.19	89.21	98.28
PhoBERT-base v2	1	58.75	84.84	94.84
Condenser		58.59	85.63	95.31
coCondenser		61.94	85.63	95.94
BGE-m3 dense retrieval		74.69	93.75	**99.22**
PhoBERT-base v2	2	61.25	88.59	96.25
Condenser		64.53	89.53	97.5
coCondenser		66.86	89.53	97.81
BGE-m3 dense retrieval		**75.78**	**94.22**	**99.22**

Bảng 4.3: Độ chính xác (%) của các mô hình bi-encoder chưa tinh chỉnh, tinh chỉnh vòng 1 và tinh chỉnh vòng 2

Qua bảng kết quả 4.3, ta có thể thấy việc tiền huấn luyện các mô hình Condenser, coCondenser thực sự mang lại hiệu quả vì đã tăng được độ chính xác so với mô hình PhoBERT-base v2, đặc biệt là coCondenser khi kết quả vượt qua 2 mô hình dựa trên PhoBERT chứng tỏ được rằng việc học biểu diễn tương phản ở mức độ tập văn bản thực sự mang lại hiệu quả tốt trong việc cải thiện mô hình. Ngoài ra, mô hình BGE-m3 dense retrieval tuy không được tiền huấn luyện nhưng lại đạt kết quả vượt trội so với 3 mô hình còn lại, điều đó càng chứng tỏ rằng BGE-m3 có khả năng nhúng văn bản tiếng Việt vô cùng mạnh mẽ.

Khi so sánh kết quả của các mô hình với chính nó ở các vòng trước có thể thấy rằng nhờ tinh chỉnh trên bộ dữ liệu các mẫu âm khó và sử dụng phương pháp học tương phản mà các mô hình đã tăng độ chính xác một cách rõ rệt từ chưa tinh chỉnh đến vòng 1, từ vòng 1 đến vòng 2. Việc tinh chỉnh vòng 1 giúp tăng độ chính xác của mô hình đơn giản là vì mô hình được học từ các cặp câu truy vấn, văn bản pháp luật giúp cho mô hình trở nên tốt hơn trong tác vụ truy xuất này. Còn việc tinh chỉnh vòng 2 giúp cải thiện mô hình là do dữ liệu huấn luyện ở vòng 1 (các cặp mẫu dương, âm) được sinh ra bởi mô hình BM25 chỉ thuần về thống kê, còn dữ liệu huấn luyện ở vòng 2 được sinh ra bởi mô hình vòng 1 nên mô hình vòng 2 sẽ học được cách phân biệt các cặp câu khó giúp tăng độ chính xác hơn.

Sở dĩ em lựa chọn dense retrieval thay vì sử dụng unified retrieval cho BGE-m3 vì cấu hình phần cứng không cho phép huấn luyện mô hình unified tốt hơn so với chỉ dùng 1 hàm dense. Cụ thể là ở siêu tham số kích thước nhóm huấn luyện (train group size), mô hình dense retrieval có thể huấn luyện với kích thước nhóm huấn luyện là 4 còn mô hình unified retrieval thì chỉ là 3 và kết quả của dense tốt hơn so với unified lần lượt ở 3 độ đo là 2.5%, 1.07%, 1.25% theo bảng 4.4, nên em quyết định sử dụng BGE-m3 dense retrieval trong đồ án này và gọi tắt là BGE-m3.

Mô hình	train_group_size	Acc@1	Acc@10	Acc@100
BGE-m3 dense retrieval	2	70.63	93.91	98.59
BGE-m3 dense retrieval	4	**74.69**	**93.57**	**99.22**
BGE-m3 unified retrieval	3	72.19	92.5	97.97

Bảng 4.4: Độ chính xác (%) của các mô hình BGE-m3 vòng 1

4.5.4 Thí nghiệm bổ sung BM25

Em sẽ thử nghiệm kết hợp điểm số của mô hình BM25 và mô hình bi-encoder vòng 2 nhằm mục đích tăng độ chính xác của mô hình với khả năng so khớp ngữ pháp tốt của BM25. Cách em thí nghiệm đó là điểm của một truy vấn với một tài liệu sẽ bằng tích điểm số của mô hình bi-encoder vòng 2 và mô hình BM25.

Dựa vào kết quả từ bảng 4.3 và 4.5 có thể thấy việc bổ sung mô hình BM25

Mô hình	Acc@1	Acc@10	Acc@100
PhoBERT-base v2 + BM25	71.09	93.75	98.91
Condenser + BM25	72.97	94.22	98.59
coCondenser + BM25	73.91	93.75	98.75
BGE-m3 + BM25	**77.5**	**95**	**99.22**

Bảng 4.5: Độ chính xác (%) của mô hình bi-encoder vòng 2 kết hợp với BM25

đã làm tăng đáng kể độ chính xác của các mô hình bi-encoder vòng 2, ở Acc@1 tăng khoảng 7-9% với các mô hình dựa trên PhoBERT và khoảng 2% với mô hình BGE-m3. Tuy độ chính xác của BGE-m3 được cải thiện ít nhất so với các mô hình còn lại nhưng vẫn là cao nhất trong bốn mô hình ở cả 3 độ đo, đặc biệt là Acc@100 gần như là chính xác 100% tức là trong 100 văn bản mà mô hình đánh giá cao nhất thì gần như chắc chắn có văn bản phù hợp. Kết quả đạt được nhờ bổ sung khả năng so khớp từ vựng của mô hình BM25 đã tinh chỉnh, giúp mô hình vừa so sánh ngữ nghĩa kết hợp với từ vựng để đưa ra đánh giá khách quan nhất về độ tương đồng giữa câu truy vấn và văn bản pháp luật.

4.5.5 Thí nghiệm bổ sung chunking dữ liệu

Như đã phân tích ở phần thống kê dữ liệu 4.1.2, độ dài trung bình của các văn bản pháp luật là khoảng 335 tokens, tức là vượt quá giới hạn đầu vào cho mô hình PhoBERT là 256 tokens. Em nhận thấy như vậy mô hình sẽ bỏ qua phần văn bản nằm ngoài phạm vi xử lý của mô hình và có thể bỏ lỡ những thông tin quan trọng ở phần sau, dẫn tới điểm đánh giá độ tương đồng của câu truy vấn và văn bản có thể chưa chính xác. Nên em đã thử nghiệm bổ sung phân đoạn dữ liệu để giúp mô hình dự đoán tốt hơn, chỉ cần một đoạn trong văn bản được dự đoán phù hợp thì văn bản đó sẽ là văn bản phù hợp. Em thử nghiệm với hai trường hợp là phân thành các đoạn có độ dài 256 từ và 512 từ, em không thử nghiệm với trường hợp nhỏ hơn vì khi chia thành các đoạn quá ngắn sẽ không mang đầy đủ ngữ nghĩa, không thử nghiệm với trường hợp dài hơn vì các mô hình dựa trên PhoBERT sẽ cắt ngắn quá nhiều từ.

Ngoài ra em sử dụng kết hợp bổ sung BM25 để thử nghiệm xem sau khi bị phân đoạn thì áp dụng thêm phương pháp thuần thống kê có giúp cải thiện chất lượng mô hình hay không. Kết quả thí nghiệm thu được ở hình 4.6, các mô hình bi-encoder vòng 2 sau khi áp dụng chunking dữ liệu đã tăng độ chính xác một các rõ rệt, về Acc@1 thì các mô hình tăng từ 15-20%, điều đó chứng tỏ việc áp dụng chunking dữ liệu đã giúp cải thiện mô hình nhờ việc không bỏ sót các thông tin ở phía sau của các văn bản pháp luật. So sánh hai thử nghiệm với kích thước chunk là 256 và 512 thì kích thước 512 có kết quả tốt hơn ở cả bốn mô hình, vì thế em sẽ chọn

Mô hình	**Acc@1**		**Acc@10**		**Acc@100**	
	256	**512**	**256**	**512**	**256**	**512**
PhoBERT-base v2 + chunking	83.75	85.94	93.44	95.16	98.28	98.44
Condenser + chunking	79.72	83.59	96.09	96.88	98.75	98.91
coCondenser + chunking	86.09	87.03	95.00	95.63	97.97	97.97
BGE-m3 + chunking	93.28	**93.44**	98.28	**98.75**	99.69	99.38
PhoBERT-base v2 + BM25 + chunking	84.69	83.59	95.16	95.78	98.75	99.06
Condenser + BM25 + chunking	83.44	83.28	95.94	96.25	99.06	99.06
coCondenser + BM25 + chunking	85.47	85.94	96.56	96.41	99.06	99.22
BGE-m3 + BM25 + chunking	89.84	90.16	98.44	98.44	**99.84**	99.69

Bảng 4.6: Độ chính xác (%) của mô hình BGE bi-encoder vòng 2 kết hợp chunking dữ liệu và BM25 với hai thiết lập về kích thước chunk là 256 và 512.

phân đoạn dữ liệu kích thước 512 để áp dụng cho các thử nghiệm sau. Còn về việc bổ sung BM25 ở đây không mang lại hiệu quả khi làm giảm độ chính xác Acc@1 của các mô hình coCondenser và BGE-m3, chỉ giúp tăng Acc@10 và Acc@100 cho các mô hình. Nguyên nhân có thể là vì khi phân đoạn dữ liệu thì mỗi đoạn văn không chứa đủ các từ khóa quan trọng như đoạn văn ban đầu nên kết quả khi sử dụng BM25 sẽ bị giảm sút. Vì tác vụ truy xuất văn bản pháp luật luôn ưu tiên đưa ra được văn bản phù hợp nhất (ưu tiên cải thiện Acc@1) nên không sử dụng BM25 sẽ mang lại hiệu quả hơn.

4.5.6 Thí nghiệm bổ sung reranker và tổng hợp các thành phần

Trong phần này em đã đánh giá mô hình baseline cũng như bổ sung thành phần reranker vào một số các mô hình để thử nghiệm nhằm đưa ra giải pháp tốt nhất cho bài toán truy vấn văn bản pháp luật. Ở thí nghiệm này em sử dụng các mô hình bi-encoder của thành phần retriever để lấy ra top 50 đoạn văn bản phù hợp nhất để đưa vào bộ xếp hạng lại reranker, sau đó kết hợp điểm đánh giá độ tương đồng của cả retriever và reranker để đưa ra kết quả cuối cùng. Các kịch bản thử nghiệm mà em sử dụng sẽ là:

(i) Mô hình bi-encoder vòng 2 kết hợp với reranker áp dụng chunking, công thức tính độ tương đồng là: $\text{score}_{final} = \text{score}_{bi-encoder} + \text{score}_{reranker}$

(ii) Tương tự như kịch bản (i) nhưng bổ sung BM25, công thức tính độ tương đồng là: $\text{score}_{final} = (\text{score}_{bi-encoder} + \text{score}_{reranker}) \times \text{score}_{BM25}$

(iii) Sử dụng tổng hợp (ensemble) 2 mô hình bi-encoder vòng 2: mô hình BGE-m3 và mô hình dựa trên PhoBERT tạo thành retriever sau đó kết hợp reranker, công thức tính độ tương đồng như sau: $\text{score}_{final} = (\text{score}_{BGE-m3} + \text{score}_{PhoBERT}) + \text{score}_{reranker}$

(iv) Cuối cùng em tổng hợp cả 4 mô hình bi-encoder vòng 2 tạo thành retriever sau đó kết hợp với reranker, công thức tính độ tương đồng là:

$$\text{score}_{retriever} = \text{score}_{BGE-m3} + \frac{\text{score}_{PhoBERT-base} + \text{score}_{Condenser} + \text{score}_{coCondenser}}{3}$$

$$\text{score}_{final} = \text{score}_{retriever} + \text{score}_{reranker}$$

Sau khi thử nghiệm thì em thu được kết quả như bảng 4.7.

Mô hình	Acc@1	Acc@10	Acc@100
BM25	50.16	82.5	95.63
bkai-foundation-models/vietnamese-bi-encoder	50.8	78.12	91.56
PhoBERT-base v2 + BM25	71.09	93.75	98.91
Condenser + BM25	72.97	94.22	98.59
coCondenser + BM25	73.91	93.75	98.75
BGE-m3 + BM25	77.5	95	99.22
PhoBERT-base v2 + chunking + reranker	89.53	95.94	98.44
Condenser + chunking + reranker	91.88	97.34	98.91
coCondenser + chunking + reranker	90.63	96.56	97.97
BGE-m3 + chunking + reranker	93.75	98.75	99.4
PhoBERT-base v2 + chunking + reranker + BM25	85.63	96.1	98.44
Condenser + chunking + reranker + BM25	85	97.66	98.91
coCondenser + chunking + reranker + BM25	87.81	96.4	97.97
BGE-m3 + chunking + reranker + BM25	89.4	98.6	99.4
BGE-m3 + PhoBERT-base v2 + chunking + reranker	94.06	98.6	99.53
BGE-m3 + Condenser + chunking + reranker	**94.22**	98.6	99.53
BGE-m3 + coCondenser + chunking + reranker	93.59	**98.75**	99.53
Retriever (Gộp 4 mô hình bi-encoder) + chunking + reranker	93.91	**98.75**	**99.69**

Bảng 4.7: Độ chính xác (%) của mô hình baseline và các mô hình bi-encoder vòng 2 khi bổ sung thành phần reranker

Qua kết quả thu được, em nhận thấy việc bổ sung mô-đun xếp hạng lại có mang lại hiệu quả khi tăng được độ chính xác cho các mô hình bi-encoder vòng 2, tuy nhiên kết quả cải thiện không nhiều, có thể là do em chưa huấn luyện đủ lâu cho mô hình BGE-reranker và bộ dữ liệu huấn luyện chỉ lấy từ mô hình BGE-m3 bi-encoder vòng 2 nên kết quả chưa được cao. Ngoài ra việc bổ sung BM25 không còn tác dụng khi giảm độ chính xác của cả 4 mô hình nên em sẽ không sử dụng BM25 trong phần tổng hợp mô hình (ensemble). Việc kết hợp mô hình BGE-m3 với từng mô hình PhoBERT-base v2, Condenser, coCondenser đã cải thiện được độ chính xác khi Acc@1 có thể đạt tới hơn 94%. Em thấy khá đặc biệt là PhoBERT-base v2, Condenser có kết quả vượt qua coCondenser khi kết hợp cùng BGE-m3, và vượt qua cả kết quả tổng hợp 4 mô hình bi-encoder. Em chưa có thời gian thực hiện các

thử nghiệm sâu hơn như thay đổi trọng số trong việc tổng hợp mô hình để có thể đạt những kết quả cao hơn.

Sau cùng, kết quả tốt nhất mà em thực hiện là mô hình BGE-m3, Condenser kết hợp reranker và chunking dữ liệu, với Acc@1 đạt 94.22%. Ngoài việc thử nghiệm để kiểm tra độ chính xác của các mô hình, em còn thử nghiệm về tốc độ xử lý, truy xuất để có thể tìm ra một mô hình vừa có độ chính xác cao và tốc độ nhanh để đáp ứng nhu cầu thực tế.

4.5.7 Thí nghiệm so sánh tốc độ truy xuất của các mô hình

Em đã xây dựng một ứng dụng web đơn giản chạy trên local để trực quan hóa về tốc độ, hiệu quả của hệ thống truy xuất. Em sẽ thử nghiệm với dữ liệu văn bản đã được phân đoạn (chunking), và sẽ so sánh tốc độ truy vấn của các mô hình bi-encoder vòng 2, BM25, bổ sung reranker, tổng hợp các mô hình. Hệ thống được chạy trên GPU của Google Colab có VRAM 15GB, em thực hiện thí nghiệm bằng cách đưa 1 câu hỏi có độ dài 24 (bằng độ dài trung bình của các truy vấn trong tập dữ liệu) qua mô hình 30 lần rồi tính thời gian xử lý trung bình, kết quả thí nghiệm trình bày ở bảng 4.8.

Mô hình	Thời gian chạy 1 truy vấn
BM25	0.542
PhoBERT-base v2 vòng 2	2.702
Condenser vòng 2	2.716
coCondenser vòng 2	2.740
BGE-m3 vòng 2	3.064
PhoBERT-base v2 + reranker	8.052
Condenser + reranker	7.821
coCondenser + reranker	7.963
BGE-m3 + reranker	8.155
BGE-m3 + PhoBERT-base v2 + reranker	10.513
BGE-m3 + Condenser + reranker	10.469
BGE-m3 + coCondenser + reranker	10.717
Retriever (Gộp 4 mô hình bi-encoder) + reranker	16.053

Bảng 4.8: Tốc độ truy xuất của các mô hình (giây/1 truy vấn)

Qua so sánh, tốc độ của mô hình BM25 là cao nhất vì không dùng đến các mô hình học sâu nhưng độ chính xác thấp, tiếp đến là các mô hình bi-encoder vòng 2 mất khoảng gần 3 giây để thực hiện 1 truy vấn. Khi bổ sung reranker thì tốc độ sẽ chậm hơn vì phải rerank lại top 50 văn bản nên tốc độ khoảng gần 8 giây/1 truy vấn, khi kết hợp 2 mô hình bi-encoder thì mất hơn 10 giây/1 truy vấn, còn khi kết hợp cả 4 mô hình bi-encoder thì mất khoảng 16 giây/1 truy vấn.

Em vẫn chưa tối ưu được quá trình suy diễn của bộ truy xuất nên tốc độ xử lý truy vấn còn khá chậm, chưa đủ để đáp ứng cho hệ thống hỏi đáp về pháp luật trên quy mô lớn, chỉ dùng được ở cấp cơ sở, không có quá nhiều người dùng cùng lúc. Nếu muốn đáp ứng được lượng người dùng lớn hơn thì cần phải cải tiến cách xử lý của các mô hình, tăng cơ sở hạ tầng để hệ thống chạy song song đáp ứng được lưu lượng lớn hơn.

CHƯƠNG 5. KẾT LUẬN

5.1 Kết luận

Tổng kết lại, trong đồ án này, em đã xây dựng thành công một hệ thống hỏi đáp pháp luật Việt Nam đơn giản với đề xuất về mô hình truy xuất thông tin với độ chính xác cao. Em đã khắc phục được nhiều hạn chế của các giải pháp hiện tại bằng việc tiền huấn luyện và tinh chỉnh các mô hình PhoBERT, Condenser, coCondenser, BGE-m3 và kết hợp các mô hình để đạt được kết quả cao. Em đã sử dụng mô hình BM25 để bổ trợ cho mô-đun retrieval cũng như tạo ra bộ dữ liệu huấn luyện cho các mô hình bi-encoder bằng cách khai thác các mẫu âm khó. Tương tự thì các mô hình bi-encoder cũng khai thác mẫu âm khó để làm dữ liệu tinh chỉnh vòng 2 cho bản thân các mô hình đó giúp các mô hình học biểu diễn tốt hơn, chính xác hơn. Em cũng đã kết hợp được 2 kiến trúc bi-encoder và cross-encoder tạo thành cặp mô-đun retriver, reranker giúp tận dụng được điểm mạnh của từng kiến trúc. Ngoài ra em đề xuất giải pháp chunking dữ liệu để giải quyết vấn đề văn bản dài hơn đầu vào tối đa của mô hình nhằm tăng hiệu quả của hệ thống truy xuất.

Bên cạnh đó, đồ án này vẫn còn những vấn đề tồn đọng như hệ thống hỏi đáp còn rất thô sơ, chưa thể triển khai thực tế vì các vấn đề về tối ưu tính toán, lưu trữ dữ liệu, tốc độ truy xuất, ... Em chưa tiền huấn luyện đủ tốt các mô hình coCondenser và reranker nên kết quả chưa được cao, em cũng chưa tận dụng được toàn bộ khả năng nhúng mạnh mẽ của mô hình BGE-m3 khi mới sử dụng truy xuất dày đặc (dense retrieval) và chưa thử nghiệm truy xuất kết hợp (unified retrieval). Đồ án mới chỉ tập trung vào cải thiện khả năng truy xuất dữ liệu chứ chưa có khả năng trả lời câu hỏi cho người dùng dựa trên văn bản đã truy xuất.

5.2 Hướng phát triển trong tương lai

Về các hướng phát triển trong tương lai mà em hi vọng có thể thực hiện được để giải quyết các vấn đề tồn đọng của đồ án cũng như cải thiện hơn nữa những gì mà đồ án đã làm được.

Xây dựng một hệ thống hỏi đáp pháp luật hoàn chỉnh với cơ sở dữ liệu được cập nhật, bổ sung theo thời gian, với khả năng truy xuất chính xác hơn, nhanh hơn.

Cải thiện các mô hình đã đề xuất với phần cứng tính toán mạnh hơn cũng như nghiên cứu, thử nghiệm các mô hình tiên tiến nhất để cải thiện hiệu suất tìm kiếm của hệ thống hỏi đáp pháp luật. Đặc biệt là huấn luyện tốt mô hình BGE-m3 unified retrieval sử dụng tự chắt lọc kiến thức nhằm nâng cao độ chính xác của hệ thống truy xuất.

Với sự phát triển không ngừng của các mô hình ngôn ngữ lớn, xây dựng được một mô hình có khả năng sinh ra câu trả lời cho người dùng từ các văn bản pháp luật truy xuất được để người dùng có thể hiểu câu trả lời một cách đơn giản, chính xác hơn.

TÀI LIỆU THAM KHẢO

[1] G. Salton **and** C. Buckley, "Term-weighting approaches in automatic text retrieval," *Information Processing Management*, **jourvol** 24, **number** 5, **pages** 513–523, 1988, ISSN: 0306-4573. DOI: https://doi.org/10.1016/0306-4573(88)90021-0.

[2] S. Robertson, H. Zaragoza **and** M. Taylor, "Simple bm25 extension to multiple weighted fields," **november** 2004, **pages** 42–49. DOI: 10.1145/1031171.1031181.

[3] J. Devlin, M.-W. Chang **and** et al., *Bert: Pre-training of deep bidirectional transformers for language understanding*, 2019. arXiv: 1810.04805 [cs.CL]. **url**: https://arxiv.org/abs/1810.04805.

[4] Y. Liu, M. Ott **and** e. a. Naman Goyal, *Roberta: A robustly optimized bert pretraining approach*, 2019. arXiv: 1907.11692 [cs.CL]. **url**: https://arxiv.org/abs/1907.11692.

[5] R. Nogueira **and** K. Cho, *Passage re-ranking with bert*, 2020. arXiv: 1901.04085 [cs.IR]. **url**: https://arxiv.org/abs/1901.04085.

[6] X. S. e. a. T. Nguyen M. Rosenberg, *Ms marco: A human generated machine reading comprehension dataset*, 2016.

[7] N. Reimers **and** I. Gurevych, "Sentence-bert: Sentence embeddings using siamese bert-networks," **in***Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)* Association for Computational Linguistics, 2019, **pages** 3982–3992.

[8] L. Gao **and** J. Callan, *Condenser: A pre-training architecture for dense retrieval*, 2021. arXiv: 2104.08253 [cs.CL]. **url**: https://arxiv.org/abs/2104.08253.

[9] L. Gao **and** J. Callan, *Unsupervised corpus aware language model pre-training for dense passage retrieval*, 2021. arXiv: 2108.05540 [cs.IR]. **url**: https://arxiv.org/abs/2108.05540.

[10] H.-T. Nguyen, P. Nguyen, T.-H.-Y. Vuong **andothers**, "Jnlp team: Deep learning approaches for legal processing tasks in coliee 2021," **june** 2021.

[11] N.-M. Pham, H.-T. Nguyen **and** T.-H. Do, *Multi-stage information retrieval for vietnamese legal texts*, 2022. arXiv: 2209.14494 [cs.CL]. **url**: https://arxiv.org/abs/2209.14494.

[12] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian **and** Z. Liu, *Bge m3-embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through*

self-knowledge distillation, 2024. arXiv: 2402.03216 [cs.CL]. **url**: https://arxiv.org/abs/2402.03216.

[13] A. Vaswani, N. Shazeer, N. Parmar **andothers**, *Attention is all you need*, 2023. arXiv: 1706.03762 [cs.CL]. **url**: https://arxiv.org/abs/1706.03762.

[14] A. Conneau, K. Khandelwal, N. Goyal **andothers**, *Unsupervised cross-lingual representation learning at scale*, 2020. arXiv: 1911.02116 [cs.CL]. **url**: https://arxiv.org/abs/1911.02116.

[15] K. Clark, U. Khandelwal, O. Levy **and** C. D. Manning, *What does bert look at? an analysis of bert's attention*, 2019. arXiv: 1906.04341 [cs.CL]. **url**: https://arxiv.org/abs/1906.04341.

[16] D. Q. Nguyen **and** A. T. Nguyen, *Phobert: Pre-trained language models for vietnamese*, 2020. arXiv: 2003.00744 [cs.CL]. **url**: https://arxiv.org/abs/2003.00744.

[17] O. Khattab **and** M. Zaharia, *Colbert: Efficient and effective passage search via contextualized late interaction over bert*, 2020. arXiv: 2004.12832 [cs.IR]. **url**: https://arxiv.org/abs/2004.12832.

[18] D. E. Rumelhart, G. E. Hinton **and** R. J. Williams, "Learning representations by back-propagating errors," *Nature*, **jourvol** 323, **number** 6088, **pages** 533–536, 1986.

[19] S. Hochreiter **and** e. a. Schmidhuber, "Long short-term memory," *Neural computation*, **jourvol** 9, **number** 8, **pages** 1735–1780, 1997.

[20] Z. Lan, M. Chen, S. Goodman, K. Gimpel, P. Sharma **and** R. Soricut, "Albert: A lite bert for self-supervised learning of language representations," *arXiv preprint arXiv:1909.11942*, 2020.

[21] V. Sanh, L. Debut, J. Chaumond **and** T. Wolf, "Distilbert, a distilled version of bert: Smaller, faster, cheaper and lighter," *arXiv preprint arXiv:1910.01108*, 2019.

PHỤ LỤC

A. Kiến trúc mô hình BERT

A.1 Mô hình BERT

BERT (Bidirectional Encoder Representations from Transformers) là một mô hình ngôn ngữ dựa trên kiến trúc Transformer, được giới thiệu bởi Google vào năm 2018 trong bài báo khoa học "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding" của Jacob Devlin và cộng sự [3]. Mô hình này đã đạt được hiệu suất đột phá trên nhiều nhiệm vụ xử lý ngôn ngữ tự nhiên (NLP).

BERT dựa trên kiến trúc Transformer, một cấu trúc được giới thiệu bởi Vaswani và các cộng sự trong bài báo "Attention is All You Need" năm 2017 [13]. Transformer sử dụng cơ chế chú ý nội bộ (self-attention) (A.1.1) để xử lý tuần tự các từ trong một câu mà không cần đến cấu trúc tuần tự như RNN [18] hay LSTM [19]. BERT khác biệt với các mô hình trước đó nhờ vào khả năng xử lý ngôn ngữ một cách hai chiều (bidirectional). Điều này có nghĩa là trong quá trình tiền huấn luyện, mỗi từ được xem xét trong bối cảnh của tất cả các từ xung quanh nó trong câu, điều này cho phép mô hình hiểu ngữ cảnh một cách tốt hơn. BERT được tiền huấn luyện sử dụng hai nhiệm vụ: Mô hình ngôn ngữ mặt nạ (Masked Language Model - MLM) và dự đoán câu tiếp theo (Next Sentence Prediction - NSP).

A.1.1 Cơ chế chú ý nội bộ

Cơ chế chú ý nội bộ (Self-attention) là một phần quan trọng trong kiến trúc Transformer, được sử dụng rộng rãi trong các mô hình xử lý ngôn ngữ tự nhiên như BERT. Self-attention giúp mô hình chú ý vào các phần khác nhau trong câu đầu vào để hiểu được mối liên hệ giữa các từ. Hiểu đơn giản hơn nó là một cơ chế cho phép một mô hình tính toán sự liên quan của mỗi từ đến tất cả các từ khác trong cùng một câu nhằm tạo ra một biểu diễn mới cho mỗi từ dựa trên toàn bộ câu, giúp mô hình có khả năng hiểu và sử dụng ngữ cảnh hiệu quả hơn.

Self-attention có thể được mô tả chi tiết qua hai cơ chế chính: Scaled Dot-Product Attention và Multi-Head Attention.

Scaled Dot-Product Attention

Scaled Dot-Product Attention là bước cơ bản trong cơ chế self-attention. Các bước thực hiện như sau: Mỗi từ trong câu được biến đổi thành ba vector: query ($\mathbf{q}_i$), key ($\mathbf{k}_i$), và value ($\mathbf{v}_i$). Điều này được thực hiện bằng cách nhân vector đầu vào $\mathbf{x}_i$ với ba ma trận trọng số khác nhau, mà mỗi ma trận này được học trong quá

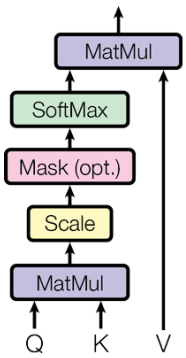

Hình A.1: Scaled Dot-Product Attention. Nguồn: [13]

trình huấn luyện:

$$\mathbf{q}_i = \mathbf{W}^Q \mathbf{x}_i, \quad \mathbf{k}_i = \mathbf{W}^K \mathbf{x}_i, \quad \mathbf{v}_i = \mathbf{W}^V \mathbf{x}_i \tag{A.1}$$

Điểm số chú ý giữa từ i và từ j được tính bằng tích vô hướng giữa query của từ i và key của từ j, sau đó chia cho $\sqrt{d_k}$ (với d_k là chiều của key vectors). Output cho từ i là tổng có trọng số của tất cả các vector $\mathbf{V}$:

$$\mathbf{z}_i = \sum_{j=1}^{n} \text{softmax}(\frac{\mathbf{q}_i^\top \mathbf{k}_j}{\sqrt{d_k}})\mathbf{v}_j \tag{A.2}$$

Multi-Head Attention

Cơ chế chú ý đa đỉnh mở rộng cơ chế attention bằng cách sử dụng nhiều "đỉnh" attention song song, cho phép mô hình đồng thời tập trung vào các phần khác nhau của câu. Cơ chế hoạt động như sau:

Từ đầu vào, tạo ra nhiều bộ Queries, Keys, và Values khác nhau bằng cách sử dụng các ma trận trọng số khác nhau:

$$\mathbf{Q}_i = \mathbf{W}_i^Q \mathbf{x}, \quad \mathbf{K}_i = \mathbf{W}_i^K \mathbf{x}, \quad \mathbf{V}_i = \mathbf{W}_i^V \mathbf{x} \tag{A.3}$$

Ở đây, i là chỉ số của các đầu attention khác nhau. Mỗi bộ Q, K, V được đưa qua cơ chế Scaled Dot-Product Attention riêng biệt. Điều này cho phép mỗi đầu attention tập trung vào các khía cạnh khác nhau của ngữ cảnh:

$$\text{head}_i = \text{Attention}(\mathbf{Q}_i, \mathbf{K}_i, \mathbf{V}_i) \tag{A.4}$$

$$\text{MultiHead}(Q, K, V) = [\text{head}_1, \text{head}_2, ..., \text{head}_h]\mathbf{W}^O \tag{A.5}$$

Sau cùng là sử dụng mạng lan truyền tiến theo vị trí (Position-Wise Feed-Forward network) được áp dụng riêng biệt và giống hệt nhau cho từng vị trí mà không có sự chia sẻ thông tin giữa các từ tại bước này. Mạng này bao gồm hai biến đổi tuyến tính và một hàm kích hoạt ReLU nằm giữa:

$$\text{FFN}(x) = \text{RELU}(xW_1 + b_1)W_2 + b_2 \tag{A.6}$$

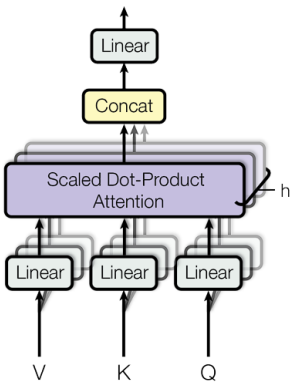

Hình A.2: Multi-Head Attention. Nguồn: [13]

Trong đó, W_1, W_2, b_1, b_2 là các tham số mô hình học được và dùng cho tất cả các vị trí.

A.1.2 Mô hình ngôn ngữ mặt nạ (Masked Language Model - MLM)

Mô hình ngôn ngữ mặt nạ (Masked Language Model) là một phương pháp học máy được sử dụng chủ yếu trong các mô hình NLP, phương pháp này trở lên phổ biến và nổi tiếng với sự xuất hiện của BERT. MLM giúp mô hình học biểu diễn ngôn ngữ một cách tốt hơn bằng cách dự đoán các từ bị ẩn (masked) từ một ngữ cảnh cho trước.

Nguyên lý chính của MLM đó là ẩn một số từ trong câu ban đầu và đưa câu đó qua mô hình ngôn ngữ và yêu cầu mô hình phải dự đoán các từ bị ẩn đi dựa trên ngữ cảnh của các từ còn lại, điều này buộc mô hình phải hiểu ý nghĩa, ngữ cảnh của toàn bộ câu để dự đoán chính xác các từ bị ẩn đi.

Hình A.3 mô tả phương pháp mô hình mặt nạ, quá trình huấn luyện MLM gồm các bước như sau: Ban đầu, ta sẽ thay thế một tỷ lệ phần trăm các từ trong câu đàu vào bằng một token đặc biệt là [MASK], ví dụ với tỷ lệ thông dụng là 15% một câu như "Chú chó đang ăn miếng thịt ngon lành." có thể trở thành "Chú chó đang [MASK] miếng thịt ngon lành.". Câu này sẽ được đưa qua kiến trúc Transformer Encoder để tạo ra các biểu diễn ngữ cảnh cho từng từ trong câu dựa trên ngữ cảnh

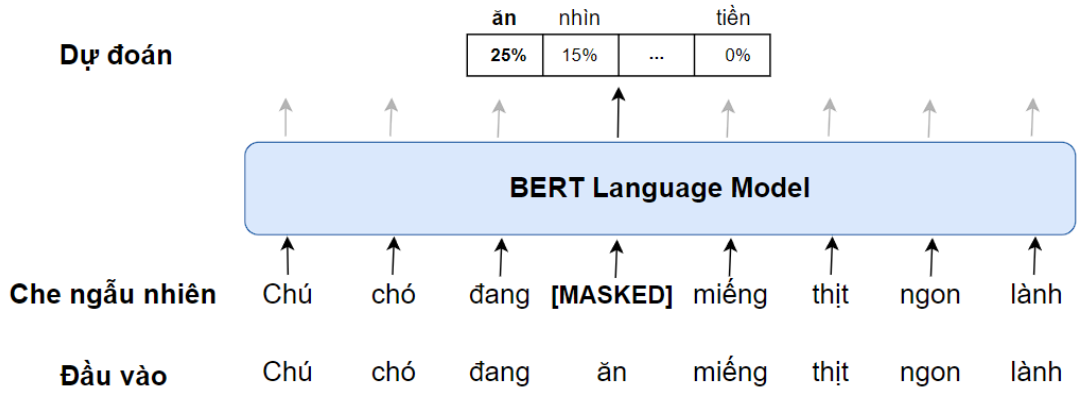

Hình A.3: Mô hình ngôn ngữ mặt nạ

của các từ còn lại. Vector biểu diễn ngữ cảnh của mỗi từ sẽ được đưa qua một bộ phân loại softmax để tạo ra vector có số chiều bằng với kích thước từ điển (vocab size) là phân phối xác suất trên toàn bộ từ vựng. Hàm mất mát được tính bằng cách so sánh các dự đoán của mô hình với nhãn thực tế bị ẩn đi, phổ biến nhất là hàm cross-entropy.

MLM cho phép mô hình học biểu diễn ngữ cảnh mạnh mẽ cho các từ ngữ, vì nó phải xem xét cả ngữ cảnh trước và sau từ bị ẩn để dữ đoán từ bị ẩn. Việc huấn luyện mô hình trên một lượng lớn dữ liệu văn bản với các từ bị ẩn một cách ngẫu nhiên sẽ giúp mô hình tổng quát hóa tốt hơn cho các tác vụ NLP khác nhau. MLM thường được sử dụng để tiền huấn luyện (pretrain) cho các mô hình ngôn ngữ, sau đó các mô hình này có thể được tinh chỉnh (fine-tune), điều này giúp tăng hiệu suất của các mô hình trong các tác vụ cụ thể.

Tóm lại, Masked Language Model (MLM) là một phương pháp mạnh mẽ để học biểu diễn ngữ cảnh cho từ ngữ trong các mô hình ngôn ngữ, giúp cải thiện độ chính xác, hiệu suất trên nhiều tác vụ NLP. MLM đã trở thành một kỹ thuật tiêu chuẩn trong huấn luyện các mô hình ngôn ngữ hiện đại.

A.1.3 Dự đoán câu tiếp theo (Next Sentence Prediction - NSP)

Next Sentence Prediction (NSP) giúp mô hình hiểu được mối quan hệ giữa các câu, một yếu tố quan trọng trong nhiều tác vụ xử lý ngôn ngữ tự nhiên (NLP) như trả lời câu hỏi, tổng hợp văn bản, và phân tích hội thoại. Nhiệm vụ NSP được thiết kế để giúp BERT học cách hiểu ngữ cảnh của câu trong một đoạn văn bản, đặc biệt là khả năng xác định xem một câu có phải là câu tiếp theo thực sự của một câu khác hay không. Điều này đặc biệt hữu ích trong các tác vụ yêu cầu hiểu biết về sự liên kết giữa các câu.

Trong quá trình tiền huấn luyện BERT, nhiệm vụ NSP được thực hiện qua các

bước sau: Đầu tiên, dữ liệu được chuẩn bị bằng cách tạo ra các cặp câu từ tập dữ liệu huấn luyện. 50% các cặp câu là các câu thực sự tiếp nối nhau trong văn bản (có nhãn là "IsNext"), và 50% còn lại là các cặp câu không liên quan, được ghép ngẫu nhiên từ các đoạn văn bản khác nhau (có nhãn là "NotNext"). Mỗi cặp câu sau đó được nối với nhau và đưa vào mô hình BERT. Các token đặc biệt như [CLS] được thêm vào đầu chuỗi và [SEP] được thêm giữa hai câu để phân biệt chúng, ví dụ: "[CLS] Trời hôm nay đẹp quá! [SEP] Hãy đi ra ngoài chơi. [SEP]". Sau khi đưa qua mô hình BERT thì thu được vector biểu diễn của token [CLS] đã tổng hợp được thông tin toàn bộ chuỗi, vector này sau đó được đưa qua một lớp tuyến tính và hàm softmax để tạo ra một phân phối xác suất trên hai nhãn "IsNext" và "NotNext" và tính độ mất mát bằng hàm loss Cross-entropy.

Nhờ vào nhiệm vụ NSP, BERT có thể học cách hiểu và dự đoán quan hệ giữa các câu trong văn bản. Điều này giúp mô hình nắm bắt được ngữ cảnh tổng thể của đoạn văn bản tốt hơn, tăng cường hiệu suất trong các nhiệm vụ NLP yêu cầu hiểu biết về mối quan hệ giữa các câu.

A.1.4 Quá trình tiền huấn luyện và tinh chỉnh mô hình BERT

Hình A.4 thể hiện quy trình tiền huấn luyện và tinh chỉnh mô hình BERT, ban đầu BERT được tiền huấn luyện với lượng lớn dữ liệu văn bản trên Wikipedia và BooksCorpus thông qua hai nhiệm vụ MLM (A.1.2) và NSP (A.1.3). BERT có hai phiên bản chính:

(i) BERT-Base: Gồm 12 lớp encoder, mỗi lớp có 12 đỉnh attention, kích thước hidden là 768, tổng cộng khoảng 110 triệu tham số.

(ii) BERT-Large: Gồm 24 lớp encoder, mỗi lớp có 16 đỉnh attention, kích thước hidden là 1024, tổng cộng khoảng 340 triệu tham số.

Sau khi được tiền huấn luyện, BERT có thể được tinh chỉnh cho các tác vụ cụ thể như phân loại văn bản, trả lời câu hỏi, nhận diện thực thể, và nhiều tác vụ NLP khác. Tinh chỉnh được thực hiện bằng cách thêm một lớp đầu ra vào trên cùng của BERT và huấn luyện lại mô hình trên tập dữ liệu của tác vụ đó.

BERT đã đạt được nhiều kết quả đột phá trên các benchmark quan trọng như SQuAD (Stanford Question Answering Dataset), GLUE (General Language Understanding Evaluation), và nhiều bài kiểm tra khác trong lĩnh vực NLP. BERT cũng đã mở đường cho nhiều nghiên cứu và phát triển các biến thể khác như RoBERTa, ALBERT [20], và DistilBERT [21].

Nhìn chung, BERT là một bước tiến lớn trong lĩnh vực xử lý ngôn ngữ tự nhiên, nhờ vào khả năng hai chiều và quá trình huấn luyện dựa trên Masked Language

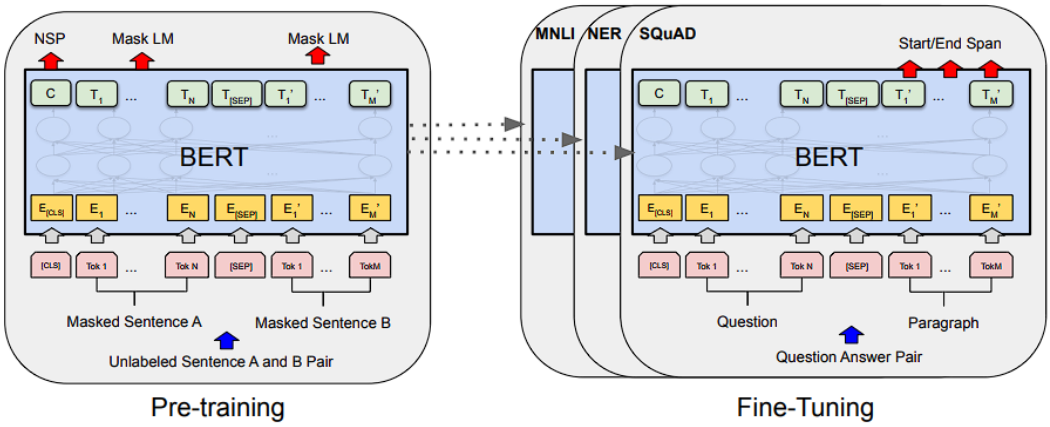

Hình A.4: Sơ đồ tiền huấn luyện và tinh chỉnh mô hình BERT. Nguồn: [3]

Model và Next Sentence Prediction. Sự linh hoạt và hiệu quả của BERT trong việc học ngữ cảnh đã giúp nó trở thành một công cụ mạnh mẽ cho nhiều ứng dụng NLP khác nhau.