HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

PROJECT III

Research on chunking techniques in the RAG problem

DOAN NGOC CUONG
cuong.dn210141@sis.hust.edu.vn

Major: Data Science and AI

Supervisor: Ph.D Michel Toulouse _____

Signature

Department: Computer Science

School: Information and Communications Technology

HA NOI, 01/2025

LỜI CẢM ƠN

Trước hết tôi xin bày tỏ lòng biết ơn chân thành và sâu sắc nhất tới TS. Michel Toulouse, người đã tận tình hướng dẫn và hỗ trợ tôi vượt qua thử thách trong Dự án III - Nhiệm kỳ 2024.1. Tôi cũng xin gửi lời cảm ơn sâu sắc đến bạn bè, anh em đã đồng hành cùng tôi trong suốt thời gian thực tập tại đây.

SUMMARY OF REPORT CONTENT

Ngày nay, trí tuệ nhân tạo và các mô hình ngôn ngữ lớn (LLM) như ChatGPT, Gemini, Claude được ứng dụng rộng rãi trong các hệ thống trả lời câu hỏi (QA) tự động. Tuy nhiên, hệ thống QA sử dụng LLM vẫn phải đối mặt với những thách thức đáng kể, bao gồm thông tin lỗi thời và ảo giác. Để giải quyết những vấn đề này, kỹ thuật Tạo tăng cường truy xuất (RAG) đã được giới thiệu để kết hợp truy xuất thông tin, tích hợp dữ liệu nội bộ và cập nhật thông tin bên ngoài. Mặc dù có tiềm năng nhưng hệ thống RAG vẫn gặp phải những hạn chế về chất lượng bối cảnh đầu vào. Nghiên cứu này tập trung nghiên cứu kỹ thuật phân đoạn văn bản nhằm nâng cao chất lượng câu trả lời trong hệ thống RAG. Nó đánh giá các phương pháp phân đoạn từ cách tiếp cận truyền thống đến hiện đại, bao gồm việc áp dụng LLM và các phương pháp kết hợp tối ưu.

Student

(Doan Ngoc Cuong)

MỤC LỤC

CHƯƠNG 1. INTRODUCTION 1

1.1 Phát biểu vấn đề 1

1.2 Giải pháp hiện tại và hạn chế 2

1.3 Đóng góp của nghiên cứu 2

1.4 Cấu trúc nghiên cứu 2

CHƯƠNG 2. THEORETICAL BACKGROUND 3

2.1 Bối cảnh vấn đề 3

2.2 Mô hình ngôn ngữ lớn (LLMs) 3

2.2.1 Tổng quan về Mô hình ngôn ngữ lớn 3

2.2.2 Các dòng LLM phổ biến: Gemini, Qwen, LLaMA 4

2.3 Khởi tạo lại kết hợp (RAG) 5

CHƯƠNG 3. RESEARCH METHODOLOGY 6

3.1 Tổng quan về các phương pháp phân đoạn truyền thống 6

3.2 Các phương pháp truyền thống 7

3.2.1 Phân đoạn theo quy tắc 7

3.2.2 Phân đoạn động 7

3.2.3 Đánh giá tổng quát 8

3.3 Phương pháp RAPTOR 8

3.3.1 Tổng quan về phương pháp 8

CHƯƠNG 4. EXPERIMENTAL EVALUATION 10

4.1 Thí nghiệm 10

4.1.1 Bộ dữ liệu 10

4.1.2 Phương pháp so sánh 10

4.1.3 Kết quả thí nghiệm 10

4.1.4 Phân tích kết quả 11

4.1.5 Hiệu quả và khả năng mở rộng 12

4.1.6 Kết luận thí nghiệm 12

CHƯƠNG 5. CONCLUSION 13

5.1 Conclusion 13

5.2 Future Directions 13

REFERENCES 16

PHỤ LỤC 18

A. HƯỚNG DẪN VIẾT ĐATN 18

A.1 Quy định chung 18

A.2 Ngành học 19

A.3 Đánh dấu (bullet) và đánh số (numering) 19

A.4 Cách thêm bảng 20

A.5 Chèn hình ảnh 20

A.6 Tài liệu tham khảo 21

A.7 Cách viết phương trình và công thức toán học 21

A.8 Qui cách đóng quyển 21

B. ĐẶC TẢ USE CASE 23

B.1 Đặc tả use case “Thống kê tình hình mượn sách” 23

B.2 Đặc tả use case “Đăng ký làm thẻ mượn” 23

DANH MỤC HÌNH VẼ

Hình 2.1 Cây phát triển của các Mô hình ngôn ngữ lớn 4

Hình 3.1 RAPTOR (Xử lý Tóm tắt Đệ quy cho Truy xuất Tổ chức Dạng Cây) 9

Hình A.1 Internet vạn vật 20

Hình A.2 Qui cách đóng quyển đồ án 22

Hình A.3 Qui cách đóng quyển đồ án 22

DANH MỤC BẢNG BIỂU

Bảng 3.1 So sánh các chiến lược phân đoạn (Cập nhật) 6

Bảng 4.1 Hiệu suất trên bộ dữ liệu NarrativeQA 11
Bảng 4.2 Hiệu suất trên bộ dữ liệu QASPER 11
Bảng 4.3 Hiệu suất trên bộ dữ liệu QuALITY 11

Bảng A.1 Table to test captions and labels. 20

DANH MỤC THUẬT NGỮ VÀ TỪ VIẾT TẮT

Thuật ngữ	Ý nghĩa
AI	Trí tuệ nhân tạo (Artificial Intelligence)
BM25	Thuật toán tìm kiếm từ khóa dựa trên tần suất (Best Matching 25)
FAISS	Thư viện tìm kiếm vector nhanh (Facebook AI Similarity Search)
GMM	Mô hình hỗn hợp Gaussian (Gaussian Mixture Model)
GPT	Generative Pre-trained Transformer
IDFT	Phép biến đổi Fourier ngược rời rạc (Inverse Discrete Fourier Transform)
LLM	Mô hình ngôn ngữ lớn (Large Language Model)
RAG	Hệ thống kết hợp truy xuất và sinh thông tin (Retrieval-Augmented Generation)
SBERT	Mô hình Sentence-BERT
UMAP	Phương pháp giảm chiều dữ liệu (Uniform Manifold Approximation and Projection)

CHƯƠNG 1. INTRODUCTION

1.1 Phát biểu vấn đề

Trí tuệ Nhân tạo (AI) và các mô hình ngôn ngữ lớn (LLMs) như ChatGPT, Gemini, và Claude ngày càng trở nên phổ biến, đóng vai trò là công cụ quan trọng trong nhiều lĩnh vực, từ giáo dục, y tế, đến kinh doanh và giải trí. Những tiến bộ này không chỉ nâng cao năng suất mà còn cải thiện đáng kể chất lượng cuộc sống thông qua xử lý ngôn ngữ tự nhiên và tạo nội dung tự động. Tuy nhiên, bất chấp tiềm năng của chúng, LLMs vẫn gặp phải những thách thức đáng kể.

Một vấn đề lớn là khả năng các mô hình này cung cấp thông tin lỗi thời hoặc không chính xác, hiện tượng này thường được gọi là "ảo giác" (hallucination). Điều này xảy ra khi mô hình tạo ra các phản hồi nghe có vẻ hợp lý nhưng lại chứa thông tin sai lệch, khiến người dùng khó đánh giá độ tin cậy /ref. Vấn đề này bắt nguồn từ các hạn chế trong dữ liệu huấn luyện (bao gồm dữ liệu nội bộ, lỗi thời hoặc không đầy đủ), sự không nhất quán của dữ liệu, và các hạn chế trong lập luận ngữ cảnh.

Để giải quyết những hạn chế này, kỹ thuật Tạo sinh Tăng cường Truy xuất (RAG) đã được phát triển như một giải pháp kết hợp giữa truy xuất dữ liệu bên ngoài với khả năng tạo phản hồi của LLMs /ref. Thay vì chỉ dựa vào dữ liệu huấn luyện, RAG tích hợp dữ liệu thời gian thực hoặc dữ liệu chuyên biệt từ các cơ sở dữ liệu bên ngoài, giúp nâng cao độ chính xác và tính kịp thời của phản hồi.

Tuy nhiên, hiệu quả của RAG phụ thuộc nhiều vào quá trình phân đoạn tài liệu (document chunking). Phân đoạn không tối ưu có thể dẫn đến mất ngữ cảnh hoặc thông tin dư thừa, ảnh hưởng trực tiếp đến chất lượng truy xuất và độ chính xác của các câu trả lời được tạo ra /ref. Một số thách thức trong phân đoạn bao gồm:

- **Mất ngữ cảnh:** Các đoạn quá nhỏ có thể làm mất kết nối giữa các phần quan trọng của tài liệu.
- **Thông tin dư thừa:** Các đoạn quá lớn khiến mô hình phải xử lý lượng dữ liệu không cần thiết, làm giảm độ chính xác.
- **Xác định quy tắc phân đoạn:** Việc chọn kích thước và phương pháp phân đoạn phù hợp cho từng trường hợp sử dụng cụ thể là một nhiệm vụ phức tạp và không đơn giản.

Vì vậy, nghiên cứu này tập trung vào việc nghiên cứu, thử nghiệm và đánh giá các phương pháp phân đoạn tài liệu để đề xuất một giải pháp tối ưu nhằm nâng cao hiệu quả của hệ thống RAG trong truy xuất thông tin và tạo phản hồi.

1.2 Giải pháp hiện tại và hạn chế

Phương pháp phân đoạn cơ bản nhất là phân đoạn kích thước cố định, chia tài liệu thành các đoạn có kích thước bằng nhau dựa trên số lượng câu hoặc token được định sẵn. Mặc dù phương pháp này đơn giản và hiệu quả về mặt tính toán, nó có thể dễ dàng dẫn đến mất ngữ cảnh hoặc bao gồm thông tin không cần thiết, ảnh hưởng tiêu cực đến chất lượng truy xuất và độ chính xác của phản hồi hệ thống.

Mục tiêu và Hướng giải pháp Nghiên cứu này hướng tới:

- Nghiên cứu các kỹ thuật phân đoạn khác nhau, đánh giá ưu và nhược điểm của chúng, và đề xuất một sự kết hợp tối ưu.
- Cải thiện hiệu quả của mô-đun truy xuất, đặc biệt trong việc xử lý ngữ cảnh dài và các truy vấn phức tạp.
- Xây dựng một hệ thống nguyên mẫu, phân tích kết quả thử nghiệm và đề xuất cải tiến.

Các trọng tâm chính của nghiên cứu bao gồm:

1. Kết hợp các phương pháp phân đoạn truyền thống với LLMs để nâng cao chất lượng phân đoạn.
2. Thiết kế một quy trình truy xuất hiệu quả với các mô-đun xếp hạng bổ sung để tăng độ chính xác.

1.3 Đóng góp của nghiên cứu

Nghiên cứu này nghiên cứu các phương pháp phân đoạn cơ bản đến các phương pháp cải tiến nhằm nâng cao hiệu suất của hệ thống RAG.

1.4 Cấu trúc nghiên cứu

Báo cáo gồm năm chương:

- Chương 1: Phát biểu vấn đề.
- Chương 2: Cơ sở lý thuyết.
- Chương 3: Phương pháp phân đoạn được nghiên cứu trong phần phương pháp luận.
- Chương 4: Đánh giá thực nghiệm.
- Chương 5: Kết luận và Định hướng tương lai.

CHƯƠNG 2. THEORETICAL BACKGROUND

2.1 Bối cảnh vấn đề

2.2 Mô hình ngôn ngữ lớn (LLMs)

2.2.1 Tổng quan về Mô hình ngôn ngữ lớn

Mô hình ngôn ngữ lớn (LLMs) là các hệ thống AI tiên tiến được huấn luyện trên lượng lớn dữ liệu văn bản để hiểu và tạo ngôn ngữ tự nhiên. Các mô hình này thường dựa vào kiến trúc học sâu, đặc biệt là Transformers, để nắm bắt các mối quan hệ phức tạp giữa từ, câu và đoạn văn. Transformers, được giới thiệu lần đầu bởi Vaswani và cộng sự vào năm 2017, đã trở thành nền tảng của hầu hết các LLM hiện đại nhờ khả năng xử lý song song và hiệu quả trong việc hiểu ngữ cảnh dài.

LLMs có hai cách tiếp cận chính để người dùng và nhà phát triển truy cập:

- **Mô hình mã nguồn mở:** Các mô hình như Qwen và LLaMA thuộc loại mã nguồn mở, cho phép người dùng tùy chỉnh và phát triển thêm dựa trên nhu cầu cụ thể. Tính linh hoạt này hỗ trợ nghiên cứu và ứng dụng đa dạng. Tuy nhiên, việc triển khai các mô hình này đòi hỏi kiến thức kỹ thuật chuyên sâu và tài nguyên tính toán đáng kể.
- **Mô hình độc quyền:** Các mô hình như GPT là độc quyền, được phát triển và duy trì bởi các tổ chức lớn như OpenAI. Các mô hình này thân thiện với người dùng và thường có chất lượng cao, nhưng bị giới hạn trong khả năng tùy chỉnh và thường yêu cầu thanh toán khi sử dụng.

Chức năng cơ bản: LLMs hoạt động bằng cách dự đoán từ tiếp theo trong một chuỗi văn bản dựa trên ngữ cảnh trước đó. Quá trình huấn luyện của chúng bao gồm hai giai đoạn chính: tiền huấn luyện và tinh chỉnh. Trong giai đoạn tiền huấn luyện, mô hình học cách dự đoán từ tiếp theo bằng cách sử dụng tập hợp văn bản lớn và đa dạng, cho phép nó nắm bắt cấu trúc ngôn ngữ và tích lũy kiến thức thế giới. Giai đoạn tinh chỉnh giúp mô hình thích nghi với các tác vụ cụ thể bằng cách huấn luyện thêm trên các tập dữ liệu theo miền.

Ứng dụng của Mô hình ngôn ngữ lớn: LLMs đã chứng minh khả năng vượt trội và được áp dụng rộng rãi trong nhiều lĩnh vực. Một trong những ứng dụng quan trọng nhất là trong hệ thống Hỏi-Đáp (QA), nơi chúng cung cấp câu trả lời chính xác và tự nhiên cho các truy vấn của người dùng. Ngoài ra, chúng còn được sử dụng để tóm tắt văn bản, tạo các bản tóm tắt ngắn gọn và mạch lạc từ các tài liệu dài, tiết kiệm thời gian và công sức xử lý thông tin. Trong dịch thuật, chúng hỗ trợ chuyển đổi ngôn ngữ chính xác và tự nhiên, giúp xóa nhòa khoảng cách văn hóa.

Hơn nữa, LLMs được sử dụng để sáng tạo nội dung, tạo ra bài viết, báo cáo hoặc các nội dung sáng tạo khác, mở ra nhiều cơ hội mới trong ngành truyền thông và nội dung.

Thách thức: Mặc dù có nhiều lợi ích và tính linh hoạt ngày càng tăng, LLMs cũng gặp phải một số hạn chế, chẳng hạn như không thể cập nhật kiến thức sau khi quá trình huấn luyện hoàn tất. Vì các mô hình chỉ biết thông tin đến thời điểm được huấn luyện, việc tích hợp kiến thức mới đòi hỏi phải huấn luyện lại hoặc tinh chỉnh, điều này mất nhiều thời gian và tài nguyên. Đảm bảo chất lượng và độ chính xác của dữ liệu mới cũng là một thách thức lớn.

Sự phát triển của Mô hình ngôn ngữ lớn:

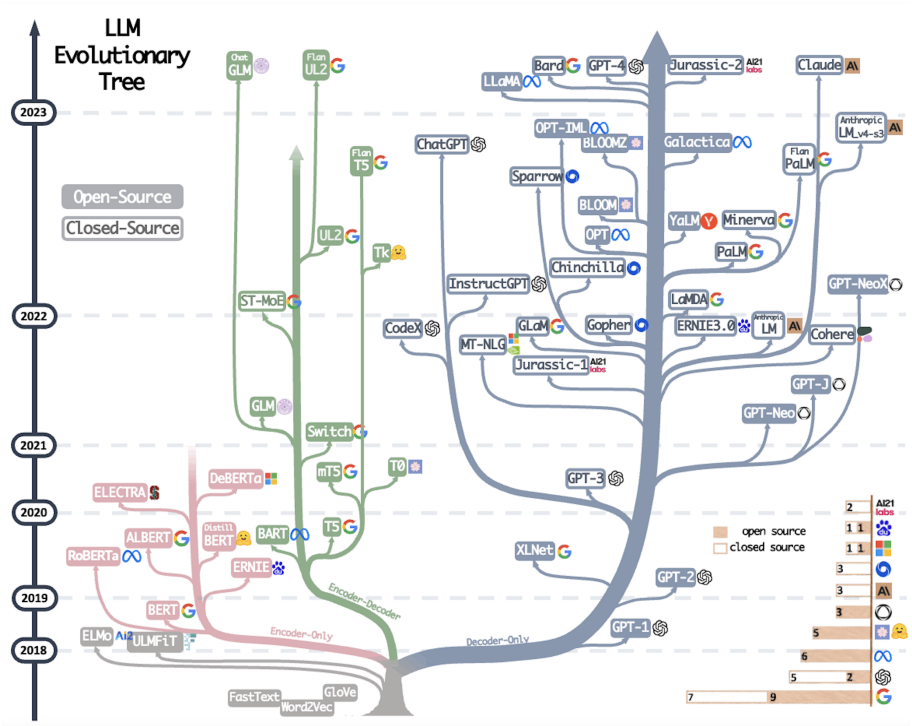

Hình 2.1: Cây phát triển của các Mô hình ngôn ngữ lớn

Hình 2.1 minh họa sự phát triển nhanh chóng và bùng nổ của LLMs. Từ năm 2023 trở đi, số lượng các LLM đã tăng đáng kể, phản ánh sự quan tâm toàn cầu và dự đoán xu hướng này sẽ trở thành tương lai của công nghệ AI.

2.2.2 Các dòng LLM phổ biến: Gemini, Qwen, LLaMA

Gemini: Được phát triển bởi Google DeepMind, Gemini tập trung vào các ứng dụng thương mại với khả năng học liên tục và tối ưu hóa xử lý ngôn ngữ tự nhiên. Nó tích hợp sâu vào các dịch vụ của Google, cung cấp các giải pháp thông minh cho doanh nghiệp và cá nhân. Các phiên bản nổi bật bao gồm Gemini 1.5 và Gemini Pro, mỗi phiên bản cải thiện hiệu suất và tính năng so với phiên bản tiền nhiệm.

Qwen: Được phát triển bởi Alibaba, Qwen phục vụ cho doanh nghiệp với khả năng hỗ trợ đa ngôn ngữ và quản lý thông tin hiệu quả. Nó được thiết kế để đáp ứng nhu cầu xử lý ngôn ngữ tự nhiên trong môi trường doanh nghiệp, cung cấp các công cụ mạnh mẽ cho phân tích dữ liệu và tương tác khách hàng. Các phiên bản như Qwen-Enterprise và Qwen-MultiLingual đã được triển khai rộng rãi trong các ứng dụng thương mại điện tử và dịch vụ khách hàng.

LLaMA: Là một mô hình mã nguồn mở từ Meta, LLaMA hỗ trợ nghiên cứu và phát triển AI mà không phụ thuộc vào các nền tảng độc quyền. Các phiên bản mới như LLaMA3.2 cải thiện đáng kể hiệu suất, mở rộng ứng dụng trong nhiều lĩnh vực, từ nghiên cứu học thuật đến sử dụng trong công nghiệp. LLaMA nổi bật với tính linh hoạt và khả năng tùy chỉnh cao, cho phép các nhà phát triển tích hợp nó một cách liền mạch vào các hệ thống hiện có.

Các mô hình này thể hiện những tiến bộ không ngừng trong AI, với mỗi dòng mô hình mang lại những tính năng và ứng dụng độc đáo để đáp ứng nhu cầu đa dạng của người dùng và doanh nghiệp. Sự phát triển liên tục của LLMs không chỉ cải thiện khả năng hiểu và tạo ngôn ngữ tự nhiên mà còn mở ra nhiều cơ hội áp dụng AI trong các ngành công nghiệp.

2.3 Khởi tạo lại kết hợp (RAG)

Khởi tạo lại kết hợp (Retrieval-Augmented Generation - RAG) là một kỹ thuật AI tiên tiến kết hợp khả năng truy xuất thông tin từ các nguồn dữ liệu bên ngoài với khả năng tạo ngôn ngữ tự nhiên của LLMs. Phương pháp này nhằm nâng cao độ chính xác và độ tin cậy của các hệ thống QA bằng cách cung cấp thông tin bổ sung và được cập nhật từ các tài liệu bên ngoài, giúp LLMs tránh tình trạng "ảo giác" và cung cấp câu trả lời dựa trên dữ liệu thực tế.

...

CHƯƠNG 3. RESEARCH METHODOLOGY

3.1 Tổng quan về các phương pháp phân đoạn truyền thống

Bảng 3.1 cung cấp một cái nhìn tổng quan so sánh các chiến lược phân đoạn truyền thống khác nhau, nêu bật mô tả, ưu điểm và hạn chế của từng phương pháp. Bảng này đóng vai trò là tài liệu tham khảo toàn diện để hiểu được sự đánh đổi giữa tính đơn giản, khả năng bảo toàn ngữ cảnh và hiệu quả tính toán liên quan đến từng phương pháp.

Bảng 3.1: So sánh các chiến lược phân đoạn (Cập nhật)

Chiến lược phân đoạn	**Mô tả**	**Ưu điểm**	**Hạn chế**
A. Phân đoạn cố định	Chia văn bản thành các đoạn có độ dài cố định với sự chồng lấn.	Dễ thực hiện, kích thước đoạn đồng đều.	Có thể cắt ngang câu và đoạn, dẫn đến mất ngữ cảnh quan trọng.
B. Phân đoạn theo câu	Chia văn bản dựa trên các câu hoàn chỉnh, giữ ngữ cảnh.	Bảo toàn ngữ cảnh, phù hợp với nội dung có cấu trúc phức tạp.	Các đoạn có thể khác nhau về độ dài, dẫn đến các đoạn quá dài.
C. Phân đoạn lai	Kết hợp phương pháp cố định và theo câu, ưu tiên tách tại ranh giới câu.	Bảo toàn ngữ cảnh tốt hơn phương pháp cố định, đặc biệt hữu ích cho nội dung theo câu.	Phức tạp hơn trong việc triển khai.
D. Phân đoạn dựa trên ngữ nghĩa	Sử dụng các mô hình ngôn ngữ để chia văn bản dựa trên ý nghĩa ngữ nghĩa thay vì độ dài cố định.	Tối ưu hóa cho tìm kiếm ngữ nghĩa, bảo toàn ý nghĩa tốt hơn.	Đòi hỏi nhiều tài nguyên tính toán, khó triển khai.
E. Phân đoạn ký tự đệ quy	Chia văn bản dựa trên các dấu ngắt câu như dấu chấm câu.	Bảo toàn cấu trúc tốt hơn so với phân đoạn ký tự đơn giản, phù hợp với văn bản có cấu trúc tốt.	Có thể cắt ngang ý nghĩa nếu dấu ngắt câu không được căn chỉnh đúng.
F. Bộ phân đoạn thông minh	Sử dụng "tác nhân" để tự động nhóm các đề xuất liên quan thành các đoạn ngữ nghĩa.	Tối ưu hóa tự động dựa trên ngữ cảnh, linh hoạt và thông minh hơn.	Phức tạp, đòi hỏi các mô hình AI tiên tiến.
G. Phân đoạn theo loại tài liệu	Chia nhỏ dựa trên các loại tài liệu (PDF, Markdown, mã Python).	Tối ưu hóa cho các loại tài liệu cụ thể, bảo toàn ngữ nghĩa tốt hơn.	Cần phân loại tài liệu trước khi phân đoạn.

3.2 Các phương pháp truyền thống

Trong phần này, tôi sẽ trình bày các phương pháp cơ bản làm nền tảng cho các cách tiếp cận phân đoạn tiếp theo. Các phương pháp này được chia thành hai loại chính: *phân đoạn theo quy tắc* và *phân đoạn động*, trong đó phương pháp sau kết hợp các mô hình tương đồng ngữ nghĩa và các mô hình ngôn ngữ lớn (LLMs).

3.2.1 Phân đoạn theo quy tắc

Phân đoạn theo quy tắc chia văn bản dài thành các đoạn có độ dài cố định mà không xem xét ranh giới câu. Tuy nhiên, phương pháp **Llama Index** (Langchain, 2023) cải thiện điều này bằng cách cân bằng giữa việc bảo toàn ranh giới câu trong khi đảm bảo số lượng token trong mỗi đoạn gần với một ngưỡng định sẵn.

Đặc điểm chính:

- Chia văn bản dựa trên số lượng token cố định.
- Đảm bảo tính toàn vẹn của câu trong các đoạn.

3.2.2 Phân đoạn động

Phân đoạn động dựa trên các mô hình học sâu được thiết kế để thích nghi với ngữ cảnh và cấu trúc của văn bản.

a, Phân đoạn tương đồng

Phương pháp này sử dụng các mô hình nhúng câu để tính toán mức độ tương đồng ngữ nghĩa giữa các câu, sau đó chọn các điểm phân đoạn dựa trên một ngưỡng tương đồng. Các câu trong mỗi đoạn thể hiện mức độ gắn kết ngữ nghĩa cao (Xiao et al., 2023).

Ưu điểm:

- Phân đoạn văn bản dựa trên ý nghĩa ngữ cảnh thay vì độ dài.
- Nhóm hiệu quả các câu có liên quan ngữ nghĩa cao.

b, Phân đoạn dạng mệnh đề dày đặc (Dense X Retrieval)

Phương pháp này giới thiệu một cấp độ phân đoạn mới gọi là *mệnh đề*, nơi văn bản được chia thành các đơn vị nhỏ nhất truyền tải thông tin đầy đủ (Chen et al., 2023a). Phương pháp này đặc biệt hiệu quả với nội dung dựa trên sự kiện như Wikipedia nhưng gặp hạn chế với nội dung có tính tuần tự hoặc kể chuyện.

c, LumberChunker

LumberChunker (Duarte et al., 2024) sử dụng khả năng lập luận của các mô hình ngôn ngữ lớn (LLMs) để dự đoán các điểm phân đoạn tối ưu trong văn bản. Tuy nhiên, phương pháp này yêu cầu khả năng làm theo hướng dẫn cao từ các LLM,

dẫn đến chi phí tài nguyên đáng kể khi sử dụng các mô hình như Gemini.

d, Phân đoạn dựa trên lấy mẫu biên (Margin Sampling Chunking - MSP)

Phương pháp này được đề xuất để tối ưu hóa LumberChunker, cải thiện khả năng thích ứng với các mô hình nhỏ hơn. Văn bản được chia thành tập hợp các câu $(x_1, x_2, ..., x_n)$, và các điểm phân đoạn được xác định dựa trên sự chênh lệch xác suất (*Margin*):

$$\text{Margin}_M(x_i) = P_M(y = k_1|\text{Prompt}(x_i, X')) - P_M(y = k_2|\text{Prompt}(x_i, X'))$$

Trong đó:

- k_1, k_2: Quyết định phân đoạn hay không.
- Prompt(x_i, X'): Hướng dẫn giúp mô hình quyết định liệu x_i và X' có nên được gộp lại.

Margin$_M(x_i)$ được so sánh với một ngưỡng θ để quyết định có phân đoạn hay không. Ngưỡng ban đầu được đặt là 0 và điều chỉnh dựa trên trung bình lịch sử của Margin$_M(x_i)$.

3.2.3 Đánh giá tổng quát

Các phương pháp cơ bản cung cấp nền tảng cho việc phân đoạn văn bản, mỗi phương pháp có các điểm mạnh riêng:

- Phân đoạn theo quy tắc đơn giản và nhanh chóng nhưng thiếu khả năng nắm bắt ý nghĩa ngữ nghĩa sâu sắc.
- Phân đoạn động mang lại hiệu quả cao hơn trong việc tổ chức thông tin nhưng đòi hỏi nhiều tài nguyên tính toán hơn.

Những khía cạnh này sẽ được so sánh chi tiết với Meta-Chunking trong các phần tiếp theo.

3.3 Phương pháp RAPTOR

3.3.1 Tổng quan về phương pháp

RAPTOR (Recursive Abstractive Processing for Tree-Organized Retrieval) là một phương pháp tiên tiến trong lĩnh vực tạo sinh tăng cường truy xuất (RAG). Tiếp cận này kết hợp truy xuất thông tin và tạo văn bản bằng cách xây dựng một cấu trúc cây phân cấp đệ quy từ dưới lên.

...

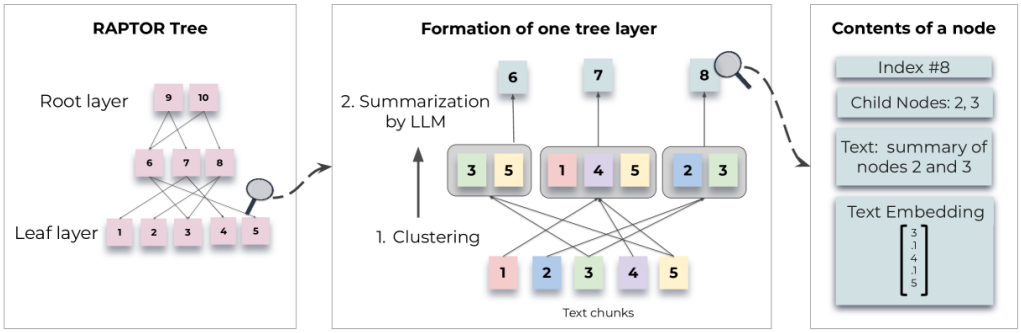

Hình 3.1: RAPTOR (Xử lý Tóm tắt Đệ quy cho Truy xuất Tổ chức Dạng Cây)

CHƯƠNG 4. EXPERIMENTAL EVALUATION

4.1 Thí nghiệm

Trong chương này, tôi trình bày kết quả của RAPTOR như đã thảo luận trong bài báo arXiv 2401.18059v1. Các tác giả đã đánh giá RAPTOR trên ba bộ dữ liệu câu hỏi - trả lời (QA) chính: NarrativeQA, QASPER và QuALITY. Phần này bao gồm mô tả bộ dữ liệu, các phương pháp so sánh, kết quả thí nghiệm, phân tích chi tiết và những phát hiện chính từ các thí nghiệm.

4.1.1 Bộ dữ liệu

Các tác giả đã sử dụng ba bộ dữ liệu QA phổ biến để đánh giá hiệu quả của RAPTOR:

- **NarrativeQA**: Chứa các cặp câu hỏi-trả lời dựa trên toàn bộ sách và kịch bản phim. Bộ dữ liệu này kiểm tra khả năng của mô hình trong việc hiểu và tóm tắt các ngữ cảnh dài.
- **QASPER**: Bao gồm 5.049 câu hỏi được trích xuất từ 1.585 bài báo nghiên cứu NLP. Các câu hỏi yêu cầu tổng hợp thông tin từ nhiều phần khác nhau của bài báo, kiểm tra khả năng truy xuất và hiểu sâu các tài liệu khoa học.
- **QuALITY**: Gồm các câu hỏi trắc nghiệm với độ dài trung bình của ngữ cảnh khoảng 5.000 token. Bộ dữ liệu này tập trung vào các câu hỏi khó (QuALITY-HARD) đòi hỏi suy luận phức tạp và hiểu ngữ cảnh toàn diện.

4.1.2 Phương pháp so sánh

Các tác giả đã so sánh RAPTOR với các phương pháp truy xuất truyền thống như BM25, DPR (Dense Passage Retrieval) và SBERT (Sentence-BERT) trên các bộ dữ liệu. Các mô hình ngôn ngữ được sử dụng trong thí nghiệm bao gồm UnifiedQA, GPT-3 và GPT-4. Để đảm bảo tính công bằng, tất cả các phương pháp so sánh được triển khai với cùng cấu hình truy xuất và các tham số tối ưu.

4.1.3 Kết quả thí nghiệm

a, NarrativeQA

Trên bộ dữ liệu NarrativeQA, RAPTOR kết hợp với UnifiedQA-3B đạt điểm số ROUGE-L, BLEU-1, BLEU-4 và METEOR cao hơn các phương pháp truy xuất truyền thống:

RAPTOR cho thấy cải thiện đáng kể so với các phương pháp truy xuất cơ bản, đặc biệt trong việc nâng cao chất lượng tóm tắt và tạo ra câu trả lời chính xác.

Bảng 4.1: Hiệu suất trên bộ dữ liệu NarrativeQA

Mô hình	ROUGE-L	BLEU-1	BLEU-4	METEOR
SBERT với RAPTOR	30,87%	23,50%	6,42%	19,20%
SBERT không RAPTOR	29,26%	22,56%	5,95%	18,15%
BM25 với RAPTOR	27,93%	21,17%	5,70%	17,03%
BM25 không RAPTOR	23,52%	17,73%	4,65%	13,98%
DPR với RAPTOR	30,94%	23,51%	6,45%	19,05%
DPR không RAPTOR	29,56%	22,84%	6,12%	18,44%

b, QASPER

Trên bộ dữ liệu QASPER, RAPTOR kết hợp với các mô hình ngôn ngữ khác nhau đạt điểm F-1 cao hơn so với BM25 và DPR:

Bảng 4.2: Hiệu suất trên bộ dữ liệu QASPER

Phương pháp truy xuất	GPT-3 F-1	GPT-4 F-1	UnifiedQA F-1
Title + Abstract	25,2	22,2	17,5
BM25	46,6	50,2	26,4
DPR	51,3	53,0	32,1
RAPTOR	53,1	55,7	36,6

RAPTOR không chỉ vượt qua DPR mà còn cải thiện đáng kể điểm F-1, thể hiện khả năng tổng hợp thông tin từ các nguồn khác nhau trong bài báo khoa học.

c, QuALITY

Trên bộ dữ liệu QuALITY, RAPTOR đạt độ chính xác 82,6% khi kết hợp với GPT-4, vượt qua các phương pháp hiện tại:

Bảng 4.3: Hiệu suất trên bộ dữ liệu QuALITY

Mô hình	Độ chính xác
LongT5 XL	53,1%
CoLT5 XL	53,9%
RAPTOR + GPT-4	55,7%

RAPTOR kết hợp với GPT-4 không chỉ cải thiện độ chính xác tổng thể mà còn vượt trội trên tập QuALITY-HARD, nơi các câu hỏi đòi hỏi suy luận phức tạp.

4.1.4 Phân tích kết quả

Kết quả thí nghiệm cho thấy RAPTOR vượt trội hơn các phương pháp truy xuất truyền thống nhờ cấu trúc cây phân cấp. Điều này cho phép mô hình truy xuất thông tin ở nhiều cấp độ trừu tượng, cải thiện độ chính xác và khả năng hiểu toàn diện của câu trả lời.

a, Đóng góp của cấu trúc cây

Phân tích đóng góp của từng lớp trong cấu trúc cây RAPTOR cho thấy việc truy xuất thông tin từ các lớp cao hơn giúp xử lý tốt hơn các câu hỏi yêu cầu hiểu biết tổng quát và suy luận nhiều bước. Các thí nghiệm trên bộ dữ liệu QASPER và QuALITY chỉ ra rằng việc sử dụng toàn bộ cấu trúc cây, thay vì tập trung vào các nút lá, mang lại lợi ích đáng kể về độ chính xác và khả năng truy xuất toàn diện.

b, Chất lượng tóm tắt

Phân tích chất lượng tóm tắt cho thấy RAPTOR duy trì độ chính xác cao trong quá trình tóm tắt, với chỉ khoảng 4% tóm tắt chứa các lỗi nhỏ không đáng kể. Những vấn đề này không ảnh hưởng đáng kể đến kết quả QA, chứng minh rằng quá trình tóm tắt đệ quy của RAPTOR hiệu quả trong việc bảo toàn thông tin quan trọng mà không làm giảm độ tin cậy.

4.1.5 Hiệu quả và khả năng mở rộng

RAPTOR thể hiện khả năng mở rộng tuyệt vời, với thời gian xây dựng và chi phí token tăng tuyến tính theo độ dài tài liệu. Các thí nghiệm trên phần cứng cấp tiêu dùng cho thấy RAPTOR xử lý hiệu quả các bộ dữ liệu lớn mà không làm giảm hiệu suất truy xuất. Điều này chứng minh rằng RAPTOR là một giải pháp khả thi và hiệu quả cho các ứng dụng yêu cầu xử lý thông tin quy mô lớn.

4.1.6 Kết luận thí nghiệm

Các thí nghiệm đã chứng minh rằng RAPTOR không chỉ vượt qua các phương pháp truy xuất truyền thống mà còn thiết lập các tiêu chuẩn mới trên nhiều bộ dữ liệu QA. Cấu trúc cây phân cấp và quá trình tóm tắt đệ quy là các yếu tố chính giúp cải thiện hiệu suất và hiểu các ngữ cảnh dài. Những phát hiện này khẳng định RAPTOR là một phương pháp mạnh mẽ và hiệu quả trong việc tăng cường truy xuất và tạo văn bản.

CHƯƠNG 5. CONCLUSION

5.1 Conclusion

This thesis addressed key challenges in text chunking for RAG systems, evaluating various methods to improve retrieval and generation accuracy. However, some limitations, such as computational costs and optimization for diverse datasets, remain.

5.2 Future Directions

Future work could focus on optimizing chunking techniques for specific domains, improving computational efficiency, and exploring advanced integration of LLMs with retrieval systems for enhanced performance.

NOTES ON REFERENCES

arxiv2024 RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval, *arXiv*, January 31, 2024. Available: https://arxiv.org/html/2401.18059v1.

educative2024 Educative, “Mastering RAG with RAPTOR: A comprehensive guide using LlamaIndex," Available: https://www.educative.io/blog/mastering-rag-with-raptor, accessed September 6, 2024.

medium2024 R. Patekar, “Mastering the 25 Types of RAG Architectures: When and How to Use Each One," Medium, November, 2024. Available: https://medium.com/@rupeshit/mastering-the-25-types-of-rag-architectures-when-and-how-to-use-each-one-2ca0e4b944d7.

langchain2024 LLM Langchain Blogs, “Efficient Information Retrieval RAG for Complex PDFs Using RAPTOR," July 10, 2024. Available: https://www.langchain.ca/blog/efficient-information-retrieval-from-complex-pdfs-using-raptor-rag/.

csdn2024 CSDN Blog, “RAPTOR: RAG," July 4, 2024. Available: https://blog.csdn.net/qq_41739364/article/details/138336034.

deeplearning2024 DeepLearning.AI, “Richer Context for RAG: RAPTOR, a recursive summarizer, captures more relevant context," May 29, 2024. Available: https://www.deeplearning.ai/the-batch/raptor-a-recursive-summarizer-captures-more-relevant-context-for-llm-inputs.

huggingface2024 Hugging Face, “RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval," February 1, 2024. Available: https://huggingface.co/papers/2401.18059.

openreview2024 OpenReview, “RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval," January 16, 2024. Available: https://openreview.net/forum?id=GN921JHCRw.

github2024 GitHub, “RAPTOR: The official implementation of RAPTOR for RAG Systems," Available: https://github.com/profintegra/raptor-rag, accessed October 2024.

bluebash2024 GitHub, “BlueBash/RAG-Raptor-demo," Available: https://github.com/BlueBash/RAG-Raptor-demo, accessed October 2024.

aiengineering2024 AI Engineering Academy, “RAPTOR: Recursive Abstractive Processing for Tree Organized Retrieval," Available: https://aiengineering.academy/RAG/09_RAPTOR/, accessed October 2024.

stanford2024 Stanford University, “Expanding Horizons in RAG: Exploring and Extending the Limits of RAPTOR," Available: https://web.stanford.edu/class/cs224n/final-reports/256925521.pdf, accessed October 2024.

REFERENCES

[1] S. Scott-Hayward, G. O'Callaghan **and** S. Sezer, "Sdn security: A survey," **in***2013 IEEE SDN For Future Networks and Services (SDN4FNS)* IEEE, 2013, **pages** 1–7.

[2] K. Ashton **andothers**, "That 'internet of things' thing," *RFID journal*, **jourvol** 22, **number** 7, **pages** 97–114, 2009.

PHỤ LỤC

A. HƯỚNG DẪN VIẾT ĐATN

A.1 Quy định chung

Dưới đây là một số quy định và hướng dẫn viết đồ án tốt nghiệp mà bắt buộc sinh viên phải đọc kỹ và tuân thủ nghiêm ngặt.

Sinh viên cần đảm bảo tính thống nhất toàn báo cáo (font chữ, căn dòng hai bên, hình ảnh, bảng, margin trang, đánh số trang, v.v.). Để làm được như vậy, sinh viên chỉ cần sử dụng các định dạng theo đúng template ĐATN này. Khi paste nội dung văn bản từ tài liệu khác của mình, sinh viên cần chọn kiểu Copy là "Text Only" để định dạng văn bản của template không bị phá vỡ/vi phạm.

Tuyệt đối cấm sinh viên đạo văn. Sinh viên cần ghi rõ nguồn cho tất cả những gì không tự mình viết/vẽ lên, bao gồm các câu trích dẫn, các hình ảnh, bảng biểu, v.v. Khi bị phát hiện, sinh viên sẽ không được phép bảo vệ ĐATN.

Tất cả các hình vẽ, bảng biểu, công thức, và tài liệu tham khảo trong ĐATN nhất thiết phải được SV giải thích và tham chiếu tới ít nhất một lần. Không chấp nhận các trường hợp sinh viên đưa ra hình ảnh, bảng biểu tùy hứng và không có lời mô tả/giải thích nào.

Sinh viên tuyệt đối không trình bày ĐATN theo kiểu viết ý hoặc gạch đầu dòng. ĐATN không phải là một slide thuyết trình; khi người đọc không hiểu sẽ không có ai giải thích hộ. Sinh viên cần viết thành các đoạn văn và phân tích, diễn giải đầy đủ, rõ ràng. Câu văn cần đúng ngữ pháp, đầy đủ chủ ngữ, vị ngữ và các thành phần câu. Khi thực sự cần liệt kê, sinh viên nên liệt kê theo phong cách khoa học với các ký tự La Mã. Ví dụ, nhiều sinh viên luôn cảm thấy hối hận vì (i) chưa cố gắng hết mình, (ii) chưa sắp xếp thời gian học/chơi một cách hợp lý, (iii) chưa tìm được người yêu để chia sẻ quãng đời sinh viên vất vả, và (iv) viết ĐATN một cách cẩu thả.

Trong một số trường hợp nhất thiết phải dùng các bullet để liệt kê, sinh viên cần thống nhất Style cho toàn bộ các bullet các cấp mà mình sử dụng đến trong báo cáo. Nếu dùng bullet cấp 1 là hình tròn đen, toàn bộ báo cáo cần thống nhất cách dùng như vậy; ví dụ như sau:

- Đây là mục 1 – Thực sự không còn cách nào khác tôi mới dùng đến việc bullet trong báo cáo.
- Đây là mục 2 – Nghĩ lại thì tôi có thể không cần dùng bullet cũng được. Nên tôi sẽ xóa bullet và tổ chức lại hai mục này trong báo cáo của mình cho khoa học hơn. Tôi muốn thầy cô và người đọc cảm nhận được tâm huyết của tôi

trong từng trang báo cáo ĐATN.

A.2 Ngành học

Sinh viên lưu ý viết đúng ngành/chuyên ngành trên bìa và trên gáy theo đúng quy định của Trường. Ngành học hay chuyên ngành học phụ thuộc vào ngành học mà sinh viên đăng ký. Sinh viên có thể đăng nhập trên trang quản lý học tập của mình để xem lại chính xác ngành học của mình.

Một số ví dụ sinh viên có thể tham khảo dưới đây, trong trường hợp có chuyên ngành thì sinh viên không cần ghi chuyên ngành:

- Đối với kỹ sư chính quy:
  - Từ K61 trở về trước: Ngành Kỹ thuật phần mềm
  - Từ K62 trở về sau: Ngành Khoa học máy tính
- Đối với cử nhân:
  - Ngành Công nghệ thông tin
- Đối với chương trình EliteTech:
  - Chương trình Việt Nhật/KSTN: Ngành Công nghệ thông tin
  - Chương trình ICT Global: Ngành Information Technology
  - Chương trình DS&AI: Ngành Khoa học dữ liệu

A.3 Đánh dấu (bullet) và đánh số (numering)

Việc sử dụng danh sách trong LaTeX khá đơn giản và không yêu cầu sinh viên phải thêm bất kỳ gói bổ sung nào. LaTeX cung cấp hai môi trường liệt kê đó là:

- Đánh dấu (bullet) là kiểu liệt kê không có thứ tự. Để sử dụng kiểu liệt kê đánh dấu, chúng ta khai báo như sau
  `\begin{itemize}`
  `\item` Nội dung thứ nhất được viết ở đây.
  `\item` Nội dung thứ hai được viết ở đây.
  `\item` ...
  `\end{itemize}`
- Đánh số (numering) là kiểu liệt kê có thứ tự. Để sử dụng kiểu liệt kê đánh số, chúng ta khai báo như sau
  `\begin{enumerate}`
  `\item` Nội dung thứ nhất được viết ở đây.
  `\item` Nội dung thứ hai được viết ở đây.
  `\item` ...

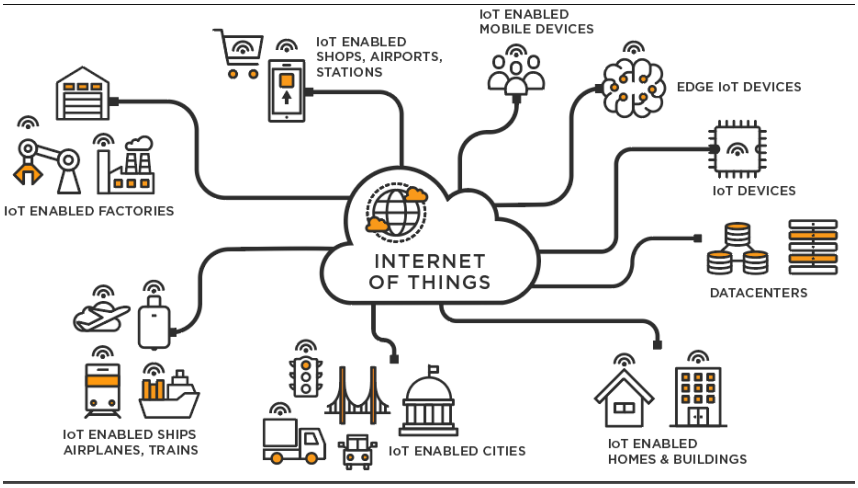

Hình A.1: Internet vạn vật

```
\end{enumerate}
```

Chú ý các nội dung trình bày trong cả hai môi trường liệt kê theo sau lệnh `\item`. Ngoài ra LaTeX còn cung cấp một số kiểu liệt kê khác, sinh viên có thể tham khảo tại `https://www.overleaf.com/learn/latex/Lists`

A.4 Cách thêm bảng

Col1	Col2	Col2	Col3
1	6	87837	787
2	7	78	5415
3	545	778	7507
4	545	18744	7560
5	88	788	6344

Bảng A.1: Table to test captions and labels.

Bảng A.1 là ví dụ về cách tạo bảng. Tất cả các bảng biểu phải được đề cập đến trong phần nội dung và phải được phân tích và bình luận. Chú ý: Tạo bảng trong Latex khá phức tạp và mất thời gian, vì vậy sinh viên có thể sử dụng các công cụ hỗ trợ tạo bảng (Ví dụ: `https://www.tablesgenerator.com/`). Sinh viên có thể tìm hiểu sâu hơn về cách chèn ảnh trong Latex tại link `https://www.overleaf.com/learn/latex/Tables`.

A.5 Chèn hình ảnh

Hình A.1 là ví dụ về cách chèn ảnh. Lưu ý chú thích của hình vẽ được đặt ngay dưới hình vẽ. Sinh viên có thể tìm hiểu sâu hơn về cách chèn ảnh trong Latex tại `https://www.overleaf.com/learn/latex/Inserting_Images`.

Chú ý, tất cả các hình vẽ phải được đề cập đến trong phần nội dung và phải được

phân tích và bình luận.

A.6 Tài liệu tham khảo

Cách liệt kê

Áp dụng cách liệt kê theo quy định của IEEE. Ví dụ của việc trích dẫn như sau [1]. Cụ thể, sinh viên sử dụng lệnh `\cite{}` như sau [2]. Chỉ những tài liệu được trích dẫn thì mới xuất hiện trong phần Tài liệu tham khảo. Tài liệu tham khảo cần có nguồn gốc rõ ràng và phải từ nguồn đáng tin cậy. Hạn chế trích dẫn tài liệu tham khảo từ các website, từ wikipedia.

Các loại tài liệu tham khảo

Các nguồn tài liệu tham khảo chính là sách, bài báo trong các tạp chí, bài báo trong các hội nghị khoa học và các tài liệu tham khảo khác trên internet.

A.7 Cách viết phương trình và công thức toán học

Các gói amsmath, amssymb, amsfonts hỗ trợ viết phương trình/công thức toán học đã được bổ sung sẵn ở phần đầu của file main.tex. Một ví dụ về tạo phương trình (A.1) như sau

$$F(x) = \int_b^a \frac{1}{3}x^3 \tag{A.1}$$

Phương trình A.1 là ví dụ về phương trình tích phân. Một phương trình khác không được đánh số thứ tự (gán nhãn)

$$x[t_n] = \frac{1}{\sqrt{N}} \sum_{k=0}^{N-1} X[f_k] e^{j2\pi nk/N}$$

Phương trình này thể hiện phép biến đổi Fourier rời rạc ngược (IDFT).

A.8 Qui cách đóng quyển

Phần bìa trước chế bản theo qui định; bìa trước và bìa sau là giấy liền khổ. Sử dụng keo nhiệt để dán gáy khi đóng quyển thay vì sử dụng băng dính và dập ghim như mô tả ở Hình A.3 Phần gáy ĐATN cần ghi các thông tin tóm tắt sau: Kỳ làm ĐATN - Ngành đào tạo - Họ và tên sinh viên - Mã số sinh viên. Ví dụ:

2022.1 - KỸ THUẬT MÁY TÍNH - NGUYỄN VĂN A - 20221234

Qui cách ghi chữ phần gáy như hình dưới đây:

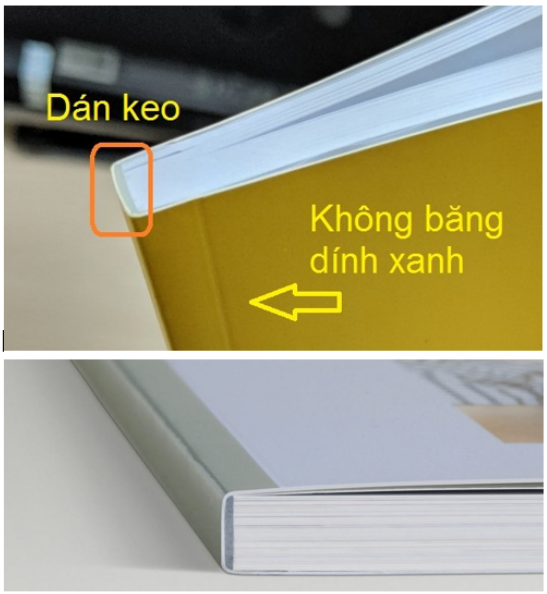

Hình A.2: Qui cách đóng quyển đồ án

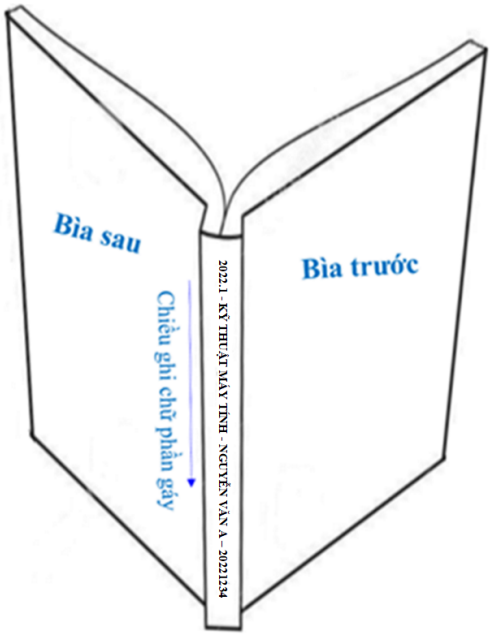

Hình A.3: Qui cách đóng quyển đồ án

B. ĐẶC TẢ USE CASE

Nếu trong nội dung chính không đủ không gian cho các use case khác (ngoài các use case nghiệp vụ chính) thì đặc tả thêm cho các use case đó ở đây.

B.1 Đặc tả use case "Thống kê tình hình mượn sách"

...

B.2 Đặc tả use case "Đăng ký làm thẻ mượn"

...