ĐẠI HỌC BÁCH KHOA HÀ NỘI

ĐỒ ÁN TỐT NGHIỆP

Ứng dụng các mô hình học sâu trong tóm tắt tóm lược đa văn bản tiếng Việt

ĐỖ THÀNH ĐỨC
duc.dt200159@sis.hust.edu.vn

Ngành: Khoa học máy tính

Giảng viên hướng dẫn: PGS.TS. Lê Thanh Hương _____

Chữ kí của GVHD

Khoa: Khoa học máy tính

Trường: Công nghệ Thông tin và Truyền thông

HÀ NỘI, 06/2024

LỜI CẢM ƠN

Có lẽ cuộc đời mỗi người đã dùng những năm trung học để khát khao về một tương lai mới, về những thứ mới mẻ mà tuyệt vời, cả những chân trời tri thức tại đại học, và Bách khoa Hà Nội đã trở thành một nơi tuyệt vời như thế. Khoảng thời gian được học tập và rèn luyện tại nơi đây tuy không dài, nhưng từng đó là đủ để cho một sinh viên có được những ký ức, những kỷ niệm chẳng thể quên đã tô đẹp thêm một bức tranh tuổi trẻ nhiệt huyết. Để có được như ngày hôm nay, trước hết em muốn gửi những tình cảm sâu sắc nhất, tình yêu thương vô hạn đến gia đình, những người thân yêu nhất đã luôn ở bên, đồng hành để em vững bước trên chặng đường đời của mình. Em cũng xin cảm ơn chân thành tới PGS. TS. Lê Thanh Hương đã tận tình hướng dẫn và định hướng giúp em vượt qua những khó khăn, thử thách trong quá trình thực hiện đồ án tốt nghiệp. Đồng thời, em xin bày tỏ lòng biết ơn các thầy cô giảng viên Đại học Bách khoa Hà Nội, đặc biệt là các thầy cô tại trường Công nghệ Thông tin và Truyền thông đã truyền đạt cho em những kiến thức làm hành trang quý giá, giúp đỡ em trong quá trình học tập. “Muốn đi nhanh hãy đi một mình, muốn đi xa hãy đi cùng nhau” câu nói ấy cho bản thân thấu hiểu hơn về tình bạn, những người bạn tốt tại Bách Khoa là niềm vui cũng là kỷ niệm mà em sẽ nhớ mãi. Những trải nghiệm tuyệt vời khi là sinh viên Đại học Bách Khoa Hà Nội sẽ luôn khắc sâu trong tim em, là động lực to lớn để em không ngừng phấn đấu hoàn thiện bản thân và hướng đến một tương lai tươi đẹp.

LỜI CAM KẾT

Họ và tên sinh viên: Đỗ Thành Đức
Điện thoại liên lạc: 0375344524
Email: duc.dt200159@sis.hust.edu.vn
Lớp: Khoa học máy tính 06
Hệ đào tạo: Kỹ sư chính quy

Tôi – *Đỗ Thành Đức* – cam kết Đồ án Tốt nghiệp (ĐATN) là công trình nghiên cứu của bản thân tôi dưới sự hướng dẫn của *PGS.TS. Lê Thanh Hương*. Các kết quả nêu trong ĐATN là trung thực, là thành quả của riêng tôi, không sao chép theo bất kỳ công trình nào khác. Tất cả những tham khảo trong ĐATN – bao gồm hình ảnh, bảng biểu, số liệu, và các câu từ trích dẫn – đều được ghi rõ ràng và đầy đủ nguồn gốc trong danh mục tài liệu tham khảo. Tôi xin hoàn toàn chịu trách nhiệm với dù chỉ một sao chép vi phạm quy chế của nhà trường.

Hà Nội, ngày tháng năm

Tác giả ĐATN

Họ và tên sinh viên

TÓM TẮT NỘI DUNG ĐỒ ÁN

Mặc dù ngày nay ngành trí tuệ nhân tạo đang phát triển vượt bậc đã đáp ứng được nhiều nhu cầu của người dùng. Tuy nhiên, vẫn có những nhiệm vụ khó khăn chưa được giải quyết triệt để, trong đó có bài toán tóm tắt tóm lược đa văn bản đặc biệt đối với ngôn ngữ tiếng Việt với độ dài đầu vào lớn. Đối với bài toán này, những nghiên cứu trước đó tiếp cận chủ yếu theo hướng tóm tắt trích xuất đã có những thành tựu nhưng vẫn gặp phải các vấn đề như dữ liệu dư thừa hoặc đoạn văn sinh ra không được tự nhiên, mạch lạc và các mô hình này yêu cầu lượng tài nguyên lớn và khó khăn khi triển khai. Để giải quyết những vấn đề đã nêu, cùng với sự bùng nổ của các mô hình ngôn ngữ lớn trong xử lý ngôn ngữ tự nhiên, tôi quyết định lựa chọn mô hình ngôn ngữ lớn Vistral-7B-Chat. Đây là mô hình được đào tạo cho ngôn ngữ tiếng Việt dựa trên mô hình gốc là Mistral-7B với khả năng thông hiểu ngôn ngữ, sinh văn bản một cách tự nhiên, đa dạng và dễ dàng. Ban đầu, đồ án tiến hành huấn luyện mô hình với các bộ dữ liệu cần thiết cho bài toán tóm tắt tóm lược đa văn bản tiếng Việt, đồng thời xử lý các đầu vào cho mô hình học tập tốt hơn. Đối với bộ dữ liệu thử nghiệm chính, thực hiện tiền xử lý loại bỏ nhiễu của văn bản, có thể bỏ đi các câu tương đồng, thiết kế đầu vào hợp lý để đưa vào mô hình, đầu ra mô hình tiến hành hậu xử lý phù hợp rồi đánh giá dựa trên độ đo ROUGE. Mô hình đã cho đạt được kết quả vượt trội tính tới thời điểm hiện tại cho tập dữ liệu Abmusu của cuộc thi VLSP 2022.

Sinh viên thực hiện

(Ký và ghi rõ họ tên)

MỤC LỤC

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI 1

1.1 Đặt vấn đề 1

1.2 Các giải pháp hiện tại và hạn chế 2

1.3 Mục tiêu và định hướng giải pháp 3

1.4 Đóng góp của đồ án 4

1.5 Bố cục đồ án 4

CHƯƠNG 2. NỀN TẢNG LÝ THUYẾT 6

2.1 Ngữ cảnh của bài toán 6

2.2 Các kết quả nghiên cứu liên quan 6

2.3 Kiến trúc Transformers 7

2.4 Mô hình ngôn lớn và kỹ thuật huấn luyện 8

2.4.1 Tổng quan mô hình ngôn ngữ lớn 8

2.4.2 Các mô hình ngôn ngữ lớn cho tiếng Việt 10

2.4.3 Mô hình ngôn ngữ lớn trong tóm tắt tóm lược văn bản tiếng Việt 12

2.4.4 Kỹ thuật huấn luyện mô hình ngôn ngữ lớn 13

2.5 Độ đo ROUGE trong đánh giá tóm tắt văn bản 19

CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT 21

3.1 Tổng quan giải pháp 21

3.2 Đề xuất sử dụng mô hình ngôn ngữ lớn Vistral-7B-Chat 21

3.2.1 Mô hình ngôn ngữ lớn Mistral-7B 22

3.2.2 Mô hình ngôn ngữ lớn Vistral-7B-Chat 24

3.2.3 Đề xuất phương pháp giải quyết 25

CHƯƠNG 4. ĐÁNH GIÁ THỰC NGHIỆM 27

4.1 Mục tiêu đánh giá 27

4.2 Tập dữ liệu sử dụng 27
4.2.1 Tập dữ liệu Abmusu 2022 27
4.2.2 Tập dữ liệu ViMS 27
4.2.3 Tập dữ liệu VietnameseMDS 28
4.2.4 Phân tích và sử dụng hợp lý các tập dữ liệu cho mô hình 29
4.3 Tiền xử lý dữ liệu 30
4.4 Cấu hình và công cụ sử dụng 30
4.4.1 Cấu hình sử dụng 30
4.4.2 Các thư viện cài đặt 30
4.5 Các phương pháp huấn luyện 31
4.5.1 Kỹ thuật Intruction Tuning và Prompt Engineering 31
4.5.2 Kỹ thuật QLoRA 32
4.6 Phương pháp thực nghiệm 33
4.6.1 Các baseline cho bài toán 33
4.6.2 Phương pháp đề xuất sử dụng Vistral-7B-Chat 34
4.6.3 Đề xuất mô hình so sánh phù hợp hiện nay 35
4.7 Các siêu tham số 36
4.8 Kết quả mô hình Vistral-7B-chat 36
4.9 Một số quan sát cụ thể 37
CHƯƠNG 5. KẾT LUẬN 39
5.1 Kết luận 39
5.2 Hướng phát triển trong tương lai 39
TÀI LIỆU THAM KHẢO 41

DANH MỤC HÌNH VẼ

Hình 2.1 Cấu trúc bộ mã hóa-giải mã của kiến trúc Transformer [2] . . 8
Hình 2.2 Xếp hạng các mô hình ngôn ngữ lớn trên VMLU [8] 9
Hình 2.3 Huggingface Leaderboard 12
Hình 2.4 Minh họa quá trình thực hiện của Prompt Engineering [6] . . . 15
Hình 2.5 dạng dấu phẩy động 16 bit và 32 bit 16
Hình 2.6 Minh họa Lora 17
Hình 2.7 So sánh các phương pháp[21] 19
Hình 2.8 So sánh Lora và Qlora 19

Hình 3.1 Cơ chế chú ý của sổ trượt (SWA) 23
Hình 3.2 Minh họa RBC 23
Hình 3.3 mô tả Pre-fill và chunking 24
Hình 3.4 Quá trình Intruction Finetuning 25
Hình 3.5 Quá trình đánh giá mô hình 25

DANH MỤC BẢNG BIỂU

Bảng 3.1 Các tham số chính cho kiến trúc mô hình Mistral-7b 22

Bảng 4.1 Thống kê trung bình cho tập Abmusu 28
Bảng 4.2 Chi tiết cấu hình GPU P100 trên Kaggle 30
Bảng 4.3 Các thư viện sử dụng 31
Bảng 4.4 Kết quả các mô hình baseline 33
Bảng 4.5 Hiệu suất của mô hình Vinallama 35
Bảng 4.6 Giá trị của siêu tham số 36
Bảng 4.7 Kết quả mô hình Vistral-7b-Chat 37

DANH MỤC THUẬT NGỮ VÀ TỪ VIẾT TẮT

Thuật ngữ	Ý nghĩa
FFN	Feed-Forward Networks
GPT	Generative Pre-trained Transformer
LCS	chuỗi con chung dài nhất
LLM	mô hình ngôn ngữ lớn
Lora	Low-rank Adaptation
PE	positional embedding
Qlora	Quantization Low-rank Adaptation
RBC	bộ đệm cuộn (Rolling Buffer Cache)
RLHF	học tăng cường từ phản hồi người dùng (Reinforcement Learning from Human Feedback))
ROUGE	độ đo đánh giá sự tương đồng của hai văn bản (Recall-Oriented Understudy for Gisting Evaluation)
SOTA	State-of-the-art
STEM	Science (Khoa học), Technology (Công nghệ), Engineering (Kỹ thuật) và Mathematics (Toán học)
SWA	cơ chế cửa sổ trượt (Sliding Window Attention)
VLSP	câu lạc bộ xử lí Ngôn ngữ và Tiếng nói tiếng Việt (Vietnamese Language and Speech Processing)
VMLU	tiêu chuẩn đánh giá năng lực tiếng việt (Vietnamese Multitask Language Understanding)

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

1.1 Đặt vấn đề

Cùng với sự phát triển vượt bậc của ngành công nghệ thông tin như hiện nay, đó là sự liên tục gia tăng dữ liệu hằng ngày tạo ra lượng thông tin vô cùng lớn đã mang lại những lợi ích cho con người từ học tập đến giải trí. Tuy nhiên, đi cùng với những lợi ích từ lượng thông tin đó mang lại thì người dùng lại gặp phải vấn đề về tìm kiếm, trích xuất và tổng hợp thông tin. Để đáp ứng được những yêu cầu này thì giải pháp được đưa ra đó là tóm tắt văn bản tự động. Đây là quá trình sử dụng các kỹ thuật xử lý ngôn ngữ tự nhiên (Natural Language Processing) và kiến thức liên quan để tạo ra một phiên bản ngắn gọn hơn từ văn bản gốc mà vẫn giữ được thông tin quan trọng và đảm bảo tính mạch lạc, nhất quán giúp tiết kiệm thời gian, giúp con người tiếp cận và xử lý thông tin hiệu quả hơn trong thời đại ngày nay.

Bài toán tóm tắt văn bản là nhiệm vụ trong xử lý ngôn ngữ tự nhiên giúp người dùng có thể nắm bắt được những thông tin chính mà không cần phải đọc toàn bộ văn bản. Quá trình này nhằm rút ngắn văn bản một cách cô đọng nhất, nắm bắt được các thông tin quan trọng đồng thời vẫn đảm bảo được văn bản tóm tắt tự nhiên, mạch lạc. Bài toán không chỉ là một hướng nghiên cứu mà nó còn áp dụng vào trong đời sống khi cần tóm tắt nội dung bài báo, câu chuyện, tin tức hằng ngày hay tài liệu khoa học... Việc thực hiện tóm tắt văn bản cho người dùng góp phần tiết kiệm thời gian khi phải đọc những văn bản dài, tăng năng suất làm việc, có thể nắm bắt được nhiều thông tin, nâng cao đời sống bản thân.

Giải quyết bài toán tóm tắt văn bản cũng chính là giải quyết vấn đề tóm tắt cho một hoặc nhiều văn bản cùng lúc được gọi là tóm tắt đơn văn bản và tóm tắt đa văn bản. Bài toán tóm tắt đơn văn bản có đầu vào là một văn bản có thể là một bài báo hoặc tin tức, còn tóm tắt đa văn bản thực hiện tóm tắt trên một cụm gồm các văn bản khác nhau từ nhiều nguồn tin. Hầu hết các phương pháp hiện nay thực hiện trên các văn bản ngắn cho đơn văn bản, nhưng trong cuộc sống thì một chủ đề có thể có nhiều thông tin khác nhau được viết trên các bài báo khác nhau và đều quan trọng như nhau, đó là một vấn đề cần nghiên cứu, giải quyết nhằm đưa ra những phương pháp tóm tắt tối ưu và hiệu quả, đồng thời cần đảm bảo việc sinh nhanh chóng, chính xác, đáp ứng được các yêu cầu đặt ra. Quá trình giải quyết bài toán này đóng vai trò quan trọng trong lĩnh vực xử lý ngôn ngữ tự nhiên có thể giúp ích cho đời sống con người khi lượng dữ liệu ngày càng bùng nổ hiện nay, đây sẽ là một hướng phát triển và nghiên cứu quan trọng có thể là nguồn cảm hứng cho các nghiên cứu mới. Với những lý do nêu ra tôi quyết định lựa chọn đề tài tóm tắt tóm

lược đa văn bản tiếng Việt cho đồ án tốt nghiệp của mình.

1.2 Các giải pháp hiện tại và hạn chế

Hiện nay, để giải quyết bài toán tóm tắt đa văn bản tiếng Việt thường có hai hướng chính sử dụng đó là tóm tắt trích rút và tóm tắt tóm lược, ngoài ra còn có thể kết hợp cả hai phương pháp lại với nhau. Mục đích chính của các phương pháp là tạo ra được bản tóm tắt chất lượng đáp ứng được yêu cầu đề tài. Để có thể chọn được một phương pháp phù hợp, tôi đã khảo sát đánh giá các phương pháp này khách quan, đồng thời có cái nhìn chi tiết rõ ràng, biết được điểm mạnh và hạn chế của chúng.

Tóm tắt trích rút là một phương pháp tạo bản tóm tắt từ văn bản gốc bằng cách chọn lọc những câu có tính quan trọng và ý nghĩa cao. Phương pháp này không tạo ra nội dung mới mà chỉ sử dụng các câu hiện có và ghép chúng lại trong bản tóm tắt. Quá trình này bao gồm các bước: tiền xử lý dữ liệu, xếp hạng các câu theo mức độ quan trọng và thông tin, và cuối cùng là trích rút các câu quan trọng nhất, sắp xếp chúng theo thứ tự tối ưu. Ưu điểm của phương pháp tóm tắt trích rút là dễ thực hiện và duy trì thông tin gốc. Tuy nhiên, nó cũng có nhược điểm như không tạo ra câu mới, có thể bao gồm thông tin không cần thiết hoặc bỏ sót thông tin quan trọng nằm giữa các câu trích rút. Điều này có thể làm cho bản tóm tắt thiếu mạch lạc và khó hiểu nếu các câu không được nối tiếp hợp lý và logic.

Tóm tắt tóm lược tiếp cận khác biệt so với tóm tắt trích rút, bằng cách tạo ra các câu hoặc đoạn văn mới từ văn bản gốc thay vì chỉ trích xuất lại. Phương pháp này sử dụng các kỹ thuật xử lý ngôn ngữ tự nhiên (NLP) tiên tiến, bao gồm các thuật toán học máy, học sâu tổng hợp và tái cấu trúc thông tin từ văn bản gốc một cách tổng quát và tự nhiên, giúp người đọc dễ hiểu hơn. Quá trình tóm tắt tóm lược bao gồm: tiền xử lý dữ liệu, phân tích và hiểu nội dung văn bản để đưa ra mô hình tóm tắt phù hợp, sau đó tạo ra các câu hoặc đoạn văn mới sử dụng mô hình này. Ưu điểm của phương pháp này là khả năng tạo ra câu văn mới có tính ngữ nghĩa cao, văn phong tự nhiên, giúp người đọc dễ hiểu hơn và tạo ra bản tóm tắt mượt mà nhờ các câu văn logic và liên kết chặt chẽ. Tuy nhiên, các mô hình tóm tắt tóm lược đôi khi có thể tạo ra câu văn không liên quan. Hơn nữa, triển khai phương pháp này phức tạp hơn tóm tắt trích rút, đòi hỏi phát triển và tối ưu các mô hình NLP, học máy, học sâu, cũng như yêu cầu phần cứng mạnh như RAM và GPU.

Với sự phát triển của các mô hình ngôn ngữ lớn như hiện nay được đào tạo với lượng dữ liệu khổng lồ, đảm bảo sự thông hiểu mạch lạc của ngôn ngữ đáp ứng được các yêu cầu với nhiều tác vụ khác nhau nên tôi quyết định chọn phương pháp này để áp dụng cho bài toán tóm tắt tóm lược đa văn bản tiếng Việt. Phương pháp

cho cái nhìn tổng quan về sự phát triển của mô hình ngôn ngữ lớn đồng thời xem xét khả năng giải quyết bài toán trong việc xây dựng mô hình từ đó có thể tạo ra một bản tóm tắt chất lượng tốt nhất. Phương pháp này vẫn sử dụng các bước như tiền xử lý văn bản rồi tiến hành đánh giá mô hình đã được huấn luyện, sau đó tối ưu hóa mô hình. Mô hình cho phép nắm bắt đầy đủ thông tin của văn bản gốc tạo ra bản tóm tắt đầy đủ, chính xác và mạch lạc, tận dụng ưu điểm của các mô hình ngôn ngữ hiện nay, điều này giúp người đọc hiểu rõ hơn và tiếp cận tốt hơn với một văn bản. Tuy nhiên, phương pháp vẫn cần phải điều chỉnh dữ liệu cẩn thận, tỉ mỉ phù hợp với mô hình đề xuất. Quá trình xây dựng mô hình cũng đòi hỏi khả năng của bản thân thiết kế mô hình hợp lý, đảm bảo mô hình hoạt động tốt nhất tránh được các nhược điểm không cần thiết nhưng vẫn phải đảm bảo tính đa dạng, đầy đủ và mạch lạc.

1.3 Mục tiêu và định hướng giải pháp

Do những hạn chế của phương pháp tóm tắt trích rút như thiếu mạch lạc, thiếu nhất quán, khả năng bỏ sót thông tin, cũng như những hạn chế của phương pháp tóm tắt tóm lược trước đây bao gồm tính phức tạp, mô hình chưa đủ tốt và hạn chế tài nguyên, mục tiêu của đồ án là phát triển các mô hình tóm tắt tóm lược đa văn bản tiếng Việt với độ chính xác cao nhưng đòi hỏi ít tài nguyên và bộ nhớ hơn. Điều này sẽ được thực hiện bằng cách áp dụng các kiến thức và kỹ năng trong lĩnh vực xử lý ngôn ngữ tự nhiên đòi hỏi khả năng nắm bắt thông tin quan trọng từ các cụm văn bản có độ dài và mức độ phức tạp lớn, từ đó tạo ra các bản tóm tắt ngắn gọn và đáng tin cậy. Đồ án còn đặt mục tiêu đánh giá và so sánh kết quả của giải pháp đề xuất với các phương pháp tiên tiến hiện nay. Các thử nghiệm sẽ được thực hiện trên cùng một tập dữ liệu thực tế và đánh giá trên một độ đo cụ thể cũng như các khía cạnh khác như thời gian và tài nguyên bộ nhớ sử dụng. Ngoài ra, đồ án cũng sẽ nghiên cứu các cách tối ưu hóa mô hình để giảm yêu cầu về tài nguyên mà vẫn duy trì được độ chính xác cao. Điều này bao gồm việc sử dụng các kỹ thuật tiên tiến trong học máy và học sâu, cũng như các phương pháp tối ưu hóa khác trong xử lý ngôn ngữ tự nhiên. Các kết quả đạt được từ quá trình nghiên cứu và thử nghiệm sẽ cung cấp cái nhìn sâu sắc về hiệu suất của các mô hình, từ đó đề xuất các cải tiến và ứng dụng thực tế trong việc tóm tắt văn bản tự động.

Giải pháp của đồ án là lựa chọn và huấn luyện mô hình ngôn ngữ lớn có khả năng hiểu và thích ứng tốt với ngôn ngữ, hiệu quả trong các nhiệm vụ sequence-to-sequence hiện nay. Quá trình này bao gồm đưa văn bản có độ dài đầu vào lớn vào mô hình, sau đó huấn luyện và tối ưu hóa tham số. Tuy nhiên, để giảm thiểu tài nguyên bộ nhớ và thời gian cần thiết cho huấn luyện, giải pháp đã được điều chỉnh bằng cách thực hiện tiền xử lý hiệu quả loại bỏ nhiễu không cần thiết, áp dụng các

kỹ thuật xử lý và huấn luyện cho mô hình ngôn ngữ lớn tiết kiệm tài nguyên và thời gian trong khi vẫn duy trì độ chính xác cao. Cách tiếp cận này không chỉ tối ưu hóa quá trình huấn luyện mà còn nâng cao hiệu suất tổng thể của mô hình tóm tắt. Các phương pháp huấn luyện thiết kế giúp tăng cường khả năng thông hiểu nhiệm vụ giúp cho mô hình hoạt động tốt nhất giảm thiểu sự lặp lại và tăng tính mạch lạc cho bản tóm tắt cuối cùng.

Với mục tiêu đặt ra và giải pháp khả thi, đồ án sẽ xây dựng mô hình có thể tạo ra các bản tóm tắt ngắn gọn, dễ hiểu và chính xác hơn, đồng thời giảm yêu cầu về tài nguyên và thời gian huấn luyện. Hơn nữa, đồ án cũng bao gồm việc tối ưu hóa tham số và cấu trúc của mô hình để đảm bảo hiệu quả trên các hệ thống có tài nguyên hạn chế, phát triển giải pháp tóm tắt tóm lược đa văn bản tiếng Việt tự động hiệu quả, tiết kiệm và đáng tin cậy, đưa ra những đánh giá chi tiết, so sánh sự hiệu quả cho mô hình.

1.4 Đóng góp của đồ án

Những đóng góp chính trong việc thực hiện đồ án:

1. Đồ án sử dụng hiệu quả phương pháp tóm tắt tóm lược đa văn bản tiếng Việt, huấn luyện mô hình ngôn ngữ lớn Vistral-7B-Chat đạt kết quả chính xác và ổn định.
2. Giải quyết vấn đề của mô hình ngôn ngữ lớn khi chạy trên tài nguyên thiết bị hạn chế.
3. Đồ án đã xây dựng phương pháp phù hợp cho đầu ra ngắn gọn, hợp lý, kết quả đạt được vượt trội hơn so với các phương pháp trước khi đánh giá trên tập dữ liệu cụ thể.

1.5 Bố cục đồ án

Bố cục của đồ án này là sự tổng hợp cho quá trình tìm hiểu, đánh giá và thực nghiệm bao gồm 5 chương như sau:

- CHƯƠNG 1 giới thiệu tổng quan cho nhiệm vụ đặt ra của bài toán tóm tắt tóm lược đa văn bản tiếng Việt. Tìm hiểu những phương pháp nghiên cứu để giải quyết bài toán đồng thời phân tích những ưu điểm và nhược điểm, từ đó đưa ra phương pháp sử dụng hợp lý.
- CHƯƠNG 2 trình bày về những nền tảng lý thuyết cần thiết cho bài toán, đưa ra các nghiên cứu liên quan, và các kỹ thuật hiện nay sử dụng trong kiến trúc của Transformer hay các mô hình ngôn ngữ lớn. Đồng thời, phần này cũng trình bày độ đo ROUGE phù hợp cho việc đánh giá của bài toán.

- CHƯƠNG 3 nêu ra phương hướng khả thi để giải quyết nhiệm vụ sau quá trình tìm hiểu, đánh giá các phương pháp và các kết quả nghiên cứu. Đề xuất phương pháp sử dụng mô hình ngôn ngữ lớn Vistral-7B-Chat.
- CHƯƠNG 4 trình bày đánh giá thực nghiệm cho mô hình. Trong nội dung chương này đưa ra các baseline và các cấu hình đã sử dụng. Trong đó, bằng việc áp dụng những kỹ thuật, thiết lập tham số, từ đó đánh giá khách quan cho kết quả mô hình đạt được.
- CHƯƠNG 5 đưa ra kết luận cho quá trình tìm hiểu, xây dựng và đánh giá mô hình, đồng thời nêu lên các định hướng phát triển trong tương lai.

CHƯƠNG 2. NỀN TẢNG LÝ THUYẾT

2.1 Ngữ cảnh của bài toán

Bài toán tóm tắt đa văn bản tiếng Việt có nhiều cách tiếp cận khác nhau tùy thuộc vào mục tiêu và khả năng của hệ thống, nhưng thường sử dụng hai cách tiếp cận chính là tóm tắt trích rút và tóm tắt tóm lược. Nếu như tóm tắt trích rút tập trung vào việc chọn ra những câu quan trọng trong văn bản gốc để tạo ra một bản tóm tắt, thì tóm tắt tóm lược tạo ra các câu mới dựa trên nội dung và ý nghĩa của văn bản gốc, cố gắng diễn đạt như con người để tạo nên một bản tóm tắt.

Phương pháp tóm tắt trích rút được thực hiện một cách đơn giản, nhanh chóng và đảm bảo giữ nguyên văn phong và ngữ nghĩa của văn bản gốc. Do phương pháp này chỉ đơn giản chọn các câu từ văn bản gốc và có số điểm cao nhất nên khi kết hợp các câu có thể không được diễn đạt một cách tự nhiên, mạch lạc hoặc có thể bỏ sót các thông tin quan trọng. Nhìn chung, đây vẫn là một phương pháp hữu ích, hiệu quả trong nhiều tình huống, có thể áp dụng cho nhiều loại ngôn ngữ khác nhau mà không cần điều chỉnh nhiều.

Bên cạnh đó, phương pháp tóm tắt tóm lược tạo ra các bản tóm tắt bằng cách sinh ra các câu mới, tóm tắt ý nghĩa chính của văn bản gốc một cách mạch lạc và có thể bao quát được nội dung rộng hơn. Bản tóm tắt được tạo ra từ phương pháp này được trình bày tự nhiên, mới mẻ mà vẫn duy trì tính nhất quán và nội dung của văn bản gốc không bị giới hạn bởi cấu trúc câu trong văn bản gốc. Tuy nhiên, cần khắc phục vấn đề của các mô hình sinh khi thông tin tạo ra có thể không chính xác hoặc sai lệch nếu không được huấn luyện tốt. Nhìn chung đây là một phương pháp mạnh mẽ trong xử lý ngôn ngữ tự nhiên, hướng đến mục tiêu tạo ra các văn bản tóm tắt như con người mang lại lợi ích lớn cho việc quản lý thông tin và xử lý văn bản trong nhiều ứng dụng thực tiễn.

Ngoài ra, cũng có thể kết hợp sử dụng cả tóm tắt trích rút và tóm tắt tóm lược để giúp cho mô hình có thể xử lý thông tin nhanh hơn, giảm độ phức tạp tính toán đồng thời có thể khắc phục nhược điểm của từng phương pháp.

2.2 Các kết quả nghiên cứu liên quan

Cùng với sự phát triển của ngành trí tuệ nhân tạo thì các phương pháp tóm tắt truyền thống chỉ dựa vào việc xếp hạng độ quan trọng các câu trong văn bản để tạo ra bản tóm tắt đã không thể đáp ứng được yêu cầu đặt ra hiện nay mà thay vào đó là sự ra đời một số cách mới như sử dụng đồ thị tri thức hay các mô hình seq2seq [1], Transformer [2] để tạo văn bản mới. Phương pháp tóm tắt sử dụng đồ thị tri thức

biểu diễn các khái niệm trong văn bản từ đó tạo ra bản tóm tắt chính xác, mạch lạc hơn. Tuy nhiên, phương pháp này đòi hỏi phải xây dựng được một đồ thị tri thức chất lượng cao và có sự phức tạp hơn nhiều cả trong quá trình sử dụng so với phương pháp truyền thống. Bên cạnh đó, các mô hình dựa trên transformer đã tạo ra các văn bản tự nhiên hơn mặc dù việc xử lý đoạn văn đầu vào dài hay xử lý ngữ cảnh cho đầu vào đó chưa thực sự tốt. Nhưng với sự phát triển không ngừng của các mô hình hiện nay đã mang lại hiệu quả cao và khả năng thích ứng rộng rãi. Để đáp ứng được các yêu cầu đặt ra cho bài toán, việc sử dụng một mô hình ngôn ngữ lớn được đào tạo với lượng tri thức khổng lồ sẽ là một phương hướng thực tế và tích cực đối với bài toán tóm tắt tóm lược đa văn bản tiếng Việt.

2.3 Kiến trúc Transformers

Để hiểu hơn bài toán, trước hết tôi sẽ trình bày về kiến trúc Transformer [2], đây là cơ sở cho các mô hình ngôn ngữ hiện nay.

Mô hình là sự kết hợp ưu điểm của các mạng sâu như mạng nơ ron tích chập (Convolutional Neural Network [3]) và mạng nơ ron hồi tiếp (Recurent Neural Network [4]). Đây là một kiến trúc song song học chuỗi hồi tiếp với cơ chế tập trung đồng thời mã hóa vị trí của từng phần tử trong chuỗi.

Transformer dựa trên kiến trúc encoder-decoder [5] (mã hóa – giải mã). Tuy nhiên, nó thay thế các tầng hồi tiếp trong seq2seq bằng các tầng tập trung đa đầu (multi-head attention), kết hợp thông tin vị trí thông qua biểu diễn vị trí (positional encoding) và áp dụng chuẩn hóa tầng (layer normalization).

Các embedding của chuỗi nguồn được đưa vào n khối lặp lại. Đầu ra của khối mã hóa cuối cùng sau đó được sử dụng làm bộ nhớ tập trung cho bộ giải mã. Tương tự, các embedding của chuỗi đích được đưa vào n khối lặp lại trong bộ giải mã. Ta thu được đầu ra cuối cùng bằng cách áp dụng một tầng dày đặc có kích thước bằng kích thước bộ từ vựng lên các đầu ra của khối giải mã cuối cùng.

Kiến trúc của transformer gồm 2 phần chính là encoders(là 1 ngăn xếp gồm 6 khối encoder kiến trúc giống nhau) và decoders(là 1 ngăn xếp gồm 6 khối decoder giống nhau). Với mỗi khối encoder có 2 layer chính: self-attention và feed forward. Còn mỗi khối decoder có 3 layer chính: sef-attention, encoder-decoder attention và feed forward.

Kiến trúc Transformers ra đời đã khắc phục được các hạn chế của mạng nơ-ron hồi quy nhờ vào cơ chế chú ý (Attention), cho phép xử lý thông tin từ xa một cách hiệu quả. Điều này đã đặt nền tảng quan trọng cho sự phát triển của các mô hình ngôn ngữ lớn hiện nay như GPT, Llama hay Mistral, dẫn đến những bước tiến đột

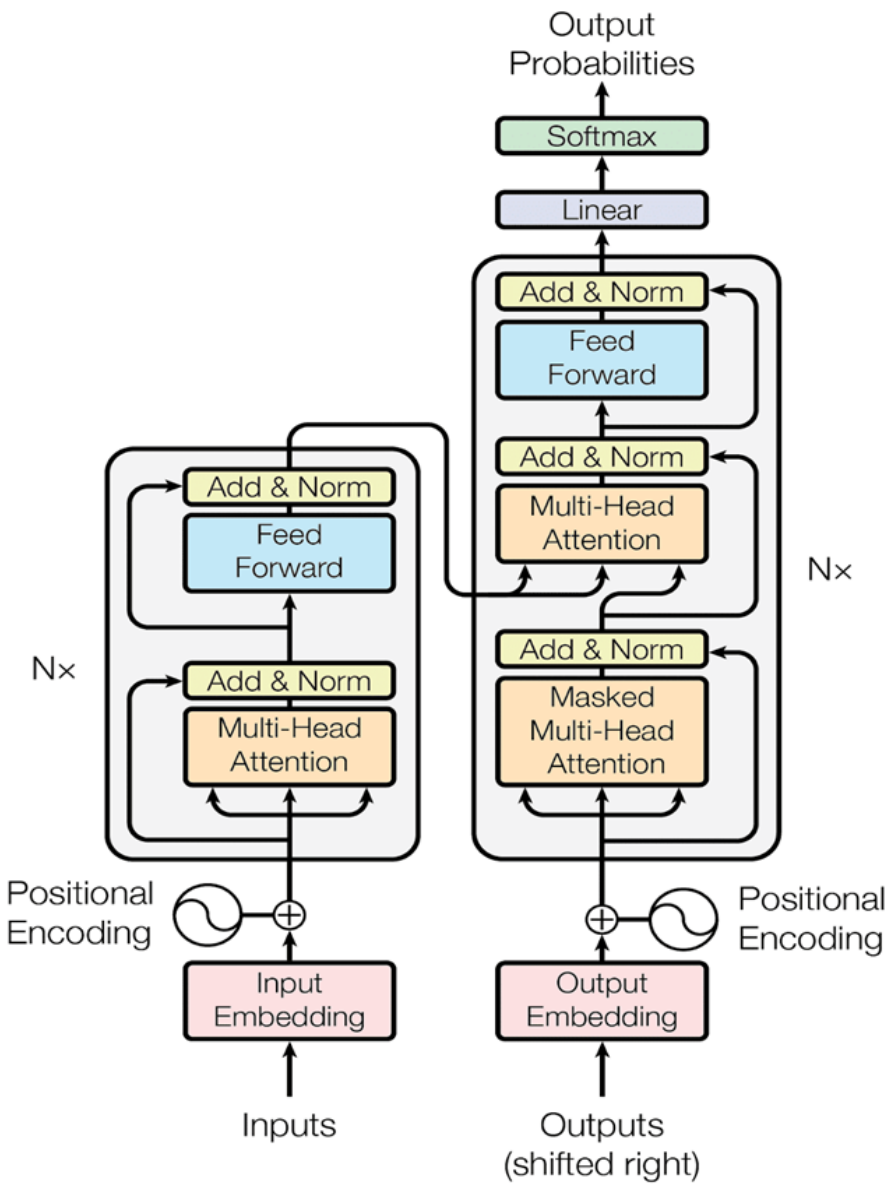

Hình 2.1: Cấu trúc bộ mã hóa-giải mã của kiến trúc Transformer [2]

phá trong lĩnh vực xử lý ngôn ngữ tự nhiên. Nhờ khả năng nắm bắt ngữ cảnh và mối quan hệ giữa các từ trong văn bản một cách tốt hơn, Transformers đã mở ra những cơ hội mới cho việc tạo ra các hệ thống ngôn ngữ mạnh mẽ và chính xác hơn, từ dịch máy đến tổng hợp văn bản và nhiều ứng dụng khác.

2.4 Mô hình ngôn lớn và kỹ thuật huấn luyện

2.4.1 Tổng quan mô hình ngôn ngữ lớn

Dựa trên kiến trúc Transformer, các mô hình ngôn ngữ hiện nay đang đạt được những thành tựu đáng kể và vượt bậc hơn so với các mô hình trước đó với nhiều tác vụ khác nhau trong xử lý ngôn ngữ tự nhiên. Hiện nay, xu hướng nổi bật được thực hiện trong lĩnh vực này là việc phát triển các mô hình ngôn ngữ lớn (Large

Language Models) - đây là những mô hình máy học được huấn luyện trên lượng thông tin khổng lồ để hiểu và tạo ra văn bản tự động với kiến trúc phức tạp nhưng lại dễ dàng sử dụng và đạt hiệu quả cao.

Với Transformer, kiến trúc này cho phép đào tạo trước (pre-train) các mô hình BERT, GPT bằng việc sử dụng các dữ liệu rất lớn và không giám sát, cùng với đó là sự ra đời của mô hình nền tảng như RoBERTa, T5 và BART. Nổi bật lên là GPT-3 (Generative Pre-trained Transformer) của OpenAI thể hiện khả năng học tập thông qua prompt engineering[6] và in-context learning[7]. Ngay sau đó là sự tiến bộ đáng kể của ChatGPT và GPT-4 đã đóng góp lớn cho mô hình ngôn ngữ và cả lĩnh vực trí tuệ nhân tạo. Sự phát triển này cũng kéo theo sự gia tăng của các LLM mới như Llama-2, Bloom, Falcon hay Mistral.

Các mô hình ngôn ngữ lớn không bao gồm chỉ dùng trong một ngôn ngữ cụ thể mà mục tiêu hướng tới là giải quyết được đa ngôn ngữ cũng như đa tác vụ. Không chỉ đối với ngôn ngữ tiếng Anh mà các mô hình này đang được đánh giá rất cao cho tiếng Việt. Cụ thể các mô hình từ đầu khi chưa huấn luyện với các nhiệm vụ cụ thể đã đạt các kết quả vượt trội trên bảng xếp hạng VMLU[8], đây là một khuôn khổ tin cậy để đánh giá các mô hình ngôn ngữ lớn bằng tiếng Việt với các nhiệm vụ khác nhau như STEM, khoa học xã hội,. . ..

Leaderboard of from-scratch models

#	MODEL	CREATOR	ACCESS	EVALUATION DATE	STEM	SOCIAL SCIENCE	HUMANITIES	OTHERS	AVG
1	Llama-3-70B	Meta	Weight	23/04/2024	61.7	74.91	68.74	63.53	66.44
2	GPT-4	OpenAI	API	08/01/2024	63.84	71.78	66.14	60.37	65.53
3	KiLM-13b-v24.4.2	Zalo AI	Private	30/04/2024	54.58	72.09	70.75	60.2	63.49
4	gemini	Google	API	30/01/2024	42.8	60.31	55.35	51.30	51.03
5	ChatGPT	OpenAI	API	08/01/2024	43.24	51.67	46.96	46.32	46.33
6	ViGPT-1.6B-v1	Vin BigData	Private	08/01/2024	35.06	48.72	47.20	42.54	42.34
7	gemma-7b-it	Google	Weight	22/02/2024	39.95	44.93	43.39	40.11	41.9
8	Qwen-7B	Alibaba Cloud	Weight	08/01/2024	30.64	35.07	34.15	32.68	32.81
9	gemma-2b-it	Google	Weight	22/02/2024	24.39	29.59	31.01	26.81	27.72

Hình 2.2: Xếp hạng các mô hình ngôn ngữ lớn trên VMLU [8]

Từ bảng xếp hạng nhận thấy sự vượt trội của các mô hình ngôn ngữ lớn, các mô hình càng được huấn luyện nhiều với dữ liệu và bộ tham số nhiều thì càng đạt kết quả cao như Llama 3-70B hay GPT 4. Tuy nhiên, một số mô hình chỉ cho truy cập vào API hoặc chỉ được truy cập riêng tư nên việc lựa chọn mô hình trọng số là hợp lý. Các mô hình này không có những kết quả vượt trội nhưng vẫn là các mô hình

tiềm năng, cho phép mỗi người có thể truy cập, huấn luyện theo từng nhiệm vụ cụ thể đáp ứng yêu cầu của bản thân.

Với khả năng học hỏi từ lượng lớn dữ liệu văn bản và xử lý ngôn ngữ tự nhiên một cách hiệu quả, LLM mang đến nhiều tiềm năng ứng dụng trong các lĩnh vực như dịch thuật tự động, tóm tắt văn bản, chatbot, và thậm chí cả sáng tác nội dung sáng tạo.Điểm nổi bật của LLM nằm ở hai giai đoạn phát triển: Huấn luyện trước (pre-trained) và tinh chỉnh (fine-tuned). Ở giai đoạn đầu, LLM được đào tạo bằng một kho dữ liệu khổng lồ gồm văn bản và mã, giúp chúng hình thành kiến thức nền tảng vững chắc về ngôn ngữ. Sau đó, LLM được "chuyên môn hóa" cho từng nhiệm vụ cụ thể, ví dụ như dịch tiếng Anh sang tiếng Việt hay viết tóm tắt văn bản.Nhờ quy mô lớn và khả năng học tập linh hoạt, LLM đang dần trở thành công cụ không thể thiếu trong lĩnh vực trí tuệ nhân tạo. Chúng mở ra cánh cửa cho những ứng dụng sáng tạo và hiệu quả hơn, góp phần thúc đẩy sự phát triển của xã hội trong tương lai.

2.4.2 Các mô hình ngôn ngữ lớn cho tiếng Việt

Các mô hình ngôn ngữ lớn (LLM) đã chứng kiến sự tiến bộ đáng kể trong trí tuệ nhân tạo và đặc biệt là trong xử lý ngôn ngữ tự nhiên tại Việt Nam. Khi đó, hàng loạt các LLMs hướng đến người dùng Việt được ra đời như Vietcuna, PhoGPT, Bloomz... Để có thể lựa chọn phương pháp giải quyết phù hợp, tôi đã tìm hiểu một số các mô hình ngôn ngữ lớn áp dụng cho tiếng Việt từ đó đưa ra phương pháp cụ thể cho bài toán tóm tắt tóm lược đa văn bản tiếng Việt.

a, VinaLLaMA

Đây là một LLMS nền tảng thiết kế cho tiếng Việt, được xây dựng dựa trên LLaMA - 2[9] với 7 tỷ tham số là một mô hình hướng tới sự toàn diện về ngôn ngữ trong trí tuệ nhân tạo, đáp ứng được vấn đề về cú pháp và ngữ nghĩa trong tiếng Việt. Mô hình LLaMA-2 cho thấy lỗ hổng khi xử lý nhiệm vụ đối với tiếng Việt, nên các nhà nghiên cứu đã sử dụng các bộ dữ liệu, huấn luyện và điều chỉnh nhằm thiết kế phù hợp cho người Việt Nam.

Quá trình đào tạo trươc (pre-training), mô hình sử dụng Tokenizer của BKAI's LLaMA-2-chat với hiệu suất tốt trong xử lý ngôn ngữ. Bộ dữ liệu huấn luyện gồm: Dữ liệu công khai: 250,000 cuốn sách tiếng Việt thuộc nhiều lĩnh vực (khoa học, lịch sử, tài chính, triết học, tiểu thuyết và khoa học viễn tưởng) và các bài báo từ VnExpress và BaoMoi. Dữ liệu công khai này tổng cộng khoảng 330 tỷ tokens. Dữ liệu nội bộ: Sử dụng các đoạn văn bản ngẫu nhiên từ các tập dữ liệu công khai, tích hợp vào hơn 80 mẫu prompt riêng biệt được thiết kế cho nhiệm vụ viết lại. Phương pháp này tạo ra khoảng 100,000 mẫu tổng hợp chất lượng cao, đặc biệt

dành cho mục đích đào tạo trước. Từ đó tạo nên bộ dữ liệu toàn diện, sử dụng kỹ thuật Supervised Instruction Fine-tuning[10] huấn luyện mô hình xử lý các tác vụ lý luận, mã hóa, tóm tắt văn bản, làm văn, viết thơ,...

VinaLLaMA[11] đánh dấu một bước ngoặt quan trọng trong lĩnh vực mô hình ngôn ngữ, đặc biệt là trong xử lý ngôn ngữ tiếng Việt. VinaLLaMA đạt được điểm số cao nhất trên các tiêu chuẩn đánh giá tiếng Việt, chứng tỏ được năng lực và khả năng thích ứng cho ngôn ngữ tiếng Việt. Mô hình này đã đặt ra chuẩn mực mới cho các mô hình ngôn ngữ tiếng việt mở đường cho những tiến bộ trong tương lai. Trong đồ án này, tôi cũng sử dụng VinaLLaMA làm tiêu chuẩn so sánh để xem sự vượt trội trong phương pháp đề xuất của bản thân.

b, PhoGPT

Là một mô hình ngôn ngữ lớn (LLM) mở rộng dành riêng cho tiếng Việt, bao gồm PhoGPT-4B[12] và biến thể chat của nó, PhoGPT-4B-Chat. Mô hình cơ sở PhoGPT-4B có 3.7 tỷ tham số, được huấn luyện trên 102 tỷ token từ một kho ngữ liệu tiếng Việt. Biến thể chat, PhoGPT-4B-Chat, được tinh chỉnh từ PhoGPT-4B bằng cách sử dụng 70.000 mẫu hướng dẫn và 290.000 cuộc trò chuyện bổ sung. PhoGPT-4B-Chat đã thể hiện hiệu suất vượt trội so với các mô hình nguồn mở trước đó.

PhoGPT-4B là một mô hình sử dụng kiến trúc Transformer decoder-based sử dụng Flash Attention (Triton) để cải thiện hiệu suất và ALiBi (Attention with Linear Biases) cho phép mở rộng độ dài ngữ cảnh. Tokenizer: Sử dụng bộ mã hóa byte-level BPE (Byte Pair Encoding [13]) dành riêng cho tiếng Việt, với bộ từ vựng gồm 20,480 tokens. Mô hình được cấu hình độ dài tối đa max_seq_len là 8192, với số chiều d_model là 3072 và số lớp n_layers là 32. Mô hình được đào tạo trước trên kho văn bản có dung lượng 482GB bằng tiếng Việt được làm sạch và sao chép cẩn thận. PhoGPT-4B được tinh chỉnh bằng phương pháp huấn luyện có giám sát (supervised fine-tuning[10]) với 70K hướng dẫn, 290k đoạn hội thoại để tạo nên PhoGPT-4B-Chat.

PhoGPT-4B và biến thể trò chuyện của nó, PhoGPT-4B-Chat, đã thể hiện hiệu suất mạnh mẽ hơn so với các mô hình mã nguồn mở và mã nguồn đóng khác. PhoGPT-4B-Chat được đánh giá cao trong việc xử lý các nhiệm vụ ngôn ngữ phức tạp và cung cấp một công cụ mạnh mẽ để nghiên cứu và ứng dụng xong xử lý ngôn ngữ tự nhiên đối với tiếng Việt.

c, Vistral-7B-Chat

Trước hết ta tìm hiểu mô hình Mistral-7B[14], đây là một mô hình ngôn ngữ lớn được phát hành vào tháng 9 năm 2023 dựa trên kiến trúc của Transformer được

huấn luyện nhiều cho việc sinh văn bản đồng thời xử lý được nhiều nhiệm vụ như dịch máy, hỏi đáp,.... Thời điểm phát hành mô hình được xem là mạnh mẽ nhất so với các mô hình cùng kích thước khác có thể suy luận nhanh hơn và xử lý được những chuỗi dài hơn với chi phí nhỏ hơn.

Vistral-7B-Chat[15] là mô hình ngôn ngữ lớn sử dụng để đối thoại dành cho tiếng việt, được mở rộng từ mô hình Mistral-7B sử dụng lượng dữ liệu khổng lồ đa dạng được liên tục đào tạo trước (continual pre-training[16]) và điều chỉnh hướng dẫn (instruction tuning[17]). Quá trình phát triển thực hiện mở rộng thêm từ vựng hỗ trợ tiếng việt, thực hiện đào tạo trước liên tục với các văn bản tiếng việt chất lượng cao đảm bảo các tiêu chí an toàn tại Việt Nam.

Mô hình Vistral sử dụng bảng xếp hạng VMLU[8] để đánh giá và đạt được kết quả vượt trội khi phát hành, vượt qua ChatGPT[18] và các mô hình trước đó đạt kết quả trung bình là 50,07.

VMLU Benchmark										
#	MODEL	CREATOR	ACCESS	BASE MODEL	EVALUATION DATE	STEM	SOCIAL SCIENCE	HUMANITIES	OTHERS	AVG
1	GPT-4	OpenAI	API	From scratch	08/01/2024	63.84	71.78	66.14	60.37	65.53
2	**Vistral-7B-Chat**	**UONLP x Ontocord**	**Weight**	**Mistral-7B-v0.1**	**16/01/2024**	**43.32**	**57.02**	**55.12**	**48.01**	**50.07**
3	ChatGPT	OpenAI	API	From scratch	08/01/2024	43.24	51.67	46.96	46.32	46.33
4	ViGPT-1.6B-v1	Vin BigData	Private	From scratch	08/01/2024	35.06	48.72	47.20	42.54	42.34
5	bloomz-7b1	BigScience	Weight	Bloom-7b1	08/01/2024	32.63	45.73	41.85	39.89	38.87
6	vbd-llama2-7b-50b...	Vin BigData	Weight	llama-2-7b	08/01/2024	31.45	40.34	40.24	39.62	36.98
7	vietcuna-3b	Virtual Interactive	Weight	bloomz-3b	08/01/2024	30.12	39.92	37.86	33.83	34.79
8	bloomz-1b7	BigScience	Weight	Bloom-1b7	08/01/2024	29.72	40.17	34.73	33.41	33.65
9	SeaLLM-7B-Hybrid	DAMO Academy	Weight	llama-2-7b	08/01/2024	29.49	34.61	36.68	34.52	33.39
10	Qwen-7B	Alibaba Cloud	Weight	From scratch	08/01/2024	30.64	35.07	34.15	32.68	32.81

Hình 2.3: Huggingface Leaderboard

Với những kết quả xuất sắc đã đạt được và sự khảo sát của bản thân đối với các mô hình tinh chỉnh sử dụng cho ngôn ngữ tiếng Việt nên đồ án này tôi quyết định sử dụng mô hình Vistral-7B-Chat[15] để giải quyết bài toán đã đặt ra là tóm tắt tóm lược đa văn bản tiếng Việt.

2.4.3 Mô hình ngôn ngữ lớn trong tóm tắt tóm lược văn bản tiếng Việt

Cách để mô hình ngôn ngữ lớn giải quyết bài toán này cũng tương tự như quá trình giải quyết bài toán cho ngôn ngữ tiếng Anh và được thực hiện như sau:

Đầu tiên, mô hình sử dụng một lớp nhúng để chuyển đổi từ ngữ trong văn bản thành các biểu diễn vector trong không gian nhiều chiều mang thông tin của các câu, các từ hay cụm từ. Quá trình này giúp mô hình nắm bắt được ngữ nghĩa và mối quan hệ giữa các từ. Lớp nhúng thường được huấn luyện trước trên các tập dữ liệu lớn và có thể tiếp tục được điều chỉnh trong quá trình huấn luyện mô hình để tối ưu hóa hiệu suất.

Sau đó, cơ chế self-attention (tự chú ý) nắm bắt và tập trung vào các phần quan trọng của câu sinh ra, xem xét các từ, cụm từ trong câu linh hoạt. Self-Attention cho phép mô hình tính toán mối quan hệ giữa mỗi từ với tất cả các từ khác trong câu, giúp nắm bắt ngữ cảnh toàn cục và các liên kết ngữ nghĩa phức tạp. Điều này đặc biệt quan trọng trong việc tóm tắt văn bản, nơi cần phải giữ lại thông tin cốt lõi và loại bỏ những phần không cần thiết.

Lớp giải mã (decoder), lớp này làm nhiệm vụ sinh văn bản, dựa trên ngữ cảnh hay mối quan hệ các câu từ mà mô hình được học, nhằm hiểu cú pháp và hiểu ngôn ngữ. Lớp giải mã thường bao gồm nhiều lớp (layers) và sử dụng các cơ chế như Dropout và Layer Normalization để tránh hiện tượng overfitting và cải thiện khả năng tổng quát hóa của mô hình. Mỗi bước trong quá trình sinh văn bản, mô hình sử dụng thông tin từ các từ trước đó và điều chỉnh lại dự đoán dựa trên ngữ cảnh toàn cục.

Ngoài các bước chính trên, quá trình tóm tắt văn bản bằng mô hình ngôn ngữ lớn decoder-only còn có một số khía cạnh quan trọng khác:

Pre-training và Fine-tuning: Mô hình thường được huấn luyện trước (pre-trained) trên một tập dữ liệu khổng lồ từ nhiều nguồn khác nhau để học các biểu diễn ngôn ngữ phong phú. Sau đó, mô hình có thể được tinh chỉnh (fine-tuned) trên các tập dữ liệu cụ thể của nhiệm vụ tóm tắt văn bản để cải thiện độ chính xác và tính thích ứng cho từng loại văn bản cụ thể.

Evaluation Metrics: Để đánh giá hiệu suất của mô hình tóm tắt, các chỉ số như ROUGE (Recall-Oriented Understudy for Gisting Evaluation[19]) thường được sử dụng. ROUGE đánh giá mức độ tương đồng giữa văn bản tóm tắt được sinh ra và văn bản tham chiếu, giúp đánh giá chất lượng và độ chính xác của các bản tóm tắt.

User Customization: Mô hình cũng có thể được điều chỉnh để phù hợp với yêu cầu cụ thể của người dùng, chẳng hạn như độ dài của bản tóm tắt, mức độ chi tiết cần thiết, hoặc ưu tiên cho các thông tin cụ thể. Điều này giúp tạo ra các bản tóm tắt đáp ứng đúng nhu cầu của người sử dụng trong nhiều bối cảnh khác nhau.

Với việc sử dụng các tiêu chí này, mô hình ngôn ngữ lớn decoder-only không chỉ cải thiện khả năng tóm tắt văn bản mà còn mở rộng ứng dụng trong nhiều lĩnh vực khác nhau, từ báo chí, giáo dục đến quản lý thông tin doanh nghiệp.

2.4.4 Kỹ thuật huấn luyện mô hình ngôn ngữ lớn

Các mô hình ngôn ngữ lớn được đào tạo trước thường được gọi là mô hình nền tảng vì chúng hoạt động tốt trên các nhiệm vụ khác nhau và có thể sử dụng chúng làm nền tảng để tinh chỉnh nhiệm vụ mục tiêu. Việc sử dụng kỹ thuật tinh chỉnh

phù hợp sẽ giúp cho mô hình trở nên tốt hơn nên ở đây tôi sẽ trình bày phương pháp Intruction tuning và kỹ thuật Prompt engineering sau khi mô hình tinh chỉnh phù hợp. Quá trình huấn luyện mô hình để chúng phù hợp với mục tiêu nhiệm vụ có thể rất tốn kém về mặt tính toán - mô hình càng lớn, việc cập nhật các lớp của nó càng tốn kém. Để đáp ứng được phần nào về việc sử dụng tài nguyên bộ nhớ thì một kỹ thuật tinh chỉnh là LoRA (Low-rank Adaptation[20]) đã được sử dụng rộng rãi để đào tạo các mô hình ngôn ngữ lớn. Cùng với LoRA là phương pháp lượng tử hóa (Quantization) được kết hợp nhằm mục đích giảm đi lượng tài nguyên, sự kết hợp này cho ra một phương pháp tinh chỉnh hiệu quả đó là QloRA[21] đã giảm được đáng kể bộ nhớ giúp huấn luyện trên các thiết bị không thật sự mạnh.

a, Intruction Tuning

Intruction Tuning [22] là một kỹ thuật để tinh chỉnh (fine-tune) các mô hình ngôn ngữ lớn (LLM) trên tập dữ liệu được gắn nhãn gồm các lời nhắc hướng dẫn (instructional prompts) và đầu ra tương ứng. Nó cải thiện hiệu suất mô hình không chỉ trên các nhiệm vụ cụ thể mà còn trong việc theo dõi các hướng dẫn nói chung, do đó giúp điều chỉnh các mô hình được đào tạo trước cho việc sử dụng thực tế.

Intruction Tuning nhằm cải thiện khả năng thực hiện các nhiệm vụ cụ thể và nâng cao hiệu suất trong việc tuân theo các hướng dẫn nói chung. Đây là một phần của các kỹ thuật tinh chỉnh (fine-tune) được sử dụng để tối ưu hóa các mô hình nền tảng được đào tạo trước cho nhiều mục đích khác nhau. Ví dụ, mô hình Llama 2[9] của Meta có các phiên bản được tinh chỉnh cho đối thoại (Llama-2-chat) và lập trình (Code Llama). Intruction tuning không loại trừ việc sử dụng các kỹ thuật tinh chỉnh khác như học tăng cường từ phản hồi của con người (RLHF[23]) hoặc tinh chỉnh dựa trên dữ liệu lập trình để cải thiện khả năng hiểu mã của mô hình. Mục tiêu của Intruction Tuning là cải thiện khả năng của LLMs trong việc đáp ứng các hướng dẫn NLP bằng cách kết hợp các nguyên tắc của prompt engineering.

Trong mỗi mẫu huấn luyện của tập dữ liệu, có ba yếu tố chính: một hướng dẫn cụ thể cho một nhiệm vụ, thông tin bổ sung tùy chọn cung cấp ngữ cảnh liên quan đến nhiệm vụ, và đầu ra mong muốn làm mục tiêu để đánh giá và tối ưu hóa dự đoán của mô hình. Phiên bản Intruction Tuning của mô hình LaMDA-PT của Google, được gọi là FLAN, đã cho thấy những cải tiến lớn nhất trong các nhiệm vụ như dịch thuật, trả lời câu hỏi, đọc hiểu và suy luận ngôn ngữ tự nhiên.

Intruction tuning không chỉ cải thiện hiệu suất của mô hình trên các nhiệm vụ đã có mà còn trên các nhiệm vụ mới chưa được đại diện trong tập dữ liệu. Điều này chứng tỏ lợi ích cơ bản của intruction tuning là nâng cao toàn diện khả năng tuân thủ hướng dẫn của mô hình. Brown và cộng sự trong bài nghiên cứu [22] năm 2020

của họ về GPT-3 cũng đã quan sát thấy rằng các mô hình tiền huấn luyện gặp khó khăn với các nhiệm vụ không xuất hiện tự nhiên trong dữ liệu tự giám sát, nhưng lại dễ dàng hơn với các nhiệm vụ có mục tiêu giống với mô hình ngôn ngữ trung thực.

b, Prompt Engineering

Các mô hình AI tạo ra được xây dựng trên các kiến trúc Transformer, cho phép chúng nắm bắt sự phức tạp của ngôn ngữ và xử lý một lượng lớn dữ liệu thông qua các mạng thần kinh. Kỹ thuật Prompt engineering[6] giúp định hình đầu ra của mô hình, đảm bảo trí tuệ nhân tạo phản hồi có ý nghĩa và mạch lạc. Một số kỹ thuật nhắc nhở đảm bảo các mô hình AI tạo ra các phản hồi hữu ích, bao gồm mã hóa, điều chỉnh tham số mô hình và lấy mẫu. Trước hết, cần hiểu prompt là gì? Prompt chính là các chuỗi đầu vào hoặc truy vấn để đưa vào cho mô hình ngôn ngữ mục đích thu được một đầu ra của mô hình đáp ứng được truy vấn đó. Prompt có thể được xây dựng từ các câu hay diễn giải của người sử dụng đưa vào mô hình, việc xây dựng prompt chính là việc tạo ra sự tương tác với các mô hình, đồng thời cũng có thể tăng hiệu quả của nhiệm vụ nhờ vào việc thiết kế prompt một cách hiệu quả.

Prompt engineering giúp các mô hình AI tạo ra hiểu rõ hơn và trả lời một loạt các truy vấn, từ đơn giản đến kỹ thuật cao để mang lại một kết quả đáng mong đợi trong khi không cần tác động đến trọng số mô hình. Generative AI dựa vào sự tinh chỉnh lặp đi lặp lại của prompt engineering khác nhau để học hỏi hiệu quả từ dữ liệu đầu vào đa dạng và thích ứng để giảm thiểu sự thiên vị, nhầm lẫn và tạo ra các phản hồi chính xác hơn. Quá trình này có thể tối ưu hóa đáng kể chất lượng và mức độ liên quan của đầu ra để giải quyết nhiệm vụ cụ thể, làm giảm nhu cầu xem xét thủ công và chỉnh sửa, cuối cùng tiết kiệm thời gian và công sức trong việc đạt được kết quả mong muốn.

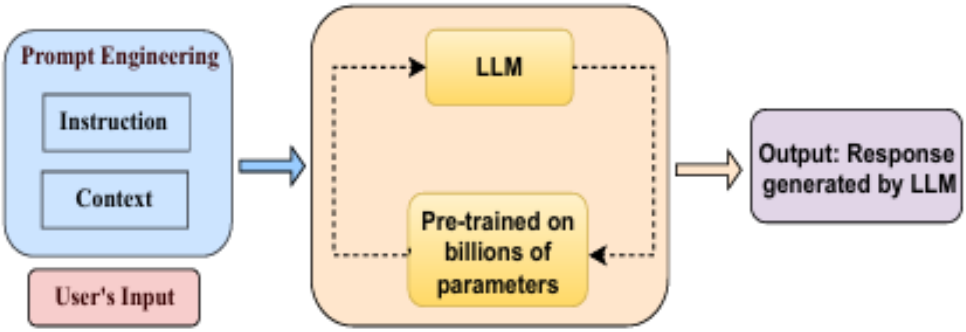

Hình 2.4: Minh họa quá trình thực hiện của Prompt Engineering [6]

Mục đích của prompt engineering để hiểu làm thế nào để có được kết quả tốt nhất từ sự đa dạng của các mô hình AI tạo ra trên thị trường. Ví dụ: viết lời nhắc

cho GPT-3 hoặc GPT-4 của Open AI khác với viết lời nhắc cho Google Bard. Bard có thể truy cập thông tin thông qua Google Tìm kiếm, vì vậy nó có thể được hướng dẫn để tích hợp thông tin cập nhật hơn vào kết quả của nó. Tuy nhiên, ChatGPT là công cụ tốt hơn để nhập và tóm tắt văn bản, vì đó là chức năng thiết kế chính của nó. Prompt (lời nhắc) được tạo tốt hướng dẫn các mô hình AI tạo ra các phản hồi phù hợp, chính xác và được cá nhân hóa hơn. Bởi vì các hệ thống AI phát triển cùng với việc sử dụng, các lời nhắc được thiết kế cao giúp tương tác lâu dài với AI hiệu quả và thỏa mãn hơn.

c, Lượng tử hóa (Quantization)

Lượng tử hóa (Quantization) là một kỹ thuật trong lĩnh vực học máy và xử lý tín hiệu, nhằm giảm độ chính xác của các tham số mô hình từ định dạng có độ chính xác cao (như 32-bit) xuống định dạng có độ chính xác thấp hơn (như 8-bit), mà vẫn duy trì hiệu suất của mô hình ở mức chấp nhận được. Kỹ thuật này đặc biệt hữu ích trong việc giảm kích thước mô hình và tăng tốc độ tính toán, từ đó tiết kiệm tài nguyên bộ nhớ và tính toán. Quá trình lượng tử hóa bao gồm ba bước chính:

Bước 1: Khởi tạo và huấn luyện mô hình gốc: Mô hình ban đầu được huấn luyện với độ chính xác cao (thường là 32-bit float). Quá trình này đảm bảo mô hình đạt được hiệu suất tốt nhất có thể trước khi áp dụng lượng tử hóa.

Bước 2: Chuyển đổi tham số: Các tham số của mô hình (trọng số và độ chệch) được chuyển đổi từ định dạng có độ chính xác cao xuống định dạng có độ chính xác thấp hơn. Việc chuyển đổi này thường được thực hiện bằng cách sử dụng các phương pháp như lượng tử hóa tuyến tính (linear quantization) hoặc lượng tử hóa phi tuyến (non-linear quantization).

Bước 3: Tinh chỉnh mô hình lượng tử hóa: Sau khi chuyển đổi, mô hình cần được tinh chỉnh lại trên tập dữ liệu huấn luyện hoặc tập dữ liệu mới để điều chỉnh các tham số cho phù hợp với định dạng mới. Quá trình này giúp giảm thiểu mất mát hiệu suất do lượng tử hóa gây ra.

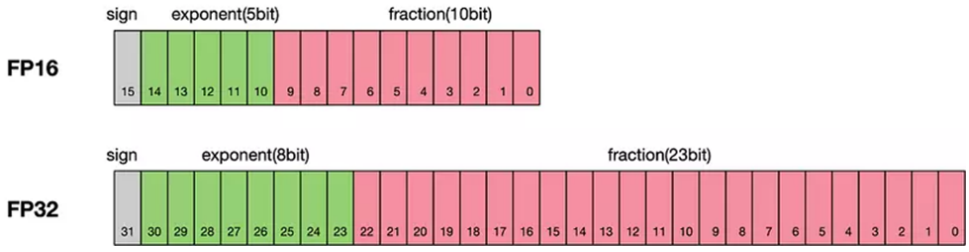

Hình 2.5: dạng dấu phẩy động 16 bit và 32 bit

Quá trình thực hiện Quantization giúp giảm dung lượng bộ nhớ khi giảm số bit cần thiết để lưu trữ các tham số, giúp mô hình nhỏ gọn hơn đồng thời tăng tốc độ

tính toán bởi các phép tính với số bit thấp hơn (như 8-bit) thường nhanh hơn nhiều so với phép tính với số bit cao (như 32-bit), đặc biệt là trên phần cứng chuyên dụng như GPU hoặc TPU. Ngoài ra, việc sử dụng phương pháp này giúp tiết kiệm năng lượng khi mô hình nhỏ hơn và tính toán nhanh hơn giúp tiết kiệm năng lượng, điều này đặc biệt quan trọng đối với các thiết bị di động và nhúng.

Lượng tử hóa là một kỹ thuật quan trọng trong việc tối ưu hóa và triển khai các mô hình ngôn ngữ lớn và mạng nơ-ron sâu. Bằng cách giảm độ chính xác của các tham số, lượng tử hóa giúp giảm dung lượng bộ nhớ, tăng tốc độ tính toán và tiết kiệm năng lượng mà vẫn duy trì hiệu suất mô hình ở mức chấp nhận được. Nhờ vào các phương pháp lượng tử hóa tiên tiến và kỹ thuật tinh chỉnh, việc sử dụng các mô hình trở nên khả thi và hiệu quả hơn, mở ra cơ hội mới cho việc triển khai các mô hình AI trên nhiều nền tảng phần cứng khác nhau.

d, LoRA (Low-rank Adaptation)

Low-rank Adaptation[20] (LoRA) là một kỹ thuật tối ưu hóa mô hình, được thiết kế để giảm thiểu số lượng tham số cần huấn luyện và do đó giảm tài nguyên tính toán cần thiết. LoRA thực hiện điều này bằng cách tập trung vào một phương pháp cụ thể để điều chỉnh các tham số của mô hình một cách hiệu quả.

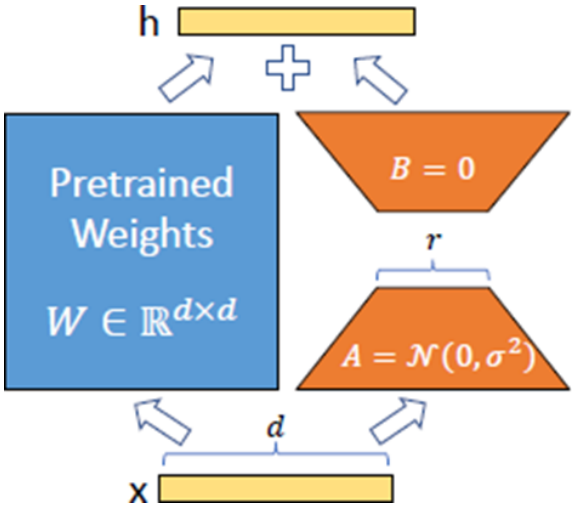

Hình 2.6: Minh họa Lora

LoRA dựa trên một quan sát rằng các thay đổi cần thiết để tinh chỉnh mô hình từ một trạng thái đã được huấn luyện trước có thể được biểu diễn bằng cách sử dụng các ma trận có cấp bậc thấp. Điều này nghĩa là thay vì cập nhật toàn bộ ma trận tham số lớn, ta chỉ cần cập nhật một số lượng nhỏ các ma trận cấp bậc thấp. Quá trình này bao gồm các bước chính sau:

- Khởi tạo ma trận tham số: Trong một mô hình ngôn ngữ lớn, các tham số được biểu diễn dưới dạng các ma trận lớn. LoRA tách các ma trận này thành

hai phần: một ma trận có cấp bậc thấp và một ma trận bổ sung để hiệu chỉnh.

- Biểu diễn tham số dưới dạng ma trận cấp bậc thấp: Thay vì cập nhật toàn bộ ma trận tham số lớn, LoRA chỉ cập nhật các ma trận có cấp bậc thấp này. Điều này giảm việc cập nhật tham số trong quá trình huấn luyện.
- Tinh chỉnh mô hình: Khi huấn luyện mô hình, chỉ các ma trận cấp bậc thấp được cập nhật, trong khi các ma trận gốc giữ nguyên. Quá trình này giảm thiểu lượng tính toán cần thiết và giảm tải bộ nhớ.

khi áp dụng kỹ thuật này trong quá trình huấn luyện thì chỉ điều chỉnh tham số của LoRA. Điều này cho phép mô hình được huấn luyện nhanh hơn và với chi phí thấp hơn nhiều so với việc điều chỉnh toàn bộ mô hình khi phải cập nhật trọng số ít hơn. LoRA cũng nâng cao hiệu quả cho các hệ thống yếu hơn, cho phép huấn luyện các mô hình lớn và mở rộng khả năng tiếp cận công nghệ tiên tiến tới nhiều người dùng hơn.

LoRA được áp dụng rộng rãi trong việc huấn luyện các mô hình ngôn ngữ lớn, đặc biệt là trong các kịch bản yêu cầu tinh chỉnh mô hình đã được huấn luyện trước trên các tập dữ liệu cụ thể. Nó giúp cải thiện hiệu suất mà không đòi hỏi tài nguyên tính toán quá lớn, đồng thời duy trì chất lượng mô hình. Bằng cách giảm số lượng tham số cần thiết để tinh chỉnh mô hình, LoRA giúp giảm yêu cầu về tài nguyên bộ nhớ và tính toán, đồng thời tăng tốc độ huấn luyện. Điều này làm cho các mô hình ngôn ngữ lớn trở nên khả thi và hiệu quả hơn trên các hệ thống máy tính có tài nguyên hạn chế.

e, QLoRA (Quantization Low-rank Adaptation)

QLoRA[21] là phiên bản mở rộng của LoRA hoạt động bằng cách định lượng độ chính xác của các thông số trọng lượng trong LLM được đào tạo trước với độ chính xác 4-bit. Thông thường, các tham số của các mô hình được đào tạo được lưu trữ ở định dạng 32 bit, nhưng QLoRA nén chúng thành định dạng 4 bit. Điều này làm giảm dấu chân bộ nhớ của LLM, giúp bạn có thể tinh chỉnh nó trên một GPU duy nhất. Phương pháp này làm giảm đáng kể dung lượng bộ nhớ, giúp chạy các mô hình LLM trên phần cứng kém mạnh mẽ hơn, bao gồm cả GPU tiêu dùng.

QLORA giới thiệu nhiều cải tiến được thiết kế để giảm sử dụng bộ nhớ mà không làm giảm hiệu suất:

1. 4-bit NormalFloat, một kiểu dữ liệu lượng tử hóa tối ưu về mặt lý thuyết thông tin cho dữ liệu phân tán thông thường mang lại kết quả thực nghiệm tốt hơn so với Số nguyên 4 bit và Số nổi 4 bit.
2. Lượng tử hóa kép, một phương pháp định lượng các hằng số lượng tử hóa, tiết

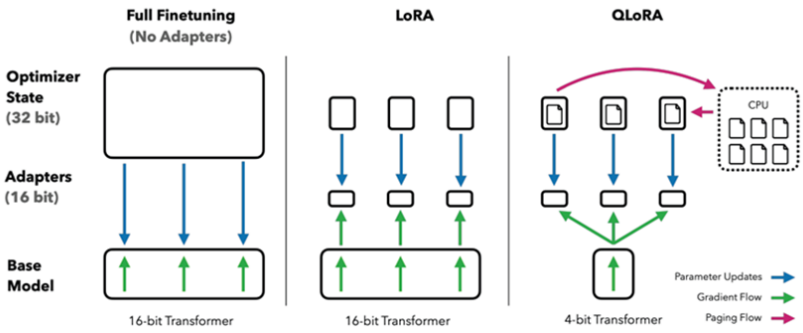

Hình 2.7: So sánh các phương pháp[21]

kiệm trung bình khoảng 0,37 bit trên mỗi tham số (khoảng 3 GB cho mô hình 65B).

3. Trình tối ưu hóa phân trang, sử dụng bộ nhớ hợp nhất NVIDIA để tránh các gai bộ nhớ điểm kiểm tra gradient xảy ra khi xử lý một lô nhỏ có độ dài chuỗi dài.

	TruthfulQA MC1	TruthfulQA MC2	Arithmetic 2ds	Arithmetic 4ds	BLiMP Causative	MMLU Global Facts
Llama 2 7B base	0.2534	0.3967	0.508	0.637	0.787	0.32
LoRA default 1	0.2876	0.4211	0.3555	0.0035	0.75	0.27
LoRA default 2	0.284	0.4217	0.369	0.004	0.747	0.26
LoRA default 3	0.2815	0.4206	0.372	0.004	0.747	0.27
QLoRA (nf4)	0.2803	0.4139	0.4225	0.006	0.783	0.23
QLoRA (fp4)	0.2742	0.4047	0.5295	0.016	0.744	0.23

Image source: *https://lightning.ai/pages/community/lora-insights/*

Hình 2.8: So sánh Lora và Qlora

Hình 2.8 cho thấy kết quả của mô hình LLaMA 2 7B được đào tạo trên các dấu phẩy động khác nhau và kết quả của các mô hình trên các nhiệm vụ khác nhau. Mô hình được đào tạo trên NF4 và float 4-bit cho kết quả tốt hơn so với mô hình cơ sở LoRA và LLaMA 2 7B, trong khi 4-bit NormalFloat thực hiện hiệu suất tốt hơn một chút so với kiểu dữ liệu float4. QLoRA giảm yêu cầu bộ nhớ bằng cách gần như sử dụng loại NF4. Tuy nhiên, sự đánh đổi là thời gian đào tạo chậm hơn, được mong đợi do các bước lượng tử hóa và phi lượng tử hóa.

Với những sự hiệu quả của QLORA mang lại với khả năng tiết kiệm bộ nhớ và đáp ứng cho các thiết bị yếu nên có lẽ đây là một cách tuyệt vời để có thể tiếp cận với mô hình ngôn ngữ lớn hướng đến giải quyết các vấn đề cụ thể.

2.5 Độ đo ROUGE trong đánh giá tóm tắt văn bản

Recall-Oriented Understudy for Gisting Evaluation[19], thường được gọi là điểm ROUGE, là một số liệu được sử dụng để đánh giá các mô hình tóm tắt và dịch thuật văn bản, đây là một độ đo phổ biến được dùng rộng rãi. Có nhiều biến thể của điểm ROUGE. Trong bài viết này, tôi sẽ hướng dẫn cách tính ROUGE-N, ROUGE-L và

đề cập đến các loại điểm ROUGE khác.

Vì không thể so sánh đầu ra của dữ liệu văn bản trực tiếp như thể đó là phân loại nhị phân nên có thể tính toán các từ chồng chéo giữa các dự đoán (ứng cử viên) và tóm tắt tham khảo và trọng số của chúng tương ứng. Các bản tóm tắt tham khảo là các bản tóm tắt được viết thủ công bởi các chuyên gia ngôn ngữ học. Có thể có nhiều hơn một bản tóm tắt cho mỗi văn bản.

Trước hết cần hiểu ROUGE-N, thì N cho biết số gram tức là biểu diễn các chuỗi ký tự liên tiếp với mỗi ứng viên là N từ, có thể là 1 hoặc 2. Đối với ROUGE-1 sẽ cho biết việc so sánh dựa trên số lượng từ của toàn bộ văn bản còn ROUGE-2 đó là số lượng bigram với mỗi ứng cử viên là 2 từ liên tiếp nhau trong văn bản. Ví dụ câu “ tôi thích mô hình ngôn ngữ” thì 1-gram là [“tôi”, “thích”, “mô”, “hình”, “ngôn”, “ngữ”] còn 2-gram sẽ là [“tôi thích”, ” thích mô”, “mô hình”, “hình ngôn”, “ngôn ngữ”, “ngữ lớn”]. Để tính điểm ROUGE chứng ta cũng cần hiểu cách tính Recall và Precision trong văn bản:

$$RECALL = \frac{ovverlapping\ number\ of\ n-grams}{Number\ of\ n-grams\ in\ the\ reference}$$

$$PRECISION = \frac{ovverlapping\ number\ of\ n-grams}{Number\ of\ n-grams\ in\ the\ candidate}$$

Để hoàn thành phép tính đúng ta cần phải tính điểm F1 (trung bình điều hòa):

$$F1 = \frac{2 \times Precision \times Recall}{Precision + recall}$$

Ngoài ROUGE-N, cũng có tiêu chí đánh giá cho nhiệm vụ này đó là ROUGE-L. ROUGE-L được định hướng chuỗi con chung dài nhất (LCS). LCS là chuỗi từ dài nhất xuất hiện trong cả ứng cử viên và tóm tắt tham khảo, trong khi vẫn giữ nguyên thứ tự của các từ. Nó tự động bao gồm chuỗi từ dài nhất. điều quan trọng cần lưu ý là LCS không nhất thiết phải liên tiếp nhưng vẫn theo thứ tự. Chẳng hạn: với đầu ra mô hình: "Một con cáo nâu nhanh nhảy qua cái cây" Còn tài liệu tham khảo: "Con cáo nâu nhanh nhẹn nhưng lại lười biếng." Để tính toán ROUGE-L, trước tiên cần tìm dãy con chung dài nhất giữa hai câu. Chuỗi con chung dài nhất ở đây là "Con cáo nâu nhanh". Việc tính toán sẽ dựa trên số lượng từ của chuỗi con chung này với precision = 4/9, recall = 4/9 và dễ dàng tính được F1-score = 4/9.

Có thể thấy ROUGE là một độ đo được thiết lập tốt đã được chứng minh là tương quan tốt với đánh giá của con người. Việc tính toán dễ dàng và tương đối dễ hiểu có thể đánh giá trên bất kỳ ngôn ngữ nào và hoàn toàn phù hợp với bài toán.

CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT

Trong các phần trước, đồ án đã trình bày nền tảng lý thuyết cho bài toán, các kết quả nghiên cứu gần đây, các vấn đề trong bài toán tóm tắt văn bản. Đồng thời đã nêu lên độ đo đánh giá cho bài toán này cũng như một số hướng giải quyết có thể phát triển để đáp ứng nhu cầu hiện nay. Trong chương này tôi nêu ra đề xuất về phương pháp giải quyết cho bài toán tóm tắt tóm lược đa văn bản tiếng Việt.

3.1 Tổng quan giải pháp

Bài toán đặt ra yêu cầu cần tóm tắt tóm lược đa văn bản tiếng Việt sao cho kết quả của bản tóm tắt được tự nhiên và mạch lạc. Một số phương pháp trước đây thực hiện dựa trên việc trích xuất các câu quan trọng rồi đưa vào các mô hình ngôn ngữ được huấn luyện trên tiếng việt để tóm tắt tuy nhiên, vẫn gặp một số vấn đề trong quá trình xử lý đầu vào hoặc văn bản quá dài. Hiện nay, việc phát triển các mô hình ngôn ngữ lớn có thể là một giải pháp khả thi khi đáp ứng được việc xử lý chuỗi đầu vào sinh ra các bản tóm tắt mạch lạc hơn và huấn luyện trên các dữ liệu khổng lồ cho tiếng Việt, với một số mô hình hiện nay như Mistral hay Llama . . .

Với sự phát triển trong cộng đồng sử dụng mô hình ngôn ngữ lớn ở Việt Nam, hàng loạt các mô hình được đào tạo cho việc xử lý đa ngôn ngữ nhằm đáp ứng được yêu cầu mọi người dùng, cho mọi nhiệm vụ cụ thể. Dựa trên cơ sở này việc sử dụng một số mô hình như Vistral-7b-chat, Vinallama, GPT . . . được huấn luyện với tiếng Việt là hoàn toàn hợp lý cho nhiệm vụ bài toán đặt ra, các mô hình này cho thấy kết quả tốt trong việc sinh văn bản hay trả lời câu hỏi, nhưng cũng cần lựa chọn mô hình kích thước phù hợp để sử dụng cho các cấu hình của bản thân. Ngoài ra, có thể thử nghiệm các mô hình ngôn ngữ nhỏ hơn như ViT5, PhoBERT . . . xem việc cải tiến hay nâng cấp có thể tốt hơn không đồng thời so sánh với các mô hình ngôn ngữ lớn hiện nay.

Giải pháp tôi đề xuất áp dụng được trên các dữ liệu khác nhau nhưng sẽ phù hợp cho các dữ liệu theo cấu trúc cụ thể như dưới dạng một bài viết, văn bản. Để hiện thực hóa cho bài toán, tôi sử dụng các bộ dữ liệu tóm tắt văn bản dành cho tiếng Việt để thực hiện huấn luyện mô hình và sẽ đưa ra kết quả cụ thể ở phần thực nghiệm.

3.2 Đề xuất sử dụng mô hình ngôn ngữ lớn Vistral-7B-Chat

Đối với tác vụ tóm tắt tóm lược đa văn bản tiếng Việt và theo các kết quả đã khảo sát với các mô hình ngôn ngữ lớn cho tiếng Việt, từ đó tôi đề xuất sử dụng mô hình Vistral-7B-Chat[15] đây là mô hình được phát triển từ mô hình ngôn ngữ lớn

Mistral-7B[14]. Do đó, để hiểu về rõ hơn về mô hình, tôi sẽ trình bày về Mistral-7B

3.2.1 Mô hình ngôn ngữ lớn Mistral-7B

Mistral 7B[14] là một mô hình ngôn ngữ lớn dựa trên kiến trúc Transformer với 7 tỷ tham số được thiết kể nhằm mang lại những hiệu năng vượt trội. Mô hình này đã đạt được điểm đánh giá vượt trội trên cả lý luận, toán học và tạo mã so với mô hình Llama 2 13 tỷ tham số và cả mô hình llama 1 với 34 tỷ tham số. Mô hình đã kết hợp kiệu quả cơ chế chú ý truy vấn nhóm (Grouped-query Attention) kết hợp với cơ chế cửa sổ trượt (Sliding Window Attention) xử lý hiệu quả cho các chuỗi đầu vào với khả năng suy luận nhanh hơn đồng thời cũng giảm yêu cầu bộ nhớ trong quá trình giải mã, cho phép kích thước lô cao hơn do đó thông lượng cao hơn, một yếu tố quan trọng đối với các ứng dụng thời gian thực. Ngoài ra, SWA được thiết kế để xử lý các chuỗi dài hơn một cách hiệu quả hơn với chi phí tính toán giảm, do đó giảm bớt hạn chế chung trong LLM. Các cơ chế chú ý này góp phần nâng cao hiệu suất và hiệu quả của Mistral 7B, nó đã thực hiện một bước quan trọng trong việc cân bằng các mục tiêu đạt được hiệu suất cao trong khi vẫn duy trì hiệu quả cho các mô hình.

Parameter	Value
dim	4096
n_layers	32
head_dim	128
hidden_dim	14336
n_heads	32
n_kv_heads	8
window_size	4096
context_len	8192
vocab_size	32000

Bảng 3.1: Các tham số chính cho kiến trúc mô hình Mistral-7b

Cơ chế chú ý cửa sổ trượt (Sliding Window Attention - SWA) khai thác các lớp xếp chồng lên nhau của một hệ thống truyền tải trước đây để tham dự thông tin ngoài kích thước cửa sổ W. Trạng thái ẩn ở vị trí i của lớp k, hi, tham gia vào tất cả các trạng thái ẩn từ lớp trước đó có vị trí giữa i - W và i. Ở bước lặp lại, hi có thể truy cập mã thông báo từ lớp đầu vào ở khoảng cách lên tới Wxk mã thông báo, như được minh họa trong Hình . Ở lớp cuối cùng, sử dụng kích thước cửa sổ của W = 4096, có khoảng chú ý về mặt lý thuyết xấp xỉ 131K token. Trong thực tế, với độ dài chuỗi là 16K và W = 4096, những thay đổi được thực hiện đối với FlashAttention và xFormers mang lại kết quả gấp đôi cải thiện tốc độ trên cơ sở chú ý cơ bản.

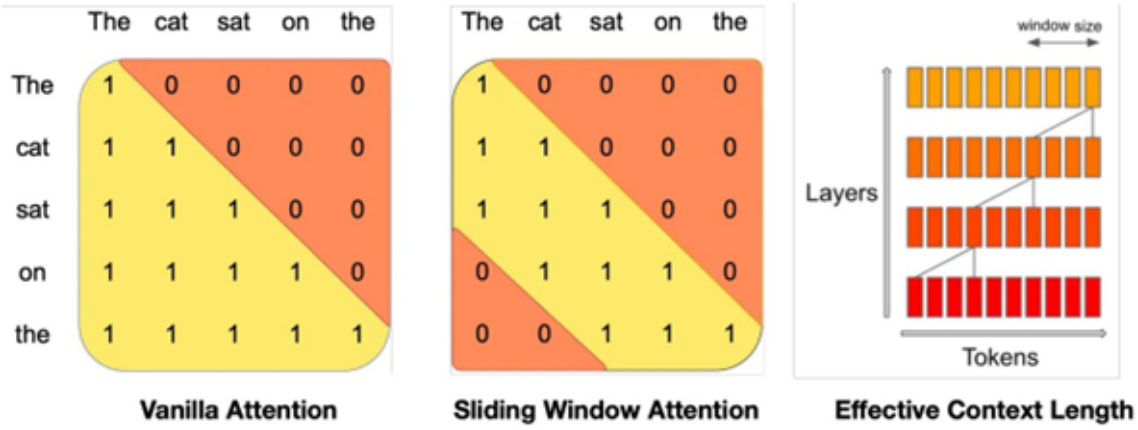

Hình 3.1: Cơ chế chú ý của sổ trượt (SWA)

Số lượng thao tác trong cơ chế chú ý truyền thống (vanilla attention) tăng theo bậc hai với độ dài chuỗi và bộ nhớ tăng tuyến tính theo số lượng mã thông báo. Tại thời điểm suy luận, điều này gây ra độ trễ cao hơn và giảm thông lượng do khả năng sử dụng bộ nhớ đệm bị hạn chế. Để khắc phục vấn đề này, đã áp dụng cơ chế chú ý của cửa sổ trượt: mỗi mã thông báo chỉ có thể chú ý đến tối đa W mã thông báo từ lớp trước (ở đây, W = 3). Lưu ý rằng các mã thông báo nằm ngoài cửa sổ trượt vẫn ảnh hưởng đến dự đoán của từ tiếp theo.

Bộ đệm cuộn (Rolling Buffer Cache - RBC). Khoảng chú ý cố định có nghĩa là có thể giới hạn kích thước bộ đệm của mình bằng cách sử dụng bộ đệm cuộn. Bộ đệm có kích thước cố định là W, đồng thời các khóa và giá trị cho dấu thời gian i được lưu trữ ở vị trí i mod W của bộ đệm khi đó vị trí i lớn hơn W, các giá trị trước đây trong bộ đệm sẽ bị ghi đè và kích thước của bộ đệm sẽ ngừng tăng. Hình minh họa trong với W = 3 có độ dài chuỗi 32k mã thông báo, điều này giúp giảm mức sử dụng bộ nhớ đệm xuống 8 lần mà không ảnh hưởng đến chất lượng mô hình.

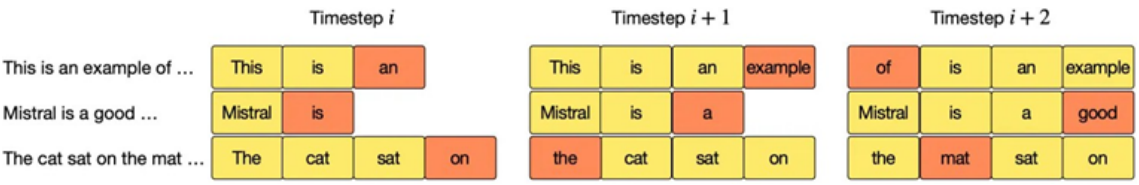

Hình 3.2: Minh họa RBC

Điền trước và chia nhỏ (Pre-fill and Chunking). Khi tạo một chuỗi, cần dự đoán từng mã thông báo một, vì mỗi mã thông báo được điều chỉnh dựa trên các mã trước đó. Tuy nhiên, lời nhắc đã được biết trước và có thể điền trước bộ nhớ đệm (k, v) bằng lời nhắc. Nếu dấu nhắc rất lớn, sẽ chia nó thành nhiều phần nhỏ hơn và điền trước từng đoạn vào bộ đệm. Với mục đích này, có thể chọn kích thước cửa sổ làm kích thước khối của mình. Do đó, đối với mỗi đoạn, cần tính toán mức độ chú

ý trên bộ đệm và trên đoạn dữ liệu. Hình 3.3 cho thấy cách mặt nạ chú ý hoạt động trên cả bộ đệm và đoạn.

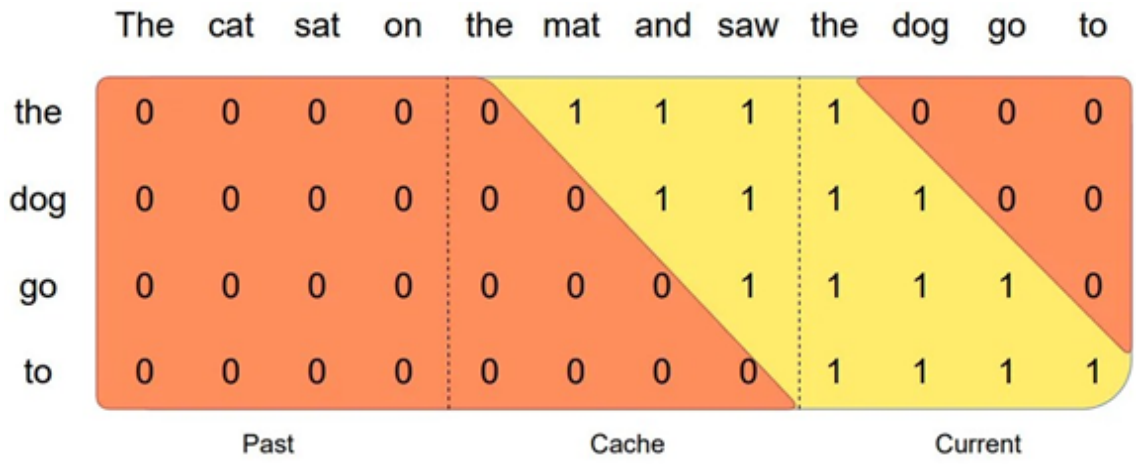

Hình 3.3: mô tả Pre-fill và chunking

Nhìn chung, Mistral 7B là một mô hình ngôn ngữ lớn ấn tượng, mang lại hiệu suất cao và khả năng ứng dụng rộng rãi. Với sự kết hợp của các kỹ thuật tối ưu hóa hiện đại, nó cung cấp một sự cân bằng tốt giữa hiệu suất và tài nguyên, phù hợp cho nhiều ứng dụng thực tế. Tuy nhiên, việc triển khai mô hình này vẫn đòi hỏi cân nhắc về tài nguyên và chi phí.

3.2.2 Mô hình ngôn ngữ lớn Vistral-7B-Chat

Vistral-7B-Chat[15] là một mô hình ngôn ngữ lớn đàm thoại nhiều lượt cho tiếng Việt. Vistral được mở rộng từ mô hình Mistral 7B[14] sử dụng dữ liệu đa dạng để đào tạo trước liên tục (continual pre-training[16]) và điều chỉnh hướng dẫn (instruction tuning[17]). Cụ thể, quá trình phát triển Vistral bao gồm:

Mở rộng tokenizer của Mistral 7B để hỗ trợ Việt Nam tốt hơn. Thực hiện đào tạo trước liên tục cho Mistral qua một bộ dữ liệu đa dạng các văn bản tiếng Việt được làm sạch tỉ mỉ và khử trùng lặp.

Thực hiện tinh chỉnh có giám sát (supervised fine-tuning[10]) cho mô hình bằng cách sử dụng dữ liệu hướng dẫn đa dạng, thiết kế một bộ hướng dẫn để điều chỉnh mô hình phù hợp với các tiêu chí an toàn tại Việt Nam.

Mô hình được đánh giá bằng cách sử dụng bảng xếp hạng VMLU[8], một khuôn khổ đáng tin cậy để đánh giá các mô hình ngôn ngữ lớn bằng tiếng Việt trong các nhiệm vụ khác nhau. Mô hình đã đạt điểm trung bình 50,07%, vượt qua hiệu suất của ChatGPT[18] là 46,33% khá đáng kể.

3.2.3 Đề xuất phương pháp giải quyết

Sau khi tìm hiểu về các hướng giải quyết bài toán, khảo sát về các kỹ thuật sử dụng cho mô hình ngôn ngữ lớn tôi đề xuất cách giải quyết cho bài toán này.

Mô hình ban đầu tôi tiến hành tinh chỉnh (fine tuning) với các bộ dữ liệu đã có, các bộ dữ liệu này được xử lý phù hợp rồi tạo các hướng dẫn (instruction) để đưa vào mô hình Vistral đã được Qlora. Mô hình ở đây được áp dụng kỹ thuật Instruction Tuning [22] nhằm huấn luyện cho mô hình hiểu được nhiệm vụ tóm tắt tóm lược đa văn bản tiếng Việt, quá trình này có thể tốn khá nhiều thời gian.

Hình 3.4: Quá trình Intruction Finetuning

Mô hình sau khi được tinh chỉnh trên tác vụ tóm tắt tóm lược đa văn bản tiếng Việt sẽ được tiến hành đánh giá như sau:

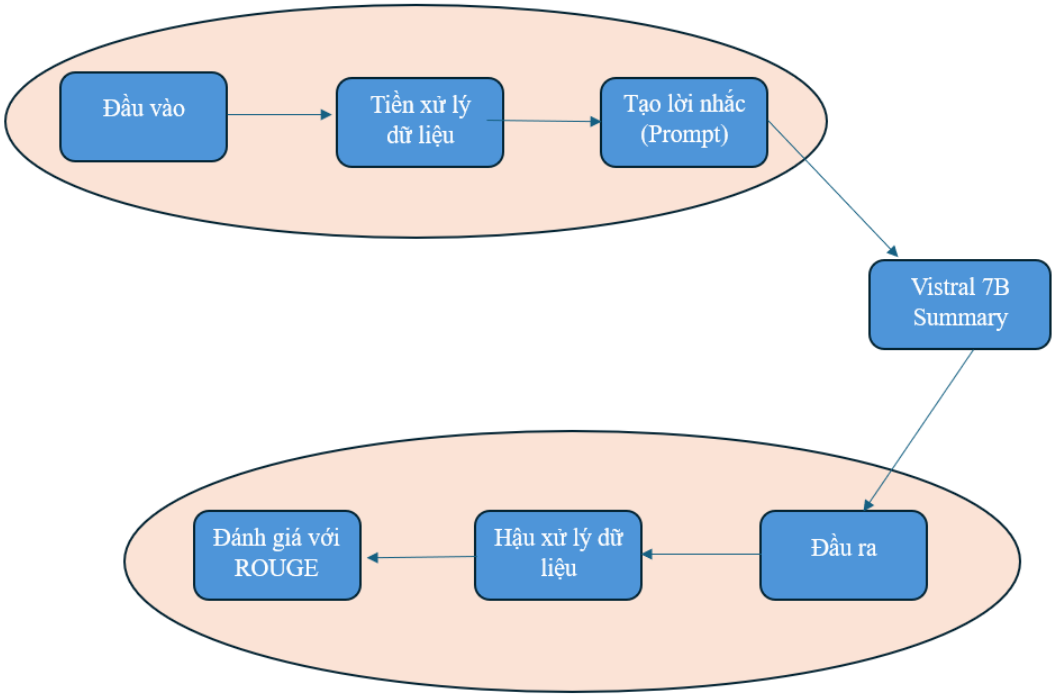

Hình 3.5: Quá trình đánh giá mô hình

- **Bước 1**, với các cụm văn bản đầu vào thực hiện tiền xử lý dữ liệu, dữ liệu này sau đó được thiết kế với kỹ thuật prompt engineering để tạo ra các lời nhắc (prompt) đầu vào phù hợp cho nhiệm vụ.
- **Bước 2**, các đầu ra từ bước trước đó sẽ được đưa vào mô hình Vistral-7B-Chat

đã được tinh chỉnh cho bài toán.

- **Bước 3**, đầu ra của mô hình tiếp tục được hậu xử lý và đánh giá dựa trên độ đo ROUGE so với bản tóm tắt thực tế do người tham chiếu đã tóm tắt trước đó.

CHƯƠNG 4. ĐÁNH GIÁ THỰC NGHIỆM

4.1 Mục tiêu đánh giá

Mục tiêu cho quá trình đánh giá thực nghiệm của đồ án nhằm:

- Phân tích, thử nghiệm phương pháp đề xuất khả thi cho bài toán.
- Đánh giá phương pháp thực hiện, đồng thời so sánh hiệu năng mô hình và kết quả đạt được với các phương pháp hiện nay.

4.2 Tập dữ liệu sử dụng

Việc xây dựng chương trình tóm tắt tự động các văn bản, các bài báo là một công cụ hữu ích cho việc nắm bắt thông tin nhanh chóng, quan trọng là vô cùng thiết yếu khi mà lượng dữ liệu bùng nổ, gia tăng hàng ngày như hiện nay. Các hệ thống tóm tắt đơn văn bản đã phần nào đáp ứng được yêu cầu này khi mà các mô hình ngôn ngữ ngày càng phát triển với những bộ dữ liệu khổng lồ. Tuy nhiên, khả năng tóm tắt đa văn bản, đặc biệt dành cho tiếng Việt với những văn bản cùng chủ đề vẫn còn nhiều hạn chế khi các văn bản chứa dữ liệu có độ dài chuỗi lớn và phức tạp hơn. Từ đó, tôi sử dụng một số tập dữ liệu cho đồ án của mình.

4.2.1 Tập dữ liệu Abmusu 2022

Để đáp ứng được vấn đề đặt ra của bài toán, tôi sử dụng tập dữ liệu đa văn bản sẵn có là tập dữ liệu Abmusu (Vietnamese Abstractive multi-document summarization) được sử dụng cho nhiệm vụ tóm tắt đa văn bản trong khuôn khổ cuộc thi VLSP[24] năm 2022. Đây là các bộ dữ liệu chứa thông tin các bài báo tin tức và các bản tóm tắt do con người tạo ra.

Tập dữ liệu Abmusu chứa các tập tin được chia thành các phần dữ liệu cho quá trình train, validation và test. Tuy nhiên, tôi sử dụng tập train và tập validation nhưng tập validation dùng để thử nghiệm vì tập test của bộ dữ liệu này không có nhãn nên không thể đánh giá được. Tập train chứa 200 cụm dữ liệu, mỗi cụm gồm nhiều văn bản cùng chủ đề dành cho quá trình huấn luyện, còn tập Validation chứa 100 cụm dữ liệu tương tự như tập train. Bộ dữ liệu này được thống kê với các tiêu chí được tính trung bình như trong **Bảng 4.1**:

Bộ dữ liệu này là bộ dữ liệu chính tôi sử dụng để đánh giá cho mô hình đề xuất, đồng thời so sánh kết quả với các mô hình khác.

4.2.2 Tập dữ liệu ViMS

Tập dữ liệu ViMS [25] dùng cho tóm tắt đa văn bản của nhóm tác giả Nghiêm Quốc Minh. Bộ dữ liệu nhằm phục vụ đề tài xây dựng công cụ tổng hợp tin tức

	Training	**Validation**
Số cụm	200	100
Số văn bản trên mỗi cụm	3.105	3.04
Số câu trên một văn bản	38.76	37.72
Số từ trên một văn bản	162.84	61.97
Số câu trên một bản tóm tắt	4.94	4.82
Số từ trên một câu bản tóm tắt	33.756	34.38

Bảng 4.1: Thống kê trung bình cho tập Abmusu

tiếng Việt và ứng dụng.

Tập dữ liệu được thu thập và xây dựng thủ công từ trang Google news, với 300 cụm văn bản tiếng Việt. Trong đó, mỗi cụm sẽ có từ 5 đến 10 bài báo được lấy từ những trang phổ biến ở Việt Nam như: Vnexpress, Dân Trí, Tuổi Trẻ ... Bộ ngữ liệu chứa các bài báo thuộc chủ đề khác nhau bao gồm: thế giới, Việt Nam (tin trong nước), kinh doanh, giải trí và thể thao.

Sau khi thu thập dữ liệu, mỗi cụm văn bản sẽ được tóm tắt bởi hai người khác nhau là những người có kinh nghiệm và đang nghiên cứu về xử lý ngôn ngữ tự nhiên.

Thông tin dữ liệu:

- Thư mục original: Chứa 300 thư mục con chính là 300 cụm văn bản, trong mỗi cụm văn bản là các văn bản thuộc cùng 1 chủ đề. Có thể có 5 đến 10 bài cho mỗi cụm văn bản. Số lượng văn bản là 1,945.
- Thư mục summary: Chứa 300 thư mục con là 600 bản tóm tắt, mỗi cụm đầu vào sẽ có 2 bản tóm tắt thủ công từ người gán nhãn khác nhau với quy trình đảm bảo chất lượng tốt nhất có thể.
- Thư mục S3_summary: Chứa 300 thư mục con gồm 600 bản tóm tắt, là kết quả của bước chọn câu quan trọng. Các nhóm chứa các câu mang nghĩa tương đương nhau, cách nhau bởi 1 dòng trống. Câu quan trọng nhất được chọn từ một nhóm có nhãn 1, các câu còn lại mang nhãn 0.

4.2.3 Tập dữ liệu VietnameseMDS

Tập dữ liệu ViettnameseMDS[1] dùng cho tóm tắt đa văn bản của tác giả Trần Mai Vũ và các cộng sự. Bộ dữ liệu sử dụng cho đề tài cấp Bộ Giáo dục và Đào tạo(Mã số: B2012-01-24): Thiết kế và cài đặt chương trình tóm tắt đa văn bản tiếng Việt.

Quá trình xây dựng dữ liệu thủ công gồm 2 bước

[1]https://github.com/lupanh/VietnameseMDS

- Bước 1: Thu thập dữ liệu và tạo ra các cụm tài liệu (mỗi cụm chứa các tài liệu liên quan đến một vấn đề cụ thể), dữ liệu được thu thập từ trang web Baomoi và được phân bố đều trên tất cả các chủ đề của Baomoi (Khoảng 8-10 chủ đề chính: Thế giới, Xã hội, Văn hóa, Kinh tế, KH-CN, Thể thao, Giải trí, Pháp luật, Giáo dục, Sức khỏe, Ô tô - Xe máy, Nhà đất).
- Bước 2: Có 2 người tham gia vào việc xây dựng các bản tóm tắt tham chiếu. Việc tóm tắt có 2 công đoạn: Trích ra các câu quan trọng và viết lại thành một đoạn văn liền mạch.

Dữ liệu bao gồm 199 cụm văn bản, mỗi cụm có từ 2-5 tài liệu, tổng cộng có 628 văn bản và được lưu lại trong các thư mục.

4.2.4 Phân tích và sử dụng hợp lý các tập dữ liệu cho mô hình

Ban đầu, tôi tiến hành tinh chỉnh mô hình trên tập train của bộ dữ liệu Abmusu và thử nghiệm trên tập validation. Tuy nhiên, trong quá trình đánh giá tôi nhận ra kết quả gặp phải những vấn đề khi thử nghiệm như sau:

- Mô hình sinh ra dữ liệu bằng tiếng Pháp: " Informations sur les ventes de billets pour la Coupe du monde 2022 organisée à Doha, au Qatar, ..."
- Dữ liệu đầu ra không ổn định, hầu hết là quá dài so với đầu ra của bản tóm tắt gốc.
- Đầu ra vẫn chứa ký tự của đầu vào, nội dung bị trùng lặp.
- Sinh ra các câu cụt, không đúng ngữ pháp, tập trung vào subtitle.
- Đầu ra lẫn code python.

Với những vấn đề khi mô hình sinh ra một loại ngôn ngữ khác và lẫn code của python, nguyên nhân cho vấn đề này là mô hình trước đó là mô hình đa ngôn ngữ và đã được huấn luyện trên nhiệm vụ liên quan tới mã(code). Ngoài ra các câu được mô hình sinh ra chưa đúng cú pháp, nội dung trùng lặp và độ dài không ổn định, từ đó cho thấy rằng mô hình chưa tập chung vào nhiệm vụ đặt ra và dữ liệu huấn luyện cho việc hiểu văn bản đầu vào là quá ít.

Để giải quyết vấn đề tôi sử dụng thêm 2500 mẫu văn bản tiếng việt từ bộ dữ liệu Vietnews của VietAI xuất bản năm 2021, là các bài báo từ các nguồn khác nhau. Quá trình huấn luyện này sẽ được huấn luyện đầu tiên nhằm cải thiện việc hiểu văn bản cho mô hình.

Do mô hình chưa ổn định và chưa thực sự hiển nhiệm vụ tóm tắt tóm lược đa văn bản tiếng Việt nên tôi tiến hành tăng cường với hai bộ dữ liệu ViMS và VietnameseMDS tinh chỉnh mô hình với hai bộ này trước khi huấn luyện với tập

train của bộ dữ liệu Abmusu.

4.3 Tiền xử lý dữ liệu

Quá trình tiền xử lý văn bản nhằm cải thiện chất lượng và hiệu quả của các mô hình xử lý ngôn ngữ tự nhiên (NLP). Đối với tập dữ liệu chính là bộ Abmusu mặc dù đã được tiến hành làm sạch từ ban tổ chức của cuộc thi nhưng để cho phù hợp với mô hình và cải thiện độ chính xác và vấn đề nêu ra trước đó tôi tiến hành tiền xử lý dữ liệu như sau:

- Loại bỏ các sub title và câu cụt vì mô hình có xu hướng tập trung vào những câu này và có thể nó không phải câu hoàn chỉnh.
- Dữ liệu đầu vào chứa các chú thích cho ảnh hay nguồn không cần thiết cần loại bỏ như: "Ảnh: Getty, Phil Oh.", "Nguồn: TTXVN",...
- Chuẩn hóa dữ liệu thành dạng đoạn văn vì có nhiều đoạn khi mô hình học có xu hướng không biết ngắt và có thể ngắt quá nhiều vì khi đưa vào học ký tự xuống dòng là một ký tự khá đặc biệt.
- Chuẩn hóa lại các số lớn hàng nghìn, hàng triệu do sự khác biệt phân tách trong tiếng Việt và tiếng Anh nên tôi tiến hành loại bỏ dấu phân tách này và khôi phục lại sau khi mô hình sinh xong bản tóm tắt.

4.4 Cấu hình và công cụ sử dụng

4.4.1 Cấu hình sử dụng

Mô hình thực nghiệm được sử dụng cài đặt và huấn luyện trên GPU P100 của kaggle có thông số là:

System	Information
GPU	1 x Tesla P100, 3584 CUDA cores, 16GB (16.28GB Usable) GDDR6 VRAM
CPU	1x single core hyper threaded i.e (1 core, 2 threads) Xeon Processors @2.2GHz (No Turbo Boost), 56MB Cache
RAM	~29 GB Available
Disk	~73.1 GB Available

Bảng 4.2: Chi tiết cấu hình GPU P100 trên Kaggle

4.4.2 Các thư viện cài đặt

Việc xử lý văn bản đầu vào cũng như thiết lập chuẩn bị cho mô hình cần sự hỗ trợ của các thư viện, chi tiết các phiên bản và thư viện sử dụng được nêu trong **bảng 4.3**:

Library	Version
numpy	1.25.0
pandas	2.1.3
trl	0.8.6
transformers	4.36.2
accelerate	0.25.0
peft	0.11.1
datasets	2.16.0
bitsandbytes	0.43.1
tokenizers	0.14.1
huggingface_hub	0.17.3
nltk	3.8.1

Bảng 4.3: Các thư viện sử dụng

4.5 Các phương pháp huấn luyện

4.5.1 Kỹ thuật Intruction Tuning và Prompt Engineering

Trong quá trình huấn luyện và thực nghiệm với mô hình tôi đã chọn ra một hướng dẫn (intruction) phù hợp cho việc tinh chỉnh khi sử dụng kỹ thuật Intruction Tuning[17] mô hình từ đầu, nhằm giúp mô hình hiểu được nhiệm vụ cần thực hiện:

“

> Nhiệm vụ của bạn là tạo một đoạn văn bản tóm tắt ngắn gọn cho văn bản bên dưới. Bài toán gồm đầu vào là văn bản có độ dài length1 từ, đầu ra là bản tóm tắt ngắn gọn có độ dài length2 từ, được biểu diễn như sau:
>
> `[###<Inp>###]: {input}`
> `[###<Out>###]: {output}`

"

Sau khi thực hiện quá trình tinh chỉnh tôi áp dụng kỹ thuật prompt engineering[6] xây dựng một prompt phù hợp để đánh giá mô hình, tương tự như mẫu đầu vào huấn luyện nhưng không có đầu ra đưa vào mà yêu cầu mô hình sinh ra. Tôi xây dựng như sau:

"

> Nhiệm vụ của bạn là tạo một đoạn văn tóm tắt ngắn gọn khoảng 4 đến 5 câu cho văn bản bên dưới. Bạn không được lấy câu trong văn bản gốc để đưa vào bản tóm tắt, có nghĩa là các câu trong bản tóm tắt của bạn không được giống các câu trong văn bản gốc. Bạn phải tóm tắt tóm lược cho văn bản đầu vào, nếu bạn lấy câu trong văn bản ban đầu để đưa vào

đầu ra của bản tóm tắt thì sẽ không đáp ứng được yêu cầu của nhiệm vụ này. Các câu trong bản tóm tắt đầu ra không được trùng nội dung, ý nghĩa của nhau. Mỗi câu trong bản tóm tắt phải mang sắc thái riêng và ý nghĩa riêng, đảm bảo tổng quát hóa nội dung toàn bộ văn bản đầu vào. Bây giờ, bạn hãy tóm tắt văn bản sau đây khoảng 4 đến 5 câu bằng length từ, với văn bản đầu vào được biểu diễn như sau:

```
[###<Inp>###]: {instruction}
[###<Out>###]:
```

"

4.5.2 Kỹ thuật QLoRA

Đối với kỹ thuật QloRA[21] đã được trình bày trong cơ sở lý thuyết nên sau đây tôi xin trình bày về các thiết lập tham số như sau:

LoRA:

- lora_r = 64: Thiết lập kích thước không gian bậc thấp được sử dụng bởi LoRA. Giá trị thấp hơn giúp giảm sử dụng bộ nhớ nhưng có thể ảnh hưởng đến độ chính xác.
- lora_alpha = 16: Kiểm soát tỷ lệ thu phóng cho các biến đổi LoRA. Giá trị cao hơn có thể dẫn đến nén dữ liệu mạnh mẽ hơn nhưng có thể gây ra hiện tượng không ổn định.
- lora_dropout = 0.1: Thiết lập tỷ lệ ngẫu nhiên loại bỏ (dropout) cho các lớp LoRA. Dropout giúp ngăn ngừa việc học quá mức trong quá trình huấn luyện.

Quantization:

- use_4bit = True: Kích hoạt việc tải mô hình cơ sở (LLM được đào tạo trước) với độ chính xác 4 bit, giảm sử dụng bộ nhớ so với đại diện số dấu phẩy động 32 bit tiêu chuẩn.
- bnb_4bit_compute_dtype = "float16": Thiết lập kiểu dữ liệu được sử dụng cho các phép tính trong quá trình đào tạo với các mô hình 4 bit. "float16" đề cập đến số dấu phẩy động nửa độ chính xác, hiệu quả hơn so với số dấu phẩy động 32 bit.
- bnb_4bit_quant_type = "nf4": Chỉ định loại lượng tử hóa cho các mô hình 4 bit. Ở đây, "nf4" có thể đề cập đến một lược đồ lượng tử hóa cụ thể (chi tiết chính xác có thể phụ thuộc vào triển khai).
- use_nested_quant = False: Vô hiệu hóa lượng tử hóa lồng nhau cho các mô

hình 4 bit. Lượng tử hóa lồng nhau sẽ áp dụng lượng tử hóa hai lần, có thể giảm thêm việc sử dụng bộ nhớ nhưng cũng có thể ảnh hưởng đến độ chính xác.

Nhìn chung, cấu hình các tham số cho kỹ thuật LoRA và lượng tử hóa để tối ưu hóa hiệu suất cho LLM trong khi vẫn duy trì độ chính xác. Các giá trị này có thể khắc phục cho hạn chế phần cứng, giảm chi phí khi huấn luyện mô hình.

4.6 Phương pháp thực nghiệm

Trong phần này, tôi sẽ triển khai ý tưởng đã chọn khả thi và phù hợp với bài toán và xu thế hiện nay. Quá trình thử nghiệm nhằm xây dựng ra hệ thống tóm tắt tóm lược đa văn bản tiếng Việt đáp ứng được yêu cầu ban đầu của bài toán bằng việc xử dụng mô hình ngôn ngữ lớn. Quá trình huấn luyện, xem xét và đánh giá cho mô hình được thực hiện một cách khách quan dựa trên những gì đã làm được và kết quả của mô hình.

Quá trình thực nghiệm được tiến hành một cách chặt chẽ, mạch lạc, đảm bảo được sự khách quan và tin cậy của mô hình đánh giá, từ đó xem xét tổng quan cho mô hình. Đồng thời lựa chọn ra mô hình baseline phù hợp để so sánh với kết quả đã thu được trên mô hình đã đề xuất.

4.6.1 Các baseline cho bài toán

Đối với mỗi mô hình thực nghiệm cần chọn ra những mô hình baseline phù hợp, trong khuôn khổ đồ án và đối với tập dữ liệu đánh giá Abmusu 2022 tôi sẽ lấy 4 phương pháp là những kết quả tốt đạt được trong cuộc thi, được xếp hạng và công bố trên trang của cuộc thi VLSP2022 AbMusu task [2] . Cuộc thi lấy kết quả điểm R-2 (ROUGE-2) làm tiêu chí để đánh giá cho bảng xếp hạng, đồng thời các kết quả khác cũng được tính trên độ đo Rouge-1, Rouge-L như sau:

Model	R2	R1	RL
Hybrid	31.50	51.68	48.93
Textrank, Lexrank, MMR	29.31	50.8	47.33
T5, Lexrank	28.41	49.32	45.47
Extractive+abstractive	25.86	46.58	42.27

Bảng 4.4: Kết quả các mô hình baseline

Mô hình baseline đầu tiên được sử dụng xếp hạng nhất trong cuộc thi được giới thiệu trong bài báo [26]. Mô hình sử dụng sự kết hợp giữa phương pháp tóm tắt trích xuất và tóm tắt tóm lược. Đối với mô hình trích xuất áp dụng mô hình GL-LSTM nhận đầu vào là các vector embedding của các chuỗi đại diện cho các câu,

[2]https://aihub.ml/competitions/341#results

sau đó truyền các vector đại diện này qua mạng thần kinh hồi tiếp (Recurrent neural network) bằng việc sử dụng Bi-LSTM kết hợp với một tầng MLP ở cuối. Đối với mô hình tóm lược sử dụng BartPho là mô hình tuần tự đơn ngữ dành cho tiếng việt. Hai mô hình này được kết hợp với nhau rồi tiến hành loại bỏ sự dư thừa thông tin chọn ra những câu phù hợp và sử dụng Rouge 2 Recall để điều chỉnh cho mô hình.

Mô hình tiếp theo sử dụng thuật toán trích rút kết hợp giữa các thuật toán Textrank, Lexrank và MMR. Với tập dữ liệu ban đầu sau khi tiền xử lý sẽ tiến hành bằng hai luồng, luồng thứ nhất tách và sắp xếp bằng Lexrank và Textrank đánh giá điểm sử dụng kết hợp hai thuật toán này với trọng số cho điểm mỗi trọng số là khác nhau, luồng thứ hai sử dụng mô hình Bert để đưa ra dạng nhúng của các câu. Cả hai luồng này sau đó kết hợp đi qua thuật toán MMR sắp xếp lại và tạo thành bản tóm tắt.

Mô hình thứ ba là việc sử dụng kết hợp mô hình BERT, T5 và Lexrank. Đầu tiên sử dụng mô hình lexrank để chọn top-N câu quan trọng nhất, tiến hành mã hóa các câu theo mô hình Bert. Cuối cùng sủ dụng mô hình T5 để tạo ra một bản tóm tắt phù hợp.

Đối với mô hình baseline cuối cùng, mô hình sử dụng phương pháp lai kết hợp phương pháp trích xuất với mô hình tóm lược để tạo ra một bản tóm tắt. Ban đầu xây dựng mô hình chọn ra k câu quan trọng nhất từ một tập tài liệu nhằm tạo ra phiên bản cô đọng của tài liệu trong khi vẫn bảo toàn được nội dung quan trọng của tài liệu. Sau khi thu được dữ liệu cần thiết, sử dụng mô hình T5 encoder-decoder được đào tạo trước với tiếng Việt để tiến hành sinh ra bản tóm tắt đầu ra đã yêu cầu.

4.6.2 Phương pháp đề xuất sử dụng Vistral-7B-Chat

Phương pháp này xây dựng dựa trên mô hình ngôn ngữ lớn Vistral-7B-Chat. Trước hết khi khảo sát xem mô hình đã được đánh giá trên nhiệm vụ tóm tắt văn bản hay chưa sau đó tiến hành Instruction Tuning cho mô hình học và hiểu nhiệm vụ tóm tắt tóm lược đa văn bản tiếng Việt. Quá trình tinh chỉnh thực hiện lần lượt với các bộ dữ liệu. Đầu tiên cần huấn luyện với 2500 mẫu dữ liệu Vietnews, sau đó mới huấn luyện trên tập ViMS và VietnameseMDS. Cuối cùng huấn luyện với tập train của bộ Abmusu.

Đối với bộ dữ liệu đánh giá chính thực hiện tiền xử lý phù hợp loại bỏ những chi tiết không cần thiết, những nhiễu và nội dung có thể ảnh hưởng đến kết quả của bài toán. Dữ liệu sau khi xử lý được thiết kế với kỹ thuật Prompt Engineering cho mô hình có thể sinh một cách tốt nhất phù hợp với những gì đã huấn luyện mô hình trước đó.

Kết quả sau khi thu được tiến hành hậu xử lý bởi quá trình sinh dữ liệu ra vẫn chứa một số ký tự đặc biệt và khôi phục các dấu phù hợp như dấu phân tách hàng nghìn, hàng triệu đã bỏ ở bước tiền xử lý. Kết quả cuối cùng được đánh giá dựa trên độ đo ROUGE và tiến hành so sánh với các baseline được đề xuất và phương pháp tiên tiến đã được sử dụng.

4.6.3 Đề xuất mô hình so sánh phù hợp hiện nay

Mặc dù đã chọn được các mô hình baseline cho việc đánh giá khách quan cho kết quả của mô hình đề xuất, tuy nhiên với sự phát triển vượt bậc của trí tuệ nhân tạo nói chung và các mô hình ngôn ngữ lớn nói riêng, đòi hỏi chọn ra một mô hình đánh giá khách quan cho thời điểm hiện tại. Từ đó, tôi chọn mô hình ngôn ngữ lớn Vinallama 7B làm mô hình đánh giá cho khả năng của mô hình đề xuất sử dụng. Bởi Vinallama là mô hình ngôn ngữ nền tảng đột phá được thiết kế riêng cho ngôn ngữ Việt Nam được thiết kế dựa trên LlaMa-2 của Meta AI với hơn 800 tỷ token đào tạo bổ sung. Mô hình đạt kết quả vượt trội trong một loạt các nhiệm vụ như lý luận, toán học kể cả trong cuộc thi VLSP, và được huấn luyện đạt kết quả cao trong nhiệm vụ tóm tắt văn bản. Do đó tôi tiến hành chạy thử nghiệm đánh giá trực tiếp cho tập dữ liệu Abmusu 2022 đồng thời lấy kết quả so sánh với mô hình thực nghiệm đã sử dụng.

Để đảm bảo tính khách quan khi so sánh với phương pháp sử dụng giải quyết bài toán, tôi sẽ tiến hành xử lý dữ liệu tương tự như quá trình xử lý với mô hình đề xuất Vistral-7B-Chat. Sau đó, cho dữ liệu vào Vinallama để sinh các dự đoán tóm tắt cho các văn bản. Với việc mô hình Vinallama hiện nay được đánh giá cao thực hiện các nhiệm vụ trong xử lý ngôn ngữ tự nhiên đặc biệt là các tác vụ trong cuộc thi VLSP nên đây sẽ là ngưỡng kết quả để có thể so sánh mô hình của tôi đồng thời có thể xem xét các vấn đề nào của mô hình sử dụng Vistral-7B-Chat

Tôi đã tiến hành thử nghiệm mô hình Vinallama với bộ dữ liệu Abmusu được xử lý phù hợp đã đạt kết quả như sau:

Tên mô hình	**Vinallama**
ROUGE-2	35.48
ROUGE-1	62.94
ROUGE-L	33.79

Bảng 4.5: Hiệu suất của mô hình Vinallama

Đối với kết quả này hoàn toàn phù hợp với công bố cho bài báo của Vinallama khi đạt trạng thái SOTA đối với nhiệm vụ của tóm tắt văn bản, vì nếu kết quả này được thực hiện khi còn thời hạn cuộc thi sẽ là kết quả xếp hạng nhất với các thông

số cho ROUGE-2 và ROUGE-1 vượt trội.

4.7 Các siêu tham số

Trong quá trình huấn luyện, bên cạnh việc tối ưu các tham số như trọng số và độ lệch của mô hình, việc lựa chọn các siêu tham số cũng rất quan trọng.Sau quá trình tìm hiểu và thử nghiệm tôi chọn ra bộ tham số cho mô hình:

1. Độ dài chuỗi tối đa (max sequence length) Đối với bài toán tóm tắt đa văn bản tiếng Việt, cũng như dựa trên mô hình Vistral-7B-Chat, tôi quyết định giới hạn cho đầu vào huấn luyện ban đầu là 1024 tokens nhằm tối ưu thời gian huấn luyện cũng như tránh việc tràn bộ nhớ VRAM của GPU.

2. Epoch mỗi epoch là quá trình huấn luyện một lần toàn bộ dữ liệu cho mô hình. Mô hình ngôn ngữ Vistral-7B-Chat, với 7 tỷ tham số, đã được huấn luyện trên nhiều tập dữ liệu và nhiệm vụ khác nhau, khiến nó trở thành một mô hình tiền huấn luyện (pretrained) với khả năng hiểu ngữ nghĩa và thích ứng tốt với nhiều loại bài toán. Mô hình được thử nghiệm trên kaggle với cấu hình GPU P100 với mỗi phiên sử dụng giới hạn 12h liên tục. Do mô hình có kích thước lớn được thử nghiệm trên Kaggle với GPU P100, mỗi phiên hoạt động trên nền tảng này được giới hạn 12h giờ mà thời gian huấn luyện cho mỗi epoch khá dài do đó tôi thiết lập số lượng epoch của thử nghiệm là 1.

3. Kích thước lô (batch size) Đây là lượng điểm đưa qua mô hình trong quá trình huấn luyện một bước nhằm thực hiện tối ưu hóa cho mô hình. Đối với thử nghiệm của bản thân, tôi đã chọn kích thước lô batch_size = 4 để tránh việc tràn bộ nhớ, do tài nguyên VRAM và GPU được sử dụng bị hạn chế.

4. Tốc độ học (learning rate) Trong quá trình huấn luyện mô hình tốc độ học được thiết lập là 1e-4 (10-4).

   Các siêu tham số đã được thiết lập trong quá trình thử nghiệm:

Loại siêu tham số	Giá trị
batch_size	4
epochs	1
learning_rate	1e-4
max_seq_length	1048

Bảng 4.6: Giá trị của siêu tham số

4.8 Kết quả mô hình Vistral-7B-chat

Với việc sử dụng kỹ thuật Instruction Tuning huấn luyện mô hình có hướng dẫn phù hợp cho nhiệm vụ tóm tắt tóm lược đa văn bản tiếng Việt với các bộ dữ liệu

khác nhau kết hợp các kỹ thuật đề xuất như Qlora giảm thời gian và tài nguyên bộ nhớ cần thiết khi huấn luyện. Tuy nhiên, quá trình huấn luyện vẫn khá lớn khoảng 40h huấn luyện 2500 mẫu tóm tắt đơn văn bản Vietnews, khoảng 20h cho ba bộ dữ liệu tóm tắt đa văn bản tiếng Việt là ViMs, VietnameseMDS và tập train của bộ dữ liệu Abmusu. Do việc giới hạn của thời gian chạy của kaggle mỗi phiên nên quá trình huấn luyện gặp nhiều khó khăn nhưng đã đạt được kết quả đáng mong đợi:

Model	**R1**	**R2**	**RL**
Hybrid	51.68	31.50	48.93
Textrank, Lexrank, MMR	50.80	29.31	47.33
T5, Lexrank	49.32	28.41	45.47
Extractive+abstractive	46.58	25.86	42.27
Vinallama	62.94	35.48	33.79
Vistral-7B-Chat	42.27	27.03	28.81
Vistral-7B Summary	**69.52**	**37.94**	37.30

Bảng 4.7: Kết quả mô hình Vistral-7b-Chat

Dựa theo kết quả của các độ đo cũng như cuộc thi VLSP 2022, mô hình tôi sử dụng đạt kết quả vượt trội so với các phương pháp còn lại kể cả mô hình tiên tiến nhất cho ngôn ngữ tiếng Việt đánh giá trên dữ liệu tóm tắt tóm lược đa văn bản tiếng Việt là Vinallama. Tuy nhiên, đối với độ đo ROUGE-L lại chưa được cao, điều này khá dễ hiểu cho các mô hình ngôn ngữ vì các mô hình này dựa trên toàn bộ văn bản để đưa ra một bản tóm tắt theo chính sự hiểu biết của mô hình, khác với các mô hình truyền thống khi trích xuất các câu gốc từ văn bản, đồng thời tôi nhận thấy bản tóm tắt do người tham chiếu cũng hầu hết dựa trên các câu gốc của văn bản và nhiều câu không sửa quá nhiều nên làm cho độ đo này thấp hơn.

Kết quả này cho thấy khả năng vượt trội của mô hình ngôn ngữ lớn hiện nay cho quá trình đọc hiểu văn bản và có thể hiểu sâu được ngôn ngữ để đưa ra văn bản tóm tắt tự nhiên, mạch lạc nhưng vẫn đầy đủ.

4.9 Một số quan sát cụ thể

Vistral-7B-Chat: " Chuyến bay của hãng Viva Aerobus mang số hiệu VB518, có sức chứa 186 hành khách, khởi hành từ Guadalajara, Mexico, tối 24/8 (giờ địa phương). 10 phút sau khi cất cánh, hành khách phát hiện tia lửa bắn ra từ động cơ bên phải của máy bay. Một số hành khách cho biết đã nghe thấy “âm thanh của một vụ nổ”. Tình huống này đã khiến nhiều hàng khách hoảng loạn, một số người than khóc, la hét và cầu nguyện. Phi hành đoàn nhận được cảnh báo khi máy bay đang ở độ cao tương đương 4.000 m và đã quay trở lại hạ cánh tại sân bay Guadalajara, 45 phút sau khi cất cánh. Rất may mắn, vụ việc này không biến thành một thảm họa hàng không. Viva Aerobus cho biết tia lửa điện trong động cơ là do “ma sát của

kim loại”. Theo hãng hàng không này, các hành khách trên chuyến bay đã được đưa đến một khách sạn và tiếp tục hành trình vào sáng hôm sau. Đây là lần thứ hai một chiếc máy bay của Viva Aerobus phải hạ cánh khẩn cấp ở Mexico trong 3 tháng qua."

Vinallama-7B: " Viva Aerobus đã trải qua một vụ hạ cánh khẩn cấp khác tại Mexico chỉ ba tháng trước. Vào ngày 22 tháng 5, một chuyến bay khởi hành từ Villahermosa và hướng đến Mexico City đã phải hạ cánh khẩn cấp sau khi một con chim bất ngờ lao vào tuabin động cơ. May mắn thay, không có tai nạn nào xảy ra và các hành khách đã được chuyển đến một khách sạn khác để tiếp tục hành trình của họ. Nguyên nhân của cả hai sự cố vẫn đang được điều tra. Viva Aerobus, một hãng hàng không giá rẻ của Mexico, đã phải đối mặt với hai vụ hạ cánh khẩn cấp chỉ trong vòng ba tháng qua. Nguyên nhân của vụ việc vẫn đang được điều tra. Trong một chuỗi sự kiện đáng lo ngại, Viva Aerobus đã trải qua hai lần hạ cánh khẩn cấp tại Mexico trong vòng chưa đầy ba tháng"

Người tham chiếu: " Chuyến bay của hãng Viva Aerobus mang số hiệu VB518, có sức chứa 186 hành khách, khởi hành từ Guadalajara, Mexico, tối 24/8 (giờ địa phương), dự kiến kéo dài 3 tiếng. Khoảng 10 phút sau khi cất cánh, hành khách phát hiện tia lửa bắn ra từ động cơ bên phải của máy bay. 45 phút sau khi cất cánh, khi máy bay đang ở độ cao tương đương 4.000 m, phi hành đoàn đã cho máy bay quay trở lại hạ cánh tại sân bay Guadalajara. Rất may mắn, vụ việc này không biến thành một thảm họa hàng không. Nguyên nhân vụ việc đang tiếp tục được điều tra làm rõ."

CHƯƠNG 5. KẾT LUẬN

5.1 Kết luận

Đồ án tốt nghiệp đã tiến hành nghiên cứu giải quyết rất tốt bài toán tóm tắt tóm lược đa văn bản tiếng Việt dựa trên mô hình ngôn ngữ lớn. Bài toán có thể phổ biến nhưng độ phức tạp lại lớn và có nhiều ứng dụng vào đời sống thực tiễn. Quá trình triển khai phương pháp cho bài toán tóm tắt tóm lược đa văn bản tiếng Việt trên tập dữ liệu Abmusu thành công. Kết quả của mô hình Vistral-7B-Chat mà tôi sử dụng đạt được kết quả vượt trội so với các nghiên cứu trước đó, tuy nhiên mô hình lại tốn lượng lớn tài nguyên và thời gian huấn luyện. Mô hình tóm tắt tóm lược đa văn bản tiếng Việt được đề xuất trong nghiên cứu cũng đã cho thấy kết quả ổn định, ngôn ngữ sinh ra tự nhiên, mạch lạc, có độ dài phù hợp. Kết quả này rất khả quan cho những thực nghiệm của đồ án đáp ứng được yêu cầu phần nào của bài toán đặt ra, cho thấy tính đúng đắn của việc lựa chọn phương pháp sử dụng đánh giá, đây có thể sẽ là nền tảng phát triển tiềm năng hoàn thiện cho bài toán này.

5.2 Hướng phát triển trong tương lai

Đồ án đã đạt được nhiều kết quả tích cực nhưng vẫn chưa thể hoàn hảo và một số hướng phát triển tiềm năng có thể được áp dụng:

1. Thực hiện xây dựng mô hình với nhiều dữ liệu tiếng Việt chọn lọc hơn, các mối quan hệ trong dữ liệu chặt chẽ để mô hình có thể hiểu sâu hơn nữa.
2. Áp dụng kỹ thuật học từ phản hồi của người dùng Reinforcement Learning from Human Feedback – RLHF là một kỹ thuật học tăng cường nhằm tối ưu hóa cho bài toán.
3. Nâng cấp cấu hình tránh những hạn chế cho việc huấn luyện và đánh giá, sử dụng các kỹ thuật làm tăng cường hiệu quả tránh sự sụt giảm kết quả.

TÀI LIỆU THAM KHẢO

[1] I. Sutskever, O. Vinyals **and** Q. V. Le, *Sequence to sequence learning with neural networks*, 2014. arXiv: 1409.3215.

[2] A. Vaswani, N. Shazeer, N. Parmar **andothers**, *Attention is all you need*, 2023. arXiv: 1706.03762.

[3] K. O'Shea **and** R. Nash, *An introduction to convolutional neural networks*, 2015. arXiv: 1511.08458.

[4] R. M. Schmidt, *Recurrent neural networks (rnns): A gentle introduction and overview*, 2019. arXiv: 1912.05911.

[5] K. Aitken, V. V. Ramasesh, Y. Cao **and** N. Maheswaranathan, *Understanding how encoder-decoder architectures attend*, 2021. arXiv: 2110.15253.

[6] H. Patel **and** S. Parmar, *Prompt engineering for large language model*, **march** 2024. DOI: 10.13140/RG.2.2.11549.93923.

[7] Q. Dong, L. Li, D. Dai **andothers**, *A survey on in-context learning*, 2024. arXiv: 2301.00234 [cs.CL]. **url**: https://arxiv.org/abs/2301.00234.

[8] VMLU, *A vietnamese multitask language understanding benchmark suite for large language models*, https://vmlu.ai/, 2023.

[9] H. Touvron, L. Martin, K. Stone **andothers**, *Llama 2: Open foundation and fine-tuned chat models*, 2023. arXiv: 2307.09288 [cs.CL]. **url**: https://arxiv.org/abs/2307.09288.

[10] X. Jiang, Y. Ge, Y. Ge, D. Shi, C. Yuan **and** Y. Shan, *Supervised fine-tuning in turn improves visual foundation models*, 2024. arXiv: 2401.10222 [cs.CV]. **url**: https://arxiv.org/abs/2401.10222.

[11] Q. Nguyen, H. Pham **and** D. Dao, *Vinallama: Llama-based vietnamese foundation model*, 2023. arXiv: 2312.11011 [cs.CL]. **url**: https://arxiv.org/abs/2312.11011.

[12] D. Q. Nguyen, L. T. Nguyen, C. Tran, D. N. Nguyen, D. Phung **and** H. Bui, *Phogpt: Generative pre-training for vietnamese*, 2024. arXiv: 2311.02945 [cs.CL]. **url**: https://arxiv.org/abs/2311.02945.

[13] V. Zouhar, C. Meister, J. L. Gastaldi **andothers**, *A formal perspective on byte-pair encoding*, 2023. arXiv: 2306.16837 [cs.CL]. **url**: https://arxiv.org/abs/2306.16837.

[14] A. Q. Jiang, A. Sablayrolles, A. Mensch **andothers**, *Mistral 7b*, 2023. arXiv: 2310.06825.

[15] Q. N. H. N. B. P. N. P. H. N. P. S. T. N. Chien Van Nguyen Thuat Nguyen, "Vistral-7b-chat - towards a state-of-the-art large language model for vietnamese," 2023.

[16] Z. Ke, Y. Shao, H. Lin, T. Konishi, G. Kim **and** B. Liu, *Continual pre-training of language models*, 2023. arXiv: 2302.03241.

[17] S. Zhang, L. Dong, X. Li **andothers**, *Instruction tuning for large language models: A survey*, 2024. arXiv: 2308.10792.

[18] Y. Liu, T. Han, S. Ma **andothers**, "Summary of chatgpt-related research and perspective towards the future of large language models," *Meta-Radiology*, **jourvol** 1, **number** 2, **page** 100 017, **september** 2023, ISSN: 2950-1628. DOI: 10.1016/j.metrad.2023.100017. **url**: http://dx.doi.org/10.1016/j.metrad.2023.100017.

[19] C.-Y. Lin, "ROUGE: A package for automatic evaluation of summaries," **in***Text Summarization Branches Out* Barcelona, Spain: Association for Computational Linguistics, **july** 2004, **pages** 74–81. **url**: https://aclanthology.org/W04-1013.

[20] E. J. Hu, Y. Shen, P. Wallis **andothers**, *Lora: Low-rank adaptation of large language models*, 2021. arXiv: 2106.09685.

[21] T. Dettmers, A. Pagnoni, A. Holtzman **and** L. Zettlemoyer, *Qlora: Efficient finetuning of quantized llms*, 2023. arXiv: 2305.14314.

[22] J. Wei, M. Bosma, V. Y. Zhao **andothers**, *Finetuned language models are zero-shot learners*, 2022. arXiv: 2109.01652 [cs.CL]. **url**: https://arxiv.org/abs/2109.01652.

[23] Z. Li, Z. Yang **and** M. Wang, *Reinforcement learning with human feedback: Learning dynamic choices via pessimism*, 2023. arXiv: 2305.18438 [cs.LG]. **url**: https://arxiv.org/abs/2305.18438.

[24] VLSP 2022, *Vlsp 2022*, https://vlsp.org.vn/vlsp2022, 2022.

[25] N.-T. Tran, M.-Q. Nghiem, N. T. Nguyen, N. L.-T. Nguyen, N. Van Chi **and** D. Dinh, "Vims: A high-quality vietnamese dataset for abstractive multi-document summarization," *Language Resources and Evaluation*, **jourvol** 54, **number** 4, **pages** 893–920, 2020.

[26] T.-M. Nguyen, T.-B. Nguyen, H.-T. Nguyen **andothers**, *Lbmt team at vlsp2022-abmusu: Hybrid method with text correlation and generative models for vietnamese multi-document summarization*, 2023. arXiv: 2304.05205 [cs.CL]. **url**: https://arxiv.org/abs/2304.05205.